

Cours ECE_4ES01_TA 2025

Architecture des microprocesseurs

Recueil de travaux dirigés - Travaux pratiques

Omar Hammami

École Nationale Supérieure
de Techniques Avancées

ENSTA



INSTITUT
POLYTECHNIQUE
DE PARIS

Table des matières

TD/TP1 : Evaluation de performances - programmation assembleur MIPS.....	6
Exercice 1 : Evaluation de performances analytique - Loi d'Amdahl	6
Exercice 2 : Evaluation de performances analytique - Loi d'Amdahl	6
Exercice 3 : Evaluation de performances – simulation	7
Exercice 4 : Commentaire d'un programme en assembleur MIPS.....	8
Exercice 5 : Programmation en assembleur MIPS.....	8
Exercice 6 : Encodage en assembleur MIPS.....	8
Exercice 7 : Commentaire du programme en assembleur MIPS.....	9
Exercice 8 : Programmation en assembleur MIPS (somme d'un tableau).....	9
TD/TP2 : Programmation assembleur MIPS - profiling d'applications et ISS (instruction set simulator)	14
Exercice 1 : Switch statement	15
Exercice 2 : Boucles	15
Exercice 3 : Appels de fonctions	15
Exercice 4 : Appels de fonctions	16
Exercice 5 : Profiling d'applications (% d'instructions par catégorie) par simulation sur ISS (instruction set simulator)	17
TD/TP3 : Processeur pipeline – superscalaire	19
Exercice 1 : Pipeline.....	19
Exercice 2 : Pipeline - Data Forwarding	20
Exercice 3 : Impact du nombre d'unités fonctionnelles	21
Exercice 4 : Exécution dans l'ordre (in-order) VS exécution dans le désordre (out-of-order).....	22
TD/TP4 : Microprocesseur superscalaire/mémoires caches - Analyse de configurations d'architectures de microprocesseurs	25
Exercice 1 : Prédiction de branchement.....	25
Exercice 2 : Impact de la fenêtre d'instructions RUU	27
Exercice 3 : Mémoires caches - Evaluation des performances de différentes configurations de mémoires caches (instructions et données) pour 4 algorithmes de multiplication de matrices.	28
Exercice 4 : Mémoires caches - Evaluation des performances de différentes configurations de mémoires caches (instructions et données)	31
Questions	34
TD/TP5 : Analyse de performances de configurations de microprocesseurs multicoeurs pour des applications parallèles.	39
Description de l'application multiplication de matrice parallèle.....	40

Questions	42
TD/TP6 : Microprocesseurs et Energie	47
Exercice 1 : Lois Physiques Energie – Puissance.....	47
Exercice 2 : Mode de gestion de l'énergie des microprocesseurs (ARM) et FSM.....	48
Exercice 3 : Microélectronique	49
Exercice 4 : Evaluation de performances – McPAT	50
Solution TD/TP1 : Evaluation de performances - programmation assembleur MIPS/DLX	53
Exercice 1 : Evaluation de performances analytique - Loi d'Amdahl	53
Exercice 2 : Evaluation de performances analytique - Loi d'Amdahl	53
Exercice 3 : Evaluation de performances – simulation	54
Exercice 4 : Commentaire d'un programme en assembleur MIPS.....	56
Exercice 5 : Programmation en assembleur MIPS.....	56
Exercice 6 : Encodage en assembleur MIPS.....	57
Exercice 7 : Commentaire du programme en assembleur MIPS.....	59
Exercice 8 : Programmation en assembleur MIPS (somme d'un tableau).....	60
Solution TD/TP2 : Programmation assembleur MIPS/DLX (sous programmes-équivalent langage C) - profiling d'applications et ISS (instruction set simulator).....	61
Exercice 1 : Switch statement	62
Exercice 2 : Boucles	64
Exercice 3 : Appels de fonctions	65
Exercice 4 : Appels de fonctions	66
Exercice 5 : Profiling d'applications (% d'instructions par catégorie) par simulation sur ISS (instruction set simulator)	67
Solution TD/TP3 : Processeur pipeline – compilateur.....	70
Exercice 1 : Pipeline.....	70
Exercice 2 : Pipeline - Data Forwarding	72
Exercice 3 : Impact du nombre d'unités fonctionnelles	75
Exercice 4 : Exécution dans l'ordre (in-order) VS exécution dans le désordre (out-of-order).....	78
Solution TD/TP4 : Microprocesseur superscalaire / mémoires caches – Analyse de configurations d'architectures de microprocesseurs	80
Exercice 1 : Prédiction de branchement.....	80
Exercice 2 : Impact de la fenêtre d'instructions RUU	82
Exercice 3 : Mémoires caches - Evaluation des performances de différentes configurations de mémoires caches (instructions et données) pour 4 algorithmes de multiplication de matrices.	84
Solution TD/TP6 : Microprocesseurs et Energie.....	88
Exercice 1 : Lois Physiques Energie – Puissance.....	88

Exercice 3 : Microélectronique	93
Exercice 4 : Evaluation de performances – MPACT	96
Hors-Programme – Pour aller plus loin...	99
Compilateur – analyse de dépendances.....	99
Impact du ré-ordonnancement de code - Loop unrolling	99
Compilation – Optimisation automatique.....	102
Annexe 1 : SimpleScalar.....	109
Annexe 2 : Applications	112
PageRank	112
Betweenness Centrality Score – SSCA #2	112
La multiplication de polynômes	113
Secure Hash Algorithm (SHA-1).....	113
Bloc cipher BlowFish	114
Autres applications 2020 :	114
• <i>EEMBC : https://www.eembc.org/</i>	114
Annexe 3 : gem5 – généralités	115
1. Résolution des dépendances, récupération des sources et compilation de gem5 :.....	115
2. Installation du cross-compilateur :.....	116
3. Installation de la librairie m5threads :.....	116
4. Compilation et exécution d'un programme sur le simulateur gem5 :.....	116
5. Statistiques d'exécution de gem5 :	117
Annexe 4 : gem5 – mémo TP5-6	119
Log in sur machine salle 2013 :.....	119
Compilation de l'application de multiplication de matrice :	119
Commande pour lancer une simulation :	119
Statistiques :	120
Annexe 5 : McPAT: An Integrated Power, Area, and Timing Modeling Framework for Multicore and Manycore Architectures	121
Références	122
TP2.....	122
TP3.....	122
TP4.....	122
TP5.....	123
TP6.....	123

Table des Figures

Tableau 1 Evaluation de performance	7
Tableau 2 Jeu d'instructions du MIPS	10
Tableau 3 Tableau 3 Codage des instructions assembleur du MIPS.....	12
Tableau 4 Formats des instructions assembleur du MIPS	13
Tableau 5 File de registres MIPS	14
Tableau 6 Pourcentage de chaque classe d'instructions	17
Tableau 7 Configurations de caches pour 2 processeurs.....	28
Tableau 8 Paramètres de sim-cache pour chaque configuration	29
Tableau 9 Instruction Cache (il1) Miss Rate	29
Tableau 10 Data Cache (dl1) Miss Rate.....	29
Tableau 11 Unified Cache (ul2) Miss Rate	30
Tableau 12 Paramètres de configuration des processeurs.....	33
Tableau 13 File de registres MIPS	61
Tableau 14 Pourcentage de chaque classe d'instructions	68
Tableau 15 Paramètres du prédicteur de branchement	81
Tableau 16 Configurations de caches pour 2 processeurs.....	84
Tableau 17 Paramètres de sim-outorder pour chaque configuration	85
Tableau 18 Instruction Cache (il1) Miss Rate	86
Tableau 19 Data Cache (dl1) Miss Rate.....	86
Tableau 20 Unified Cache (ul2) Miss Rate	86
Tableau 21 Résultats du #pragma unroll(n).....	105
Tableau 22 Statistiques sur les caches en sortie du simulateur SimpleScalar	110

TD/TP1 : Evaluation de performances - programmation assembleur MIPS

Exercice 1 : Evaluation de performances analytique - Loi d'Amdahl

Nous souhaitons améliorer les performances d'un microprocesseur en réduisant d'un facteur 5 le temps d'exécution des instructions flottantes. Nous souhaiterions évaluer l'impact d'une telle transformation sachant que le temps d'exécution d'un benchmark avant l'amélioration prend 10 secondes et que 50% du temps est dépensé dans l'exécution de calcul flottant.

Q1 : Quel serait le speed up ?

Les instructions flottantes sont 5*plus rapides mais les autres instructions ne changent pas ANCIEN TEMPS -> NOUVEAU TEMPS
 $5 \text{ (op flott)} + 5 \rightarrow 1 \text{ (op flott)} + 5$

$$\text{speed up} = \text{ancienTemps}/\text{nouveauTemps} = 10/6 = 1.66$$

Exercice 2 : Evaluation de performances analytique - Loi d'Amdahl

Nous souhaiterions améliorer les performances d'un microprocesseur et il existe 2 moyens :

1. Réduire le temps d'exécution des instructions de multiplication d'un facteur 4.
2. Réduire le temps d'exécution des instructions d'accès mémoire d'un facteur 2.

L'exécution du programme benchmark prend 100 secondes et utilise :

- 20 % des instructions pour la multiplication,
- 50% des instructions pour les accès mémoire,
- 30% des instructions pour les autres types d'opérations.

Q1 : Quel est le speedup si l'on améliore uniquement la multiplication ?

Ancien temps -> nouveau temps
 $20 + 50 + 30 \rightarrow 20/4 + 50 + 30$
 On a : 100 -> 85 donc Speed up = $100/85 = 1.18$

Q2 : Quel est le speedup si l'on améliore uniquement les accès mémoires ?

Ancien temps -> nouveau temps
 $20 + 50 + 30 \rightarrow 20 + 50/2 + 30$
 On a : 100 -> 75 donc Speed up = $100/75 = 1.33$

Q3 : Quel est le speedup si l'on améliore les deux ?

Ancien temps -> nouveau temps
 $20 + 50 + 30 \rightarrow 20/4 + 50/2 + 30$
 On a : 100 -> 60
 Speed up = $100/60 = 1.66$

Exercice 3 : Evaluation de performances – simulation

Nous souhaitons mesurer certains paramètres de performance d'un programme en utilisant un simulateur de processeur (Instruction Set Simulator – ISS). Pour cela, nous allons écrire un programme en C qui sera compilé dans un jeu d'instructions interprétable par le simulateur. L'exécutable généré sera alors simulé.

Ecrire un programme en C effectuant la somme de deux vecteurs de taille $N = 50$ que vous initialiserez de manière aléatoire. Compilez ce programme avec `sslittle-na-sstrix-gcc`. Les informations concernant l'utilisation du compilateur pour SimpleScalar se trouvent en Annexe 1.

```
sslittle-na-sstrix-gcc votreprog.c -o votreprog.ss
```

Cette commande générera un exécutable pour le processeur SimpleScalar avec un format « *.ss ». Simulez ce programme en utilisant le simulateur SimpleScalar (in-order).

```
sim-outorder -issue:inorder true votreprog.ss
```

Complétez Tableau 1 avec les valeurs suivantes :

Q1 : Quel est le nombre total d'instructions exécutées par votre programme sur ce processeur ? `sim_total_insn`

Q2 : Quel est le nombre total de cycles processeur nécessaires pour l'exécution du programme ? `sim_cycles`

Q3 : Quel est le CPI de votre programme sur ce processeur ? `sim_CPI`

Q4 : Quel est l'IPC de votre programme sur ce processeur ? `sim_IPC`

Tableau 1 Evaluation de performance

Paramètres	Valeur
nombre total d'instructions exécutées	7836
nombre total de cycles processeur	17537
CPI	2.23
IPC	0.44

Q5 : Pour un processeur ayant une fréquence d'horloge de 3 GHz, quelle est la durée d'exécution de votre programme ?

Exercice 4 : Commentaire d'un programme en assembleur MIPS

A l'aide du Tableau 2 du jeu d'instructions assembleur MIPS, commentez le programme suivant et indiquez ce que fait la fonction $F(X, Y, Z)$.

On suppose que la variable X se trouve dans le registre \$s1, la variable Y dans \$s2 et la variable Z dans \$s3. Le résultat de la fonction $F(X, Y, Z)$ se trouve dans le registre \$s7.

add \$s7, \$s1, \$s1	$\$s7 = \$s1 + \$s1$	$res = X + X = 2X$
add \$s7, \$s7, \$s7	$\$s7 = \$s7 + \$s7$	$res = res + res = 4X$
add \$s7, \$s7, \$s3	$\$s7 = \$s7 + \$s3$	$res = res + Z = 4X + Z$
add \$s7, \$s7, \$s3	$\$s7 = \$s7 + \$s3$	$res = res + Z = 4X + 2Z$
add \$s7, \$s7, \$s2	$\$s7 = \$s7 + \$s2$	$res = res + Y = 4X + 2Z + Y$

$$F(X, Y, Z) = 4X + 2Z + Y$$

Exercice 5 : Programmation en assembleur MIPS

A l'aide du Tableau 2 du jeu d'instructions MIPS, programmez en assembleur MIPS la fonction $F(X, Y, Z) = X + 2Y - 3Z$.

On suppose que la variable X se trouve dans le registre \$s1, la variable Y dans \$s2, la variable Z dans \$s3 et que le résultat de la fonction $F(X, Y, Z)$ se trouve dans le registre \$s7.

add \$s7, \$s7, \$s1	+ X
add \$s7, \$s7, \$s2	+ Y
add \$s7, \$s7, \$s2	+ Y
sub \$s7, \$s7, \$s3	- Z
sub \$s7, \$s7, \$s3	- Z
sub \$s7, \$s7, \$s3	- Z

Exercice 6 : Encodage en assembleur MIPS

A l'aide du Tableau 3 et du Tableau 4 des codages des instructions MIPS, codez les instructions suivantes :

add \$s5, \$s6, \$s7	0	6	7	5	0	32
and \$s6, \$s2, \$s5	0	2	5	6	0	36
lw \$s2, 50(\$s4)	35	4	2		50	

Exercice 7 : Commentaire du programme en assembleur MIPS

Commentez le programme suivant et indiquez ce qu'il fait.

Soit A un vecteur de dimension N = 10. L'adresse se trouve dans le registre \$s5.

andi \$s3, \$s3, 0	On met \$s3 à 0	\$s3 = 0
andi \$s1, \$s1, 0	On met \$s1 à 0	\$s1 = 0
addi \$s1, \$s1, 1	On rajoute 1 à \$s1	\$s1 = 1
andi \$s11, \$s11, 0	On met \$s11 à 0	\$s11 = 0
andi \$s2, \$s2, 0	On met \$s2 à 0	\$s2 = 0
addi \$s2, \$s2, 10	On ajoute 10 à \$s2	\$s2 = 0
Loop:		
lw \$s8, 0(\$s5)	Charger la données en \$s5 de la mém dans \$s8	\$s8 = mem[\$s5+0]
add \$s11, \$s11, \$s8	On ajoute \$s8 à \$s11	\$s11 += \$s8
addi \$s5, \$s5, 4	Ajoute 4 à \$s5 : on se déplace de 4 octets (1elt dans A?)	\$s5 += 4
sub \$s2, \$s2, \$s1	On soustrait \$s1 à \$s2	\$s2 -= \$s1
bne \$s2, \$s3, Loop	Si \$s2 != \$s3 : repart à Loop	

Concrètement, comme \$s2 part de 10 avant la boucle, et que \$s1 = 1 et \$s3 = 0, on va décrémenter \$s2 de \$s1 (ici 1) à chaque passage de boucle, tant que \$s2 != \$s3.

On va ici parcourir l'ensemble de A et ajouter ses elts ensemble (\$s11 += \$s8 avec \$s8 qui parcourt le tableau)

Exercice 8 : Programmation en assembleur MIPS (somme d'un tableau)

Ecrivez un programme en assembleur qui calcule la somme des éléments pairs dans un tableau A de dimension N = 10. L'adresse de A se trouve dans le registre \$s5

On a \$s5 qui est l'adresse de A

andi \$s1, \$s1, 0	\$s1 sera le compteur d'itérations
andi \$s3, \$s3, 0	\$s3 sera le résultat
Loop:	
lw \$s2, 0(\$s5)	On stocke dans \$s2 la donnée qui est à l'endroit \$s5
div \$s2, 2	On divise la donnée par 2
mfhi \$s4	On met dans \$s4 le reste de la div par 2 (\$s2 mod 2 dans notre cas)
bne \$s4, 0, NotPair	Si le modulo vaut pas 0 (ie pas pair) : on n'additionne pas
add \$s3, \$s3, \$s2	On ajoute la donnée actuelle au résultat
NotPair:	
addi \$s5, \$s5, 4	On met l'adresse de la valeur suivante dans \$s5
addi \$s1, \$s1, 1	On incrémente le compteur
bne \$s1, 10, Loop	

Tableau 2 Jeu d'instructions du MIPS

Category	Instruction	Example	Meaning	Comment
Arithmetic	Add	add \$s1,\$s2,\$s3	\$s1= \$s2+\$s3	Three operands ;overflow detected
	Subtract	sub \$s1,\$s2,\$s3	\$s1= \$s2-\$s3	Three operands ;overflow detected
	Add immediate	addi \$s1,\$s2,100	\$s1= \$s2+100	+constant; overflow undetected
	subtract unsigned	subu \$s1,\$s2,\$s3	\$s1= \$s2-\$s3	Three operands ;overflow undetected
	add immediate unsigned	addiu \$s1,\$s2,100	\$s1= \$s2+\$s3	+constant; overflow undetected
	move from coprocessor register	mfc0 \$s1,\$epc	\$s1=\$epc	Used to copy exception PC plus other special registers
	Multiply	mult \$s2,\$s3	Hi, Lo=\$s2x \$s3	64-bits signed product in Hi, Lo
	multiply unsigned	multu \$s2,\$s3	Hi, Lo=\$s2x \$s3	64-bits unsigned product in Hi, Lo
	Divide	div \$s2,\$s3	Lo=\$s2 / \$s3 Hi=\$s2 mod \$s3	Lo = quotient, Hi = remainder
	divide unsigned	divu \$s2,\$s3	Lo=\$s2 / \$s3 Hi=\$s2 mod \$s3	Unsigned quotient and remainder
Logical	move from Hi	mfhi \$s1	\$s1=Hi	Used to get copy of Hi
	move from Lo	mflo \$s1	\$s1=Lo	Used to get copy of Lo
	And	and \$s1,\$s2,\$s3	\$s1= \$s2 & \$s3	Three register. operands ; logical AND
	Or	or \$s1,\$s2,\$s3	\$s1= \$s2 \$s3	Three register. operands ; logical OR
	and immediate	andi \$s1,\$s2,100	\$s1= \$s2 & 100	Logical AND reg, constant
	or immediate	ori \$s1,\$s2,100	\$s1= \$s2 100	Logical OR reg, constant
Data transfer	shift left logical	sll \$s1,\$s2,10	\$s1= \$s2 << 10	Shift left by constant
	shift right logical	srl \$s1,\$s2,10	\$s1= \$s2 >> 10	Shift right by constant
	load word	lw \$s1,100(\$s2)	\$s1=Memory[\$s2+100]	Word from memory to register
	store word	sw \$s1,100(\$s2)	Memory[\$s2+100] =\$s1	Word from register to memory
	load byte unsigned	lbu \$s1,100(\$s2)	\$s1=Memory[\$s2+100]	byte from memory to register

	store byte	sb \$s1,\$100(\$s2)	Memory[\$s2+100] = \$s1	byte from register to memory
	load upper immediate	lui \$s1,100	\$s1=100*2 ¹⁶	Load constant in upper 16 bits
Conditional branch	branch on equal	beq \$s1,\$s2,25	If (\$s1==\$s2) go to PC+4+100	Equal test; PC-relative branch
	branch on not equal	bne \$s1,\$s2,25	If (\$s1 != \$s2) go to PC+4+100	Not Equal test; PC-relative
	set on less than	slt \$s1,\$s2,\$s3	If (\$s2<\$s3) \$s1=1 ; else \$s1=0	Compare less than; two's complement
	set less than immediate	slti \$s1,\$s2,100	If (\$s2<100) \$s1=1 ; else \$s1=0	Compare < constant; two's complement
	set less than unsigned	sltu \$s1,\$s2,\$s3	If (\$s2<\$s3) \$s1=1 ; else \$s1=0	Compare less than; natural numbers
	set less than immediate unsigned	sltiu \$s1,\$s2,100	If (\$s2<100) \$s1=1 ; else \$s1=0	Compare < constant; natural numbers
Unconditional jump	Jump	j 2500	Go to 10000	Jump to target address
	jump register	jr \$ra	Go to \$ra	For switch, procedure return
	jump and link	jal 2500	\$ra = PC+4; go to 10000	For procedure all

Tableau 3 Tableau 3 Codage des instructions assemblleur du MIPS

Name	Format	Example						comments
		6 bits	5 bits	5 bits	5 bits	5 bits	6 bits	
add	R	6 bits	5 bits	5 bits	5 bits	5 bits	6 bits	
sub	R	0	2	3	1	0	34	sub \$s1,\$s2,\$s3
addi	I	8	2	1	100			addi \$s1,\$s2,100
addu	R	0	2	3	1	0	33	addu \$s1,\$s2,100
subu	R	0	2	3	1	0	35	subu \$s1,\$s2,\$s3
addiu	I	9	2	1	100			addiu \$s1,\$s2,100
mfc0	R	16	0	1	14	0	0	mfc0 \$s1,\$epc
mult	R	0	2	3	0	0	24	mult \$s2,\$s3
multu	R	0	2	3	0	0	25	multu \$s2,\$s3
div	R	0	2	3	0	0	26	div \$s2,\$s3
divu	R	0	2	3	0	0	27	divu \$s2,\$s3
mfhi	R	0	0	0	1	0	16	mfhi \$s1
mflo	R	0	0	0	1	0	18	mflo \$s1
and	R	0	2	3	1	0	36	and \$s1,\$s2,\$s3
or	R	0	2	3	1	0	37	or \$s1,\$s2,\$s3
andi	I	12	2	1	100			andi \$s1,\$s2,100
ori	I	13	2	1	100			ori \$s1,\$s2,100
sll	R	0	0	2	1	10	0	sll \$s1,\$s2,10
srl	R	0	0	2	1	10	2	srl \$s1,\$s2,10
lw	I	35	2	1	100			lw s1,100(\$s2)
sw	I	43	2	1	100			sw s1,100(\$s2)
lui	I	15	0	1	100			lui s1,100
beq	I	4	1	2	25			beq \$s1,\$s2,25
bne	I	5	1	2	25			bne \$s1,\$s2,25

slt	R	0	2	3	1	0	42	slt	\$s1,\$s2,\$s3
slti	I	10	2	1	100				slti \$s1,\$s2,100
sltu	R	0	2	3	1	0	43	sltu	\$s1,\$s2,\$s3
sltiu	I	11	2	1	100				sltiu \$s1,\$s2,\$s3
j	J	2	2500				j 10000		
Jr	R	0	31	0	0	0	8	jr	\$31
Jal	J	3	2500				jal 10000		

Tableau 4 Formats des instructions assemebleur du MIPS

name		Fields						Comments
Field size		6 bits	5 bits	5 bits	5 bits	5 bits	6 bits	All MIPS instructions 32 bits
R-format		Op	rs	rt	Rd	Shamt	Funct	Arithmetic instruction format
I-format		Op	rs	rt	Address/immediate			Transfer, branch, imm, format
J-format		Op	Target address					

TD/TP2 : Programmation assembleur MIPS - profiling d'applications et ISS (instruction set simulator)

Rappel sur les conventions de l'assembleur MIPS pour les registres :

Tableau 5 File de registres MIPS

Name	Register number	Usage	Preserved on call
\$zero	0	Valeur constante 0	n.a.
\$v0-\$v1	2-3	Valeurs pour résultats et évaluation d'expression	no
\$a0-\$a3	4-7	Arguments	yes
\$t0-\$t7	8-15	Variables temporaires	no
\$s0-\$s7	16-23	Sauvegarde	yes
\$t8-\$t9	24-25	Variables temporaires	no
\$gp	28	Pointeur global (global pointer)	yes
\$sp	29	Pointeur de pile (stack pointer)	Yes
\$fp	30	Pointeur de frame (frame pointer)	Yes
\$ra	31	Adresse de retour (return address)	Yes

Naivement :

```

andi $t0, $t0, 0
beq $s5, $t0, Case0
addi $t0, $t0, 1
beq $s5, $t0, Case1
addi $t0, $t0, 1
beq $s5, $t0, Case2
addi $t0, $t0, 1
beq $s5, $t0, Case3
j End
Case0:
add $s0, $s3, $s4
j End
...
Case3:
sub $s0, $s3, $s4
End:
...

```

Exercice 1 : Switch statement

Veuillez écrire en assembleur l'équivalent du code C suivant :

```

switch(k) {
    case 0: f = i + j ; break /* k = 0 */
    case 1: f = g + h ; break /* k = 1 */
    case 2: f = g - h ; break /* k = 2 */
    case 3: f = i - j ; break /* k = 3 */
}

```

Faire la méthode optimisée :

utiliser le fait que dans chaque case il y a 2 instructions : on peut sauter avant les case de Case0 + k * offset

Q1 : Proposez 2 solutions dont une version où le temps d'exécution est indépendant du nombre de cas. On supposera que les variables f, g, h, i, j et k se trouvent dans les registres \$s0-\$s5 respectivement.

```

andi $s1, $s1, 0          // sum = 0
andi $s2, $s2, 0          // i = 0
// Bloc pas nécessaire au vu de la remise à zéro pour les boucles à
// chaque incrémentation
/* andi $s3, $s3, 0          // j = 0
addi $s3, $s3, 500        // j = j + 500 = 500
andi $s4, $s4, 0          // k = 0
addi $s5, $zero, 1000     // imax
andi $s7, $zero, 300      // kmax

```

Exercice 2 : Boucles

Veuillez écrire en assembleur l'équivalent du code C suivant :

```

sum = 0 ;
for(i= 0 ; i < 1000 ; i++) {
    for(j= 500 ; j > 0 ; j--) {
        for(k = 0 ; k < 300; k = k + 10) {
            sum = sum + (i + j + k);
        }
    }
}

```

```

Loop1:
andi $s3, $s3, 0          // On remet j à sa valeur initiale
addi $s3, $s3, 500
Loop2:
andi $s4, $s4, 0          // On remet k à sa valeur initiale
Loop3:
add $s1, $s1, $s2          // sum += i
add $s1, $s1, $s3          // sum += j
add $s1, $s1, $s4          // sum += k
addi $s4, $s4, 10          // k += 10
bne $s4, $s7, Loop3        // if(k!=kmax) {aller à Loop3}
subi $s3, $s3, 1
bne $s3, $zero, Loop2      // if(j!=0) {aller à Loop2}
addi $s2, $s2, 1
bne $s2, $s5, Loop1        // if(i!=imax) {aller à Loop1}
// i++

```

On supposera que les variables sum, i, j et k se trouvent dans les registres \$s1-\$s4 respectivement.

Exercice 3 : Appels de fonctions

Veuillez écrire en assembleur l'équivalent du code C suivant :

```

int leaf(int g, int h, int i, int j)
{
    int f;
    f = (g + h) - (i + j);
    return f;
}

```

On supposera que les variables g, h, i et j sont transmises par les registres \$a0, \$a1, \$a2, \$a3 lors de l'appel de fonction, et que f correspond à \$s0. Lors de l'exécution d'un appel de fonction, il est

nécessaire de sauvegarder dans une pile en mémoire le contenu des registres utilisés. Pour rappel, le registre \$sp donne l'adresse de la pile.

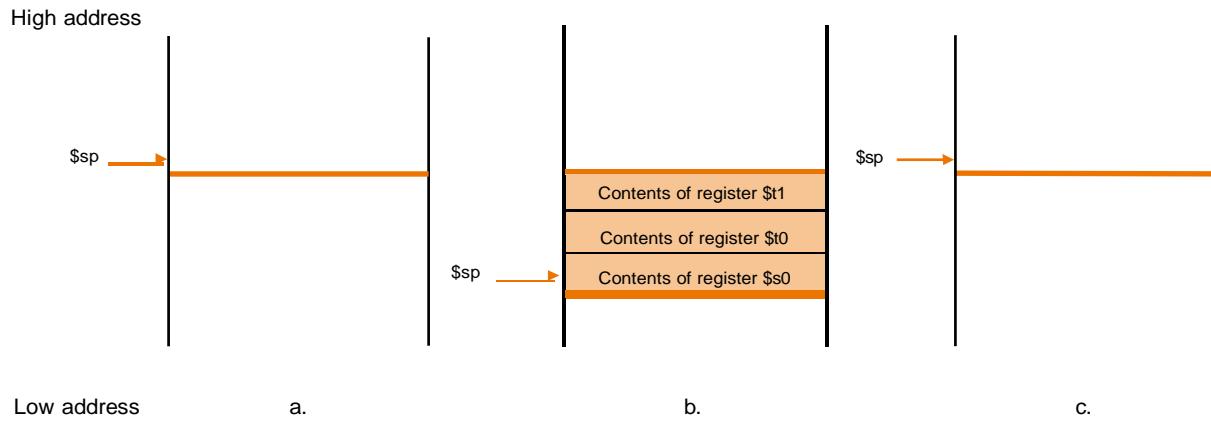


Figure 1 Evolution de la pile lors d'un appel de fonction

Q1 : Pourquoi les appels de fonctions affectent les performances des programmes ?

Q2 : Pourquoi la récursivité en programmation affecte les performances ?

Exercice 4 : Appels de fonctions

Veuillez écrire en assembleur l'équivalent du code C suivant :

```
void swap(int v[], int k)
{
    int tmp;
    tmp = v[k];
    v[k] = v[k+1];
    v[k+1] = tmp;
}
```

Exercice 5 : Profiling d'applications (% d'instructions par catégorie) par simulation sur ISS (instruction set simulator)

Nous allons maintenant nous intéresser au profiling d'une application tirée de l'inférence de réseaux de neurones convolutif (CNN). Ceux-ci utilisent de nombreuses opérations de convolution afin d'appliquer des filtres sur les données et extraire des informations importantes pour décrire ces données. Plusieurs déclinaisons sont proposées pour l'opération de convolution :

1. La convolution d'une matrice d'entiers 320x320 représentant une image avec un filtre 4x4.
2. La convolution d'une matrice de flottants 320x320 représentant une image normalisée avec un filtre 4x4.
3. La convolution d'une matrice d'entiers 320x320 représentant une image avec un filtre 4x4 avec un déroulage de boucle permettant une première optimisation des instructions.

Q1 : Générez le pourcentage de chaque classe d'instructions utilisées par ces programmes, puis remplissez le tableau suivant

Tableau 6 Pourcentage de chaque classe d'instructions

Classe d'instructions	P1 (%)	P2 (%)	P3 (%)
Instructions de lecture (Load)	12.30	13.11	27.34
Instructions d'écriture (Store)	0.40	0.42	0.88
Instructions de branchement inconditionnel (Uncond branch)	0.00	0.00	0.00
Instructions de branchement conditionnel (Cond branch)	8.08	8.61	2.57
Instructions de calcul entier (Int computation)	79.22	64.75	41.88
Instructions de calcul flottant (Fp computation)	0.00	13.11	27.33
Nombre total d'instructions exécutées	26137287	24529449	11764854

Le compilateur produisant un binaire pour le simulateur SimpleScalar est dans notre cas utilisé de la manière suivante (se reporter à l'annexe 1) :

```
sslittle-na-sstrix-gcc <source> -o <exe>
```

Dans le cas de SSCA2, modifiez puis exécutez Make dans le répertoire afin de produire un exécutable compréhensible par SimpleScalar (se reporter à l'annexe 2 : Applications).

Vous obtiendrez les pourcentages par la commande suivante¹:

```
sim-profile -iclass <exe>
```

Q2 : Quelle catégorie d'instructions nécessiterait une amélioration de performances ?

Les instructions de calcul sur les entiers car elles représentent la majorité des instructions exécutées

¹ Les pourcentages sont données sous la colonne pdf

TD/TP3 : Processeur pipeline – superscalaire

Exercice 1 : Pipeline

Identifier toutes les dépendances de données dans le code suivant. Quelles dépendances sont des aléas de données qui seront résolus par *forwarding* ?

Il y a une dépendance de données entre la première instruction, qui stocke qqchose dans \$2, et la deuxième, qui utilise \$2 comme opérande.

De même il y a une dépendance de données entre la première instruction et la troisième, car la troisième utilise \$2 comme opérande. De même entre les instructions 1 et 4 ainsi que 2 et 4.

add \$4,\$2,\$5	IF1	ID1	EX1 - MEM1- WB1
	IF2	ID2	- EX2 MEM2- WB2
sw \$5, 100(\$2)		IF3 ID3	- EX3 MEM3 WB3

add \$3,\$2,\$4	IF4	ID4	- EX4 MEM4 WB4
-----------------	-----	-----	------------------

Le forwarding consiste à passer directement la sortie de la partie EX d'une instruction à l'entrée de la partie EX sans passer par l'écriture dans les registres.

La dépendance entre 1 et 4 ne pose pas de problème car EX4 se fait après WB1 donc le registre \$2 est déjà bon au moment de EX4.

Dans le schéma ci-dessus, on voit que trois dépendances peuvent être résolues par forwarding car la forwarding unit (de la figure 2) peut prendre des données du stage EX et du stage MEM.

Vous devez vous appuyer dans votre analyse sur la Figure 2 décrivant le pipeline du processeur.

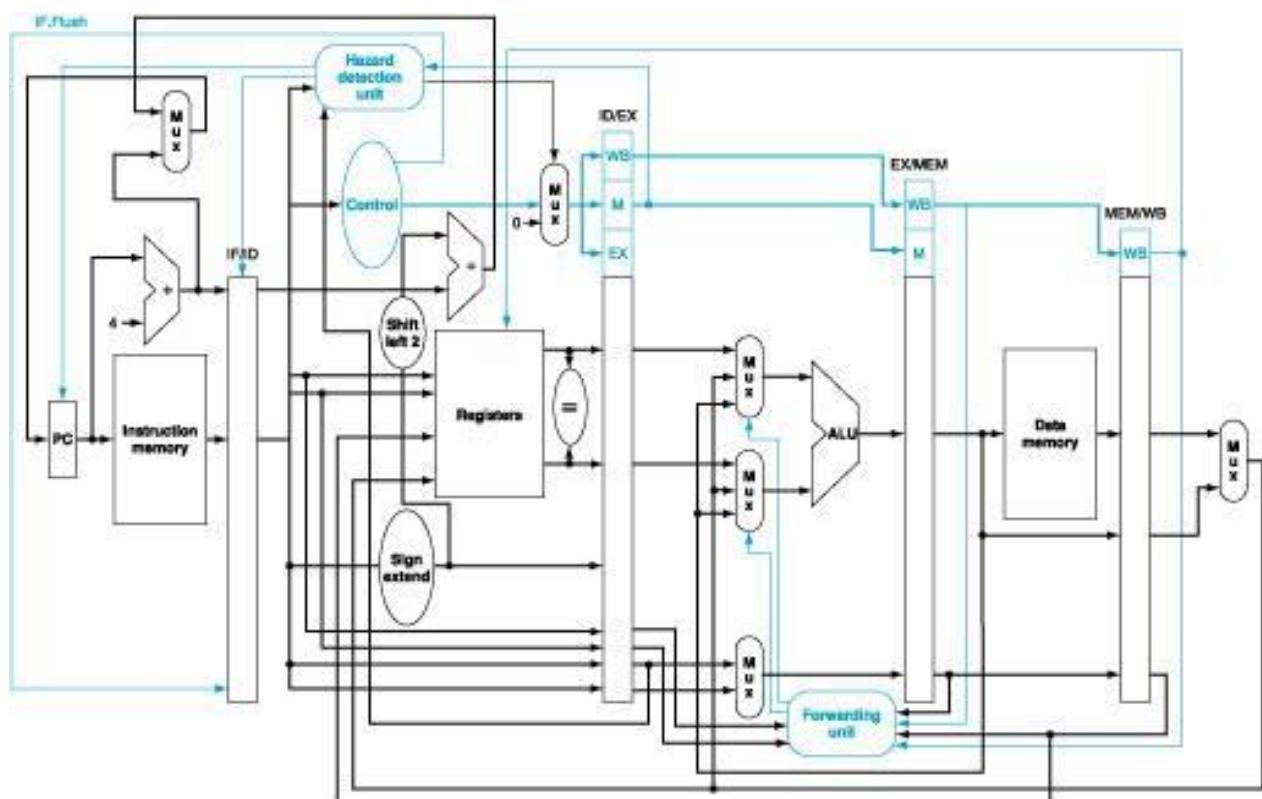


Figure 2 Processeur RISC pipeline 5 étage

Exercice 2 : Pipeline - Data Forwarding

Nous souhaitons modifier le pipeline du processeur pour lui ajouter 2 nouvelles unités fonctionnelles :

1. Une unité de multiplication
2. Une unité racine carrée

Modifiez le chemin de données du processeur et l'unité de data forwarding pour prendre en compte ces deux nouvelles unités fonctionnelles.

Vous pouvez vous appuyer dans votre analyse sur la Figure 3 décrivant le data forwarding au sein du pipeline du processeur.

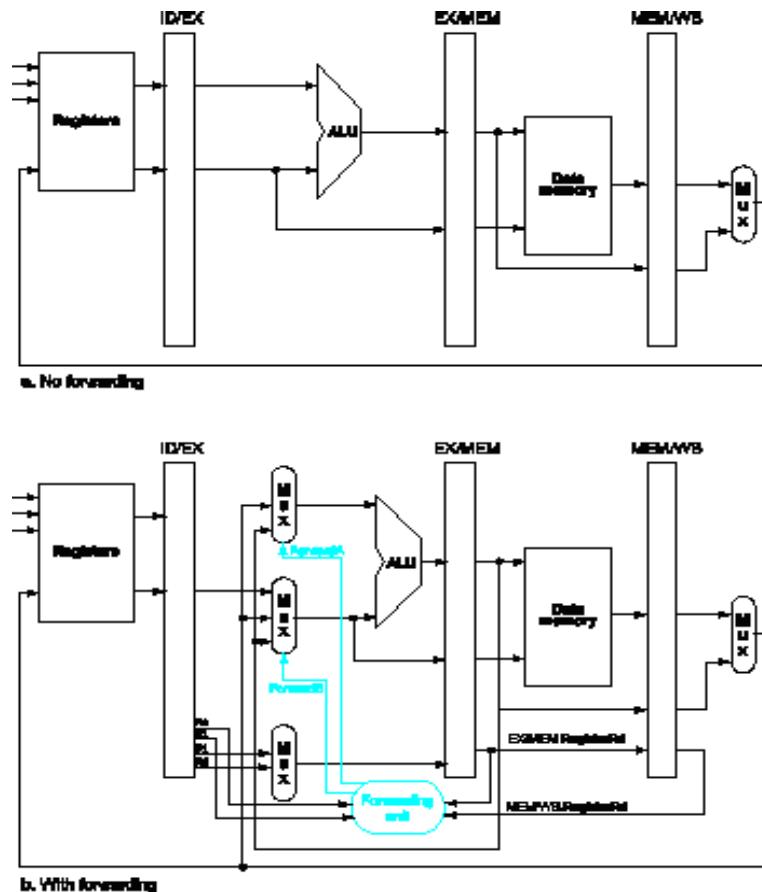


Figure 3 Data forwarding a) No forwarding b) With forwarding

Exercice 3 : Impact du nombre d'unités fonctionnelles

SimpleScalar s'exécute avec une configuration par défaut d'unités fonctionnelles. Il est possible de spécifier le nombre et le type d'unités fonctionnelles avec les options :

-res : ialu	M	nombre total d'ALUs (unité arithmétique et logique) entière
-res : imult	M	nombre total de multiplieurs/diviseurs entiers
-res : fpalu	M	nombre total d'ALUs flottantes (données de type float)
-res : fpmult	M	nombre total de multiplieurs/diviseurs flottants (données de type float)

Ce nombre total M peut varier de 0 à M où M dans les processeurs actuels ne dépasse pas 8, de manière générale.

Exemple de commande correspondant à une configuration avec 4 ALUs, 1 multiplieur, 4 ALUs flottantes, 1 multiplieur flottant :

```
sim-outorder -fetch:ifqsize 4 -decode:width 4 -issue:width 4 -issue:inorder false -commit:width 4
-ruu:size 16 -lsq:size 8 -res:ialu 4 -res:imult 1 -res:mempport 2 -res:fpalu 4 -res:fpmult 1 program.ss
```

Exemple de commande correspondant à une configuration avec 8 ALUs, 4 multiplieurs, 1 ALU flottante, 1 multiplieur flottant :

```
sim-outorder -fetch:ifqsize 4 -decode:width 4 -issue:width 4 -issue:inorder false -commit:width 4
-ruu:size 16 -lsq:size 8 -res:ialu 8 -res:imult 4 -res:mempport 2 -res:fpalu 1 -res:fpmult 1 program.ss
```

Du point de vue applicatif, l'étude sera menée sur l'algorithme PageRank, développé par Google comme métrique mesurant l'importance d'une page web [1]. Il s'avère que cette métrique peut également être utilisée dans d'autres types de réseaux (e.g. sociaux) afin de caractériser l'importance relative d'un sommet (se reporter à l'Annexe 2 : Applications).

A l'étape initiale, chaque sommet se voit attribuer un rang égal. Chaque sommet recalcule son rang en fonction du rang de ses voisins et de ses degrés entrants/sortants. On considère que l'algorithme a convergé lorsque la variation de rang, d'une itération à l'autre, est inférieur à un seuil (voir [1] pour le détail).

Q1 : Analysez le code de l'algorithme PageRank en faisant varier la taille du graphe d'entrée (min, med, max) et en faisant varier le nombre d'unités fonctionnelles M de 1 à 8 (1, 2, 4, 8). (Voir annexe « Applications »)

N_UF	SIZE		Min		Med		Max	
	Nb_cycles	CPI	Nb_cycles		CPI		Nb_cycles	CPI
			Min	Med	Max	Min	Med	Max
1	178261	1.8265	332562	1.6873	2113273	1.5759		
2	166771	1.7087	311790	1.5819	1964803	1.4652		
4	162887	1.6689	304902	1.5470	1915729	1.4286		
8	162887	1.6689	304902	1.5470	1915729	1.4286		

Q2: Tracez 2 figures indiquant le nombre de cycles et le CPI associés en fonction de la taille du problème traité ($N=\{\text{min, med, max}\}$) et des unités fonctionnelles. Quelle est votre analyse ?

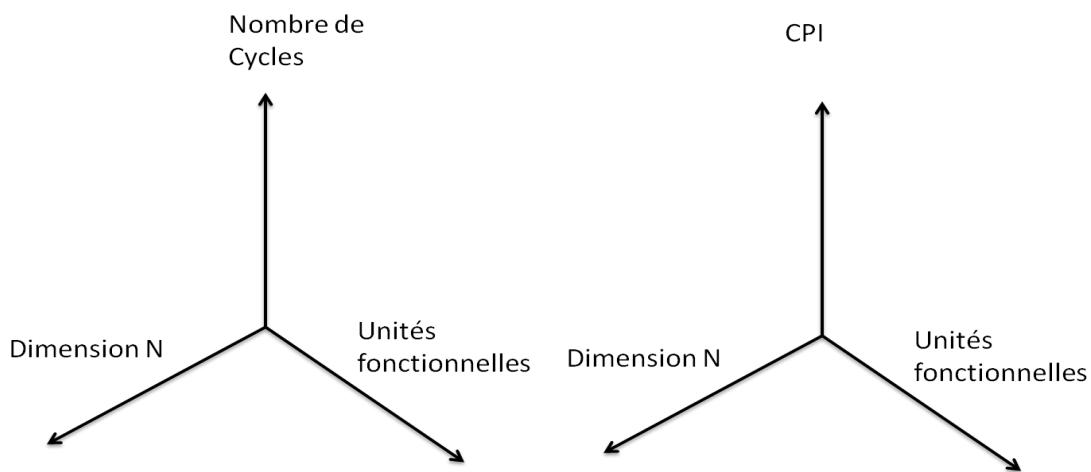


Figure 4 a) Nombre de cycles vs N vs Unités fonctionnelles b) CPI vs N vs Unités fonctionnelles

Exercice 4 : Exécution dans l'ordre (in-order) VS exécution dans le désordre (out-of-order)

Dans un processeur superscalaire à ré-ordonnancement dynamique des instructions, l'exécution des instructions peut s'effectuer dans le désordre dans l'objectif d'éviter les contraintes artificielles de la séquentialité.

L'exécution d'un programme tel que généré sans optimisations par un compilateur représente l'ordre sémantique normal du programme. Pourtant l'ordre d'exécution des instructions peut être modifié tout en préservant la sémantique. Cette exécution est appelée **out-of-order exécution**.

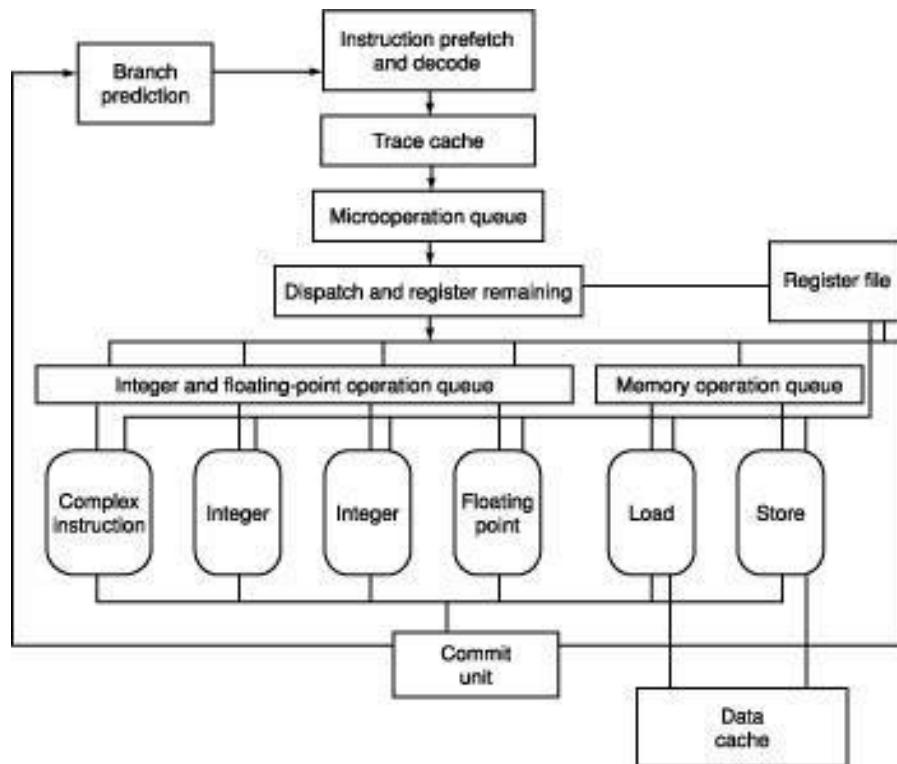


Figure 5 Pipeline d'exécution dans le désordre (out-of-order)

Le simulateur **sim-outorder** permet d'exécuter les instructions dans l'ordre ou le désordre (*out-of-order exécution*). Les deux commandes suivantes permettent les 2 possibilités :

- Exécution dans l'ordre : sim-outorder -issue:inorder true program.ss
- Exécution dans le désordre : sim-outorder -issue:inorder false program.ss

Par défaut le simulateur, ayant un modèle de processeur superscalaire avec ré-ordonnancement dynamique, exécute suivant un mode *out-of-order exécution*.

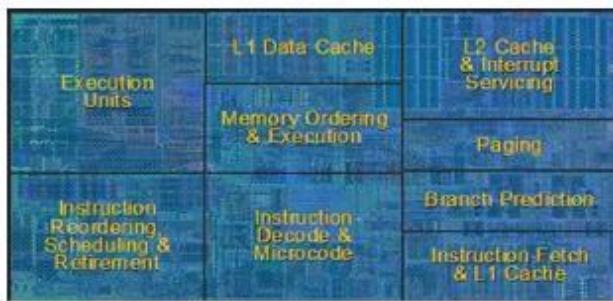
Q1 : *Evaluez l'impact de l'exécution dans l'ordre par rapport à l'exécution dans le désordre pour l'algorithme PageRank (CPI, nombre de cycles).*

N_UF	SIZE				Med				Max			
	Min		CPI		Nb_cycles		CPI		Nb_cycles		CPI	
	In-order	Out-order	In-order	Out-order	In-order	Out-order	In-order	Out-order	In-order	Out-order	In-order	Out-order
1	178261	142420	1.8265	1.4592	332562	256531	1.6873	1.3015	2113273	1603764	1.5759	1.1959
2	166771	116770	1.7087	1.1964	311790	201909	1.5819	1.0244	1964803	1239786	1.4652	0.9245
4	162887	111861	1.6689	1.1461	304902	192235	1.5470	0.9753	1915729	1172626	1.4286	0.8744
8	162887	111861	1.6689	1.1461	304902	192235	1.5470	0.9753	1915729	1172626	1.4286	0.8744

TD/TP4 : Microprocesseur superscalaire/mémoires caches - Analyse de configurations d'architectures de microprocesseurs

Exercice 1 : Prédiction de branchement

La prédiction de branchement permet aux processeurs d'exécuter un flot d'instructions sans pénalité de blocage dû à l'attente de l'évaluation de la condition de branchement. Tous les microprocesseurs haute-performance incluent une unité de prédiction de branchement. La Figure 6 montre la surface prise par l'unité de prédiction de branchement dans un processeur multi cœur Intel.



Core floorplan with major units highlighted.

Figure 6 Floorplan d'un cœur de processeur Intel

Nous souhaitons dans cet exercice évaluer l'impact de différents mécanismes de prédiction de branchement sur le CPI et le nombre de cycles pour 2 applications :

1. La fonction de hachage SHA-1 ([7] [9]). Voir l'annexe « Applications ».
2. L'algorithme de calcul de la centralité d'intermédiairité (Betweenness Centrality Score / BCS) dans la suite SSCA2 [TP2.1], se référer à l'annexe « Applications ».

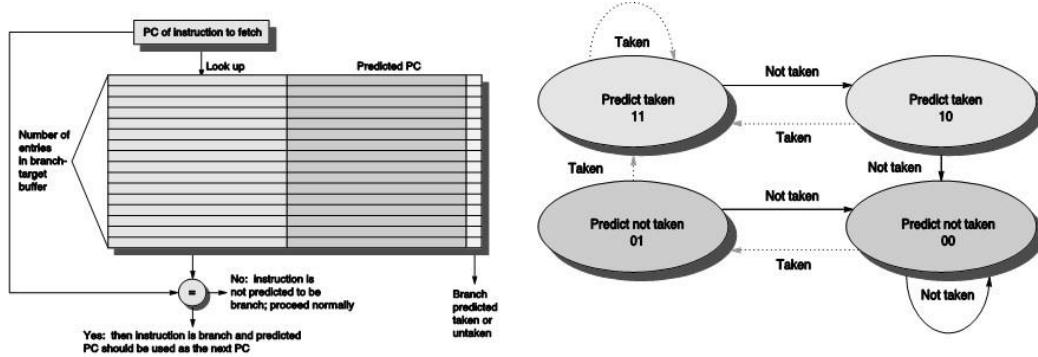
Les mécanismes de prédiction que nous souhaitons comparer sont les suivants :

- **nottaken** : ce mécanisme de prédiction de branchement statique considère toujours que le branchement n'est pas pris
- **taken** : ce mécanisme de prédiction de branchement statique considère toujours que le branchement est pris
- **perfect** : ce prédicteur « virtuel » représente la prédiction parfaite
- **bimod** : le prédicteur de branchement bimodal utilise un BTB (Branch Target Buffer) avec compteurs à 2 bits
- **2lev** : prédicteur de branchement adaptatif à 2-niveaux

Vous pouvez spécifier en utilisant le simulateur SimpleScalar le mécanisme de prédiction de branchement de votre choix en utilisant la commande suivante :

```
sim-outorder -bpred <type> <prog>.ss [options]
```

La documentation de SimpleScalar (voir l'annexe en fin de document) précise les détails pour les différents mécanismes de prédiction de branchement. La Figure 7 et la Figure 8 décrivent 2 types de prédicteurs de branchement, et la Figure 9 décrit les différents paramètres en entrée pour le prédicteur de branchement de SimpleScalar.



© 2003 Elsevier Science (USA). All rights reserved.

© 2003 Elsevier Science (USA). All rights reserved.

Figure 7 Le prédicteur de branchement bimodal

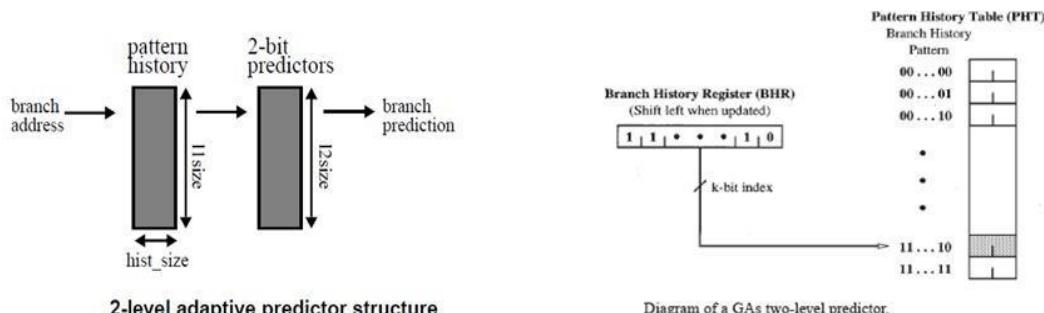


Figure 8 Le prédicteur de branchement adaptatif à 2-niveaux

predictor	l1_size	hist_size	l2_size	xor
GAg	1	W	2^W	0
GAp	1	W	$>2^W$	0
PAg	N	W	2^W	0
PAp	N	W	2^{N+W}	0
gshare	1	W	2^W	1

Branch predictor parameters

Figure 9 Paramètres du prédicteur de branchement

Q1 : Etudier l'impact des différents prédicteurs de branchement sur le CPI et le nombre de Cycles pour le programme de votre choix

Exercice 2 : Impact de la fenêtre d'instructions RUU

Le modèle d'exécution superscalaire de SimpleScalar utilise un mécanisme de ré-ordonnancement basé sur une partie centrale : la RUU (Register Update Unit).

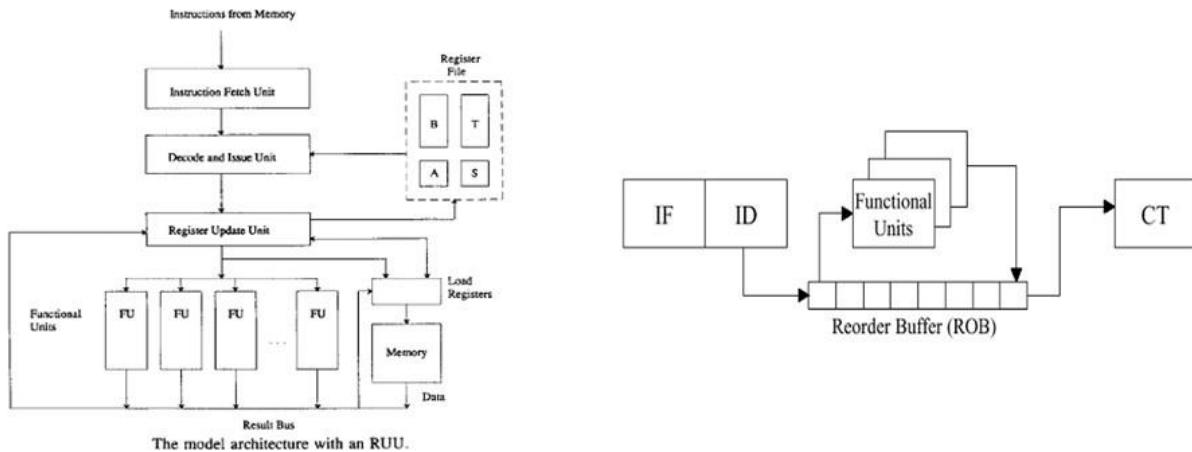


Figure 10 Register Update Unit (RUU)

L'augmentation de la taille de la RUU permet à priori de considérer davantage d'instructions potentielles pour l'exécution. Nous souhaitons analyser l'impact de cette taille sur le CPI.

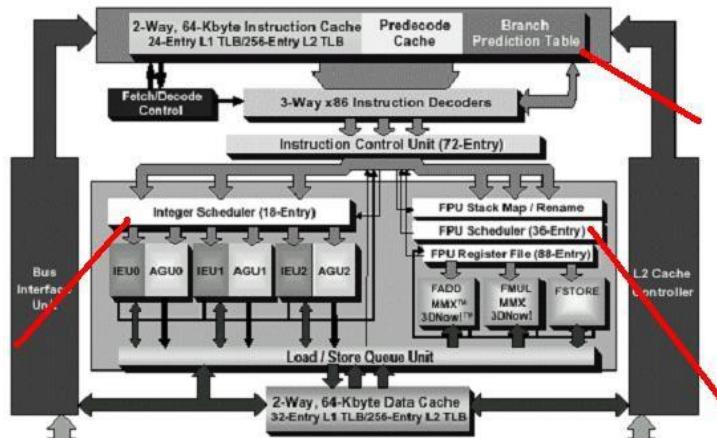


Figure 11 AMD Athlon Processor Block Diagram

Q1 : Faites varier la taille de la RUU de 16 à 128 et évaluez l'impact sur le CPI et le nombre de cycles sur une application de votre choix (SHA-1, SSAC2,...).

Exercice 3 : Mémoires caches - Evaluation des performances de différentes configurations de mémoires caches (instructions et données) pour 4 algorithmes de multiplication de matrices.

De nombreuses applications informatiques dans différents domaines font appel à des opérations sur des matrices, et en particulier la multiplication de matrices. Cette opération classique peut être répétée de nombreuses fois au cours de l'exécution de ces applications et il est donc primordial que ses performances soient optimisées. La multiplication de matrices sur des matrices de dimensions importantes est une opération dont la performance en temps d'exécution dépend beaucoup des performances de la hiérarchie mémoire, et notamment l'organisation des caches du microprocesseur sur lequel elle s'exécute. Le taux de défauts de caches (**miss rate**), qui est le rapport entre le nombre d'accès à un cache qui se traduisent par un défaut de cache (**cache miss**) sur le nombre total d'accès au cache, est le paramètre principal pour évaluer cette performance. Nous considérons ici des microprocesseurs ayant des caches d'instructions et de données séparés. De ce fait, le miss rate du cache d'instructions et du cache de données méritent une analyse.

Un simulateur de cache, comme **sim-cache (Annexe 1)**, permet d'effectuer une évaluation du miss rate pour une configuration de caches particulière et pour un programme en entrée. Lorsque l'on souhaite évaluer plusieurs configurations de caches il est alors nécessaire d'effectuer autant de simulations. Ce processus se répète pour le nombre de programmes que l'on considère en entrée.

Travail demandé

Nous considérons les 2 organisations de caches décrites dans le Tableau 7. On supposera que l'algorithme de remplacement est LRU pour toutes les configurations.

Tableau 7 Configurations de caches pour 2 processeurs

Configuration	Instruction cache	Data cache	L2 cache	Block size (bytes)
C1	4KB direct-mapped	4KB direct-mapped	32KB direct-mapped	32
C2	4KB direct-mapped	4KB 2-way set-asso	32KB 4-way set-asso	32

Les binaires pour les 4 algorithmes de matrices se trouvent dans :

`/usr/ensta/pack/simplescalar-2.0/simplescalar-4.0/mase/matrix/<algo>.ss`

Q1 : Pour chacune des 2 configurations de mémoires cache, complétez le Tableau 8. Pour cela, vous devez déterminer les paramètres d'entrée du simulateur de cache « sim_cache » de SimpleScalar.

Tableau 8 Paramètres de sim-cache pour chaque configuration

Configuration	IL1	DL1	UL2
C1			
C2			

Q2 : Complétez les tableaux 9, 10 et 11. Pour cela vous devez simuler à l'aide de sim-cache les différentes configurations et collecter les informations suivantes :

- Le taux de défauts dans le cache d'instructions il1 : **il1.miss_rate**
- Le taux de défauts dans le cache de données dl1 : **dl1.miss_rate**
- Le taux de défauts dans le cache unifié (L2) ul2 : **ul2.miss_rate**

Tableau 9 Instruction Cache (il1) Miss Rate

Programmes	<i>Configurations de caches</i>	
	C1	C2
P1 (normale)		
P2 (pointeur)		
P3 (tempo)		
P4 (unrol)		

Tableau 10 Data Cache (dl1) Miss Rate

Programmes	<i>Configurations de caches</i>	
	C1	C2
P1 (normale)		
P2 (pointeur)		
P3 (tempo)		

P4 (unrol)		
------------	--	--

Tableau 11 Unified Cache (ul2) Miss Rate

Programmes	<i>Configurations de caches</i>	
	C1	C2
P1 (normale)		
P2 (pointeur)		
P3 (tempo)		
P4 (unrol)		

Q3 : *Les 4 algorithmes de multiplication de matrices présentent-ils une bonne localité de références pour le code ? Pourquoi ?*

Exercice 4 : Mémoires caches - Evaluation des performances de différentes configurations de mémoires caches (instructions et données)

Description du problème

Un panorama détaillé de l'offre actuelle des composants microprocesseurs (8 bits, 16 bits, 32 bits et 64 bits) peut être consulté sur le site EDN (EDN 2014 Microprocessor Directory [1]). Il existe plus de 70 fabricants de microprocesseurs et de microcontrôleurs, chacun se positionnant soit dans le domaine généraliste soit dans un domaine spécifique. Par exemple, le marché des processeurs généralistes pour serveurs et desktops est dominé par Intel [2] et AMD [3], tandis que le marché des processeurs embarqués est dominé par ARM [4] et MIPS [5]. Au sein des processeurs embarqués, on trouve généralement une classification supplémentaire selon le domaine applicatif (automobile, image/vidéo, militaire/espace, télécommunications, etc.).

Cependant, chez les fabricants de ces deux grandes familles de processeurs (généralistes et embarqués), la tendance commune est à l'élargissement de la gamme de processeurs disponibles : processeurs très performants mais énergivores d'un côté, processeurs légèrement moins performants mais plus efficaces de l'autre. Cela rend les frontières entre ces deux mondes de plus en plus floues, mais cela dégage un objectif commun à tous les fabricants : la recherche de l'efficacité énergétique (ratio performances pures à consommation d'énergie donnée), en témoigne la nouvelle architecture **big.LITTLE** de ARM [6].

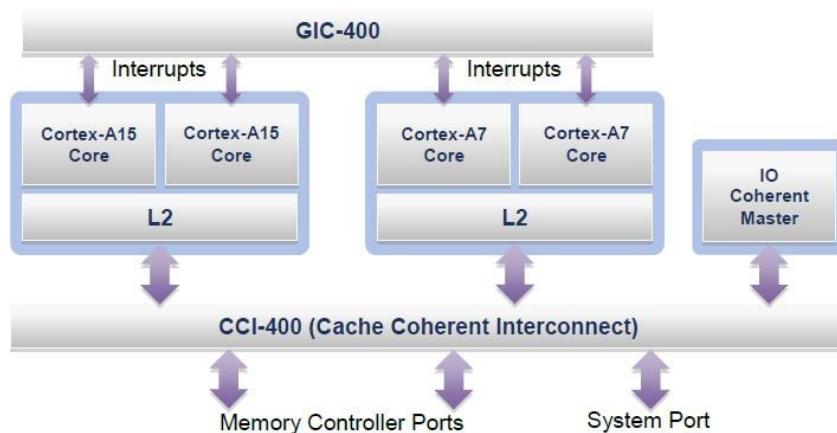


Figure 12 Une configuration typique de big.LITTLE, constituée de 2 clusters, avec 2 CPUs par cluster (Source : ARM)

Cette architecture intègre au sein du même processeur deux coeurs ARM embarqués : un **Cortex A15** (hautes performances, [4]) et un **Cortex A7** (haute efficacité énergétique, [4]). Ces deux coeurs étant entièrement compatibles au niveau du jeu d'instructions, l'architecture peut décider de reloger l'exécution sur l'un ou l'autre des coeurs en fonction des besoins en calcul de l'application. Ces deux coeurs fonctionnent donc de manière alternative (un cœur ON - un cœur OFF), afin de maximiser l'efficacité de l'architecture globale.

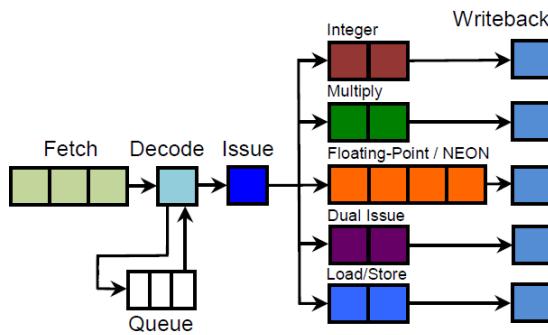


Figure 13 Pipeline du Cortex A7

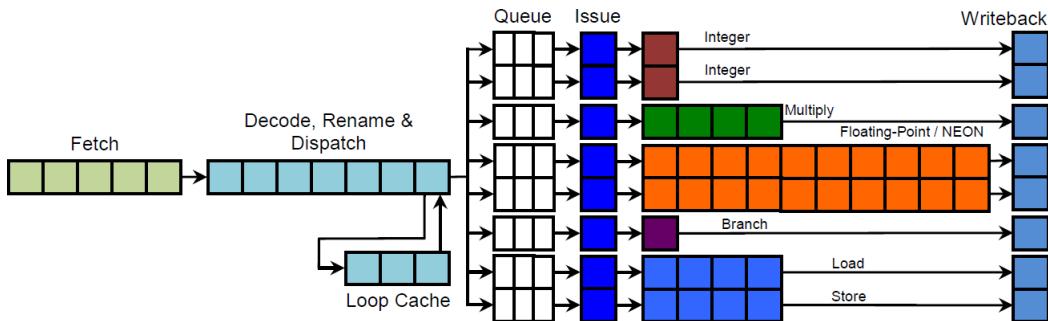


Figure 14 Pipeline du Cortex A15

Comme on a pu le voir, les critères exigés par chaque domaine applicatif (performances, énergie, surface) influencent les choix architecturaux. La microarchitecture d'un processeur spécifie : (1) le mode de traitement des instructions (pipeline, parallélisme d'instructions), (2) l'exécution dans l'ordre ou dans le désordre et enfin (3) le nombre et le type d'unités fonctionnelles (additionneurs, multiplicateurs, diviseurs, unités spécialisées, etc.). Il est possible d'identifier pour un programme donné la classe (le type) des instructions sollicitées et le pourcentage d'instructions exécutées issues de cette classe. Cette phase d'identification s'appelle le **profiling**, et a déjà été abordée dans les TD/TP précédents. Il est clair que si le profiling d'une application montre qu'il existe un pourcentage élevé d'utilisation d'une classe particulière, il est alors souhaitable, pour accroître les performances, d'augmenter le nombre d'unités fonctionnelles correspondant à ce type. A contrario, les classes d'instructions ayant un faible taux d'utilisation pourraient voir leur nombre d'unités associées réduites, voire éliminées.

Ce processus consiste à faire une **exploration manuelle/automatique** de la microarchitecture en modifiant les paramètres de configuration de l'architecture et à évaluer l'impact sur les performances et la surface. Néanmoins, ce processus s'applique plutôt à des processeurs en cours de conception. Dans le cas d'une offre existante, il s'agit plutôt d'estimer les performances potentielles en modélisant des processeurs existants.

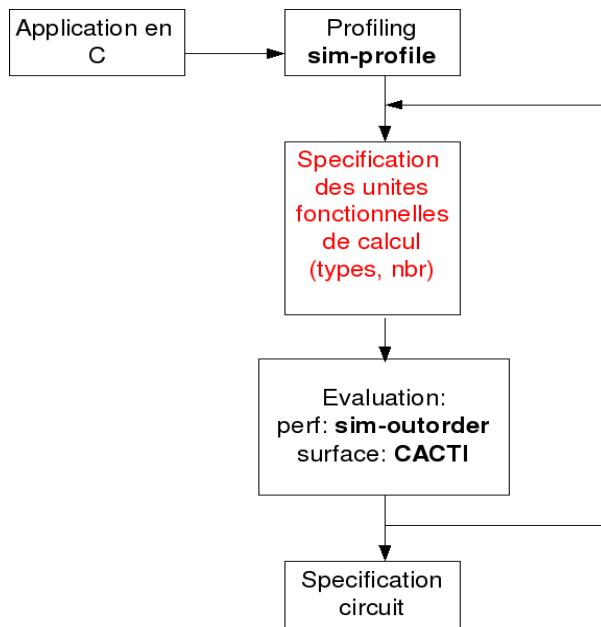


Figure 15 Flot de modification de la microarchitecture d'un microprocesseur

Le but de ce TD/TP est d'analyser les performances des 2 cœurs ARM décrits en introduction : **Cortex A7** et **Cortex A15**, sur des applications type traitement de graphes. Les configurations de ces cœurs ainsi qu'une configuration classique de leurs architectures de caches sont décrites dans le tableau suivant

Tableau 12 Paramètres de configuration des processeurs

Cœur	I-L1\$ (cache/ bloc/ assoc.)	D-L1\$ (cache/ bloc/ assoc.)	L2\$ (cache/ bloc/ assoc.)	Prédicteur de branchement		Fetch queue	Decode/ Issue/ Commit	RUU/ LSQ	# ALU entiers/ flottants	# multip. entiers/ flottants
				Type	Latence mis-préd. (cycles)					
Cortex A15	32KB/ 64/ 2	32KB/ 64/ 2	512KB/ 64/ 16	2 level BTB=256	15	8	4/8/4	16/16	5/1	1/1
Cortex A7	32KB/ 32/ 2	32KB/ 32/ 2	512KB/ 32/ 8	bimodal BTB=256	8	4	2/4/2	2/8	1/1	1/1

Pour les applications, la suite de benchmarks pour l'embarqué **MiBench** sera utilisée et notamment l'applicatif Dijkstra qui recherche les plus court chemins d'un graphe. Cette suite est téléchargeable sur le site <http://www.eecs.umich.edu/mibench/> (Téléchargement du code source : wget <http://www.eecs.umich.edu/mibench/network.tar.gz>). Une description du benchmark est disponible ici : <http://www.eecs.umich.edu/mibench/publications/Mibench.pdf>

Pour compléter, l'étude sera également menée sur le bloc cipher BlowFish [9] [10], voir l'Annexe 2 « Applications ».

- Compilez l'application **Dijkstra** et **BlowFish** avec **sslittle-na-sstrix-gcc** en modifiant au besoin les *Makefile* associés.

Dijkstra :

Type d'instruction	Nombre	Pourcentage
load	14951197	26,99
store	4420229	7,98
uncond branch	527837	0,95
cond branch	9381122	16,93
int computation	26120597	47,15
fp computation	0	0
trap	239	0

Questions

1. Profiling de l'application :

Effectuez un profiling de l'application **dijkstra** et **BlowFish** en utilisant le simulateur **sim-profile** (**dijkstra_small input.dat** et **bf.ss input_small.asc**).

Q1 : Générez le pourcentage de chaque classe d'instructions de ces applications et remplissez les valeurs dans un tableau.

Q2 : Quelle catégorie d'instructions nécessiterait une amélioration de performances ?

Expliquez en quelques lignes (max 5 lignes). **Les calculs d'entier et les load car ces instructions représentent environ les 3/4 des instructions**

Q3 : Au regard des résultats obtenus lors du TP2, pouvez-vous justifier d'éventuelles similitudes/divergences comportementales entre dijkstra, BlowFish, SSCA2-BCS, SHA-1 et le produit de polynômes ?

2. Evaluation des performances :

- Cortex A7 :** A taille de cache L2 fixe (512KB) et en faisant varier simultanément la taille des caches L1 d'instructions et de données de 1KB à 16KB (i.e. : 1KB, 2KB, 4KB, 8KB, 16KB), effectuez une évaluation de performances en utilisant le simulateur **sim-outorder**.

Q4 : Générez les figures de performances détaillées (performance générale, IPC, hiérarchie mémoire, prédition de branchements, etc.) en fonction de la taille du cache L1 pour les configurations testées. Analysez les résultats. Quelle configuration de L1 donne les meilleures performances pour le Cortex A7 pour dijkstra ? et pour BlowFish ?

N.B. : Mentionnez les paramètres d'exécution de sim-outorder que vous avez utilisés.

- Cortex A15 :** A taille de cache L2 fixe (512KB) et en faisant varier simultanément la taille des caches L1 d'instructions et de données de 2KB à 32KB (i.e. : 2KB, 4KB, 8KB, 16KB, 32KB), effectuez une évaluation de performances en utilisant le simulateur **sim-outorder**.

Q5 : Générez les figures de performances détaillées (performance générale, IPC, hiérarchie mémoire, prédition de branchements, etc.) en fonction de la taille du cache L1 pour les configurations testées. Analysez les résultats. Quelle configuration de L1 donne les meilleures performances pour le Cortex A15 pour dijkstra ? et pour BlowFish ?

N.B. : Mentionnez les paramètres d'exécution de sim-outorder que vous avez utilisé.

3. Efficacité surfacique :

La surface du Cortex A15 de l'énoncé (Tableau 13) et de ses caches L1 est de **2 mm²** pour une technologie de **28 nm**. De même, la surface du Cortex A7 de l'énoncé et de ses caches L1 est de **0.45 mm²** dans cette même technologie de **28 nm**. Utilisez l'outil CACTI de HP avec la technologie convenable pour estimer la surface des caches pour chaque type de processeur. Il est recommandé de télécharger la dernière version de CACTI (CACTI 6.5 : <http://www.hpl.hp.com/research/cacti/cacti65.tgz>) sur vos machines, car il s'agit de la version la plus récente, et génère donc les chiffres d'estimation de caches les plus précis. L'outil CACTI est exécuté avec la commande suivante :

`./cacti -infile cache.cfg`

N.B.: Si votre version ne supporte pas la technologie 28nm, ciblez la technologie 32nm.

Q6 : Observez le fichier de configuration de cache « cache.cfg ». Quels sont les paramètres de cache (taille de cache, de bloc, associativité) et la technologie en **nm** utilisés par défaut ?

Q7 : Quelle est la surface des caches L1 du Tableau 14 (instructions et données) en **mm²** ? Quel pourcentage de la surface totale des coeurs A7 et A15 est occupé par les caches L1 ? En déduire la taille des deux coeurs (hors caches L1). Donnez votre analyse.

Q8 : Faire varier la taille des caches L1 dans l'intervalle de valeurs possibles pour le Cortex A7 et le Cortex A15, et donner (en **mm²**) les surfaces des caches L1 obtenues. Avec la configuration de cache L2 utilisée précédemment (512KB), en déduire pour chaque valeur les nouvelles surfaces totales du Cortex A7 et du Cortex A15, caches L2 inclus (présentez les résultats sous forme de graphes).

Q9 : En prenant en compte les deux dimensions (performance et surface) pour les deux processeurs considérés, donnez pour chaque configuration de L1 l'efficacité surfacique de chaque processeur.

$$\underline{\text{N.B. : Efficacité surfacique}} = \frac{\text{IPC}}{\text{surface(mm2)}}$$

4. Efficacité énergétique :

D'après [6], les consommations énergétiques du Cortex A7 et du Cortex A15 sont de **0.10 mW/MHz** et **0.20 mW/MHz** respectivement. De plus, en technologie 28 nm, les fréquences maximales du Cortex A7 et du Cortex A15 sont de **1.0 GHz** et **2.5 GHz** respectivement.

Q10 : Quelle puissance en **mW** consomme chaque processeur à la fréquence maximale ?

Q11 : Avec le même protocole que précédemment, et en prenant en compte les deux dimensions (énergie et surface) pour les deux processeurs considérés, donnez pour chaque configuration de L1 l'efficacité énergétique de chaque processeur (à fréquence maximale).

$$\text{N.B. : } \text{Efficacitéénergétique} = \frac{\text{IPC}}{\text{consommationenergie}(mW)}$$

5. Architecture système big.LITTLE :

Q12 : Avec un esprit de concepteur de système, et en se basant sur les résultats de Q10 et Q11, proposez la meilleure configuration du cache L1 du processeur big.LITTLE pour les applications Dijkstra et BlowFish **individuellement**.

6. Facultatif :

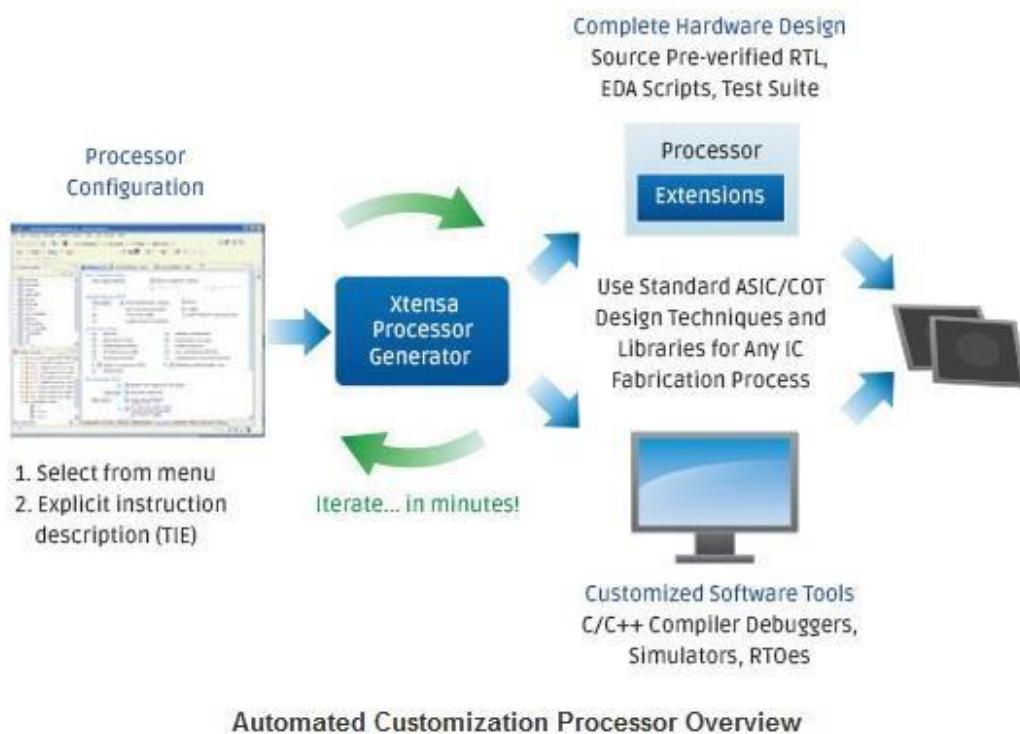
Q13 : Les configurations proposées sont-elles équivalentes ? Proposer éventuellement un compromis et conclure sur les applications étudiées.

Q14 : Proposez une approche pour la spécification d'une architecture avec plusieurs applications dans un domaine spécifique.

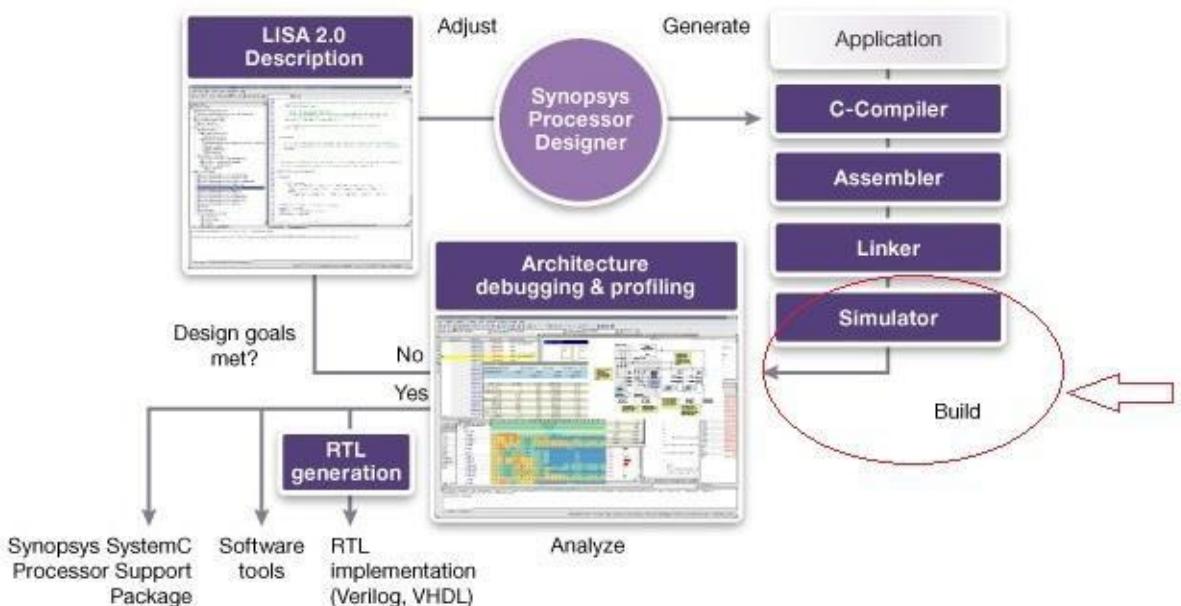
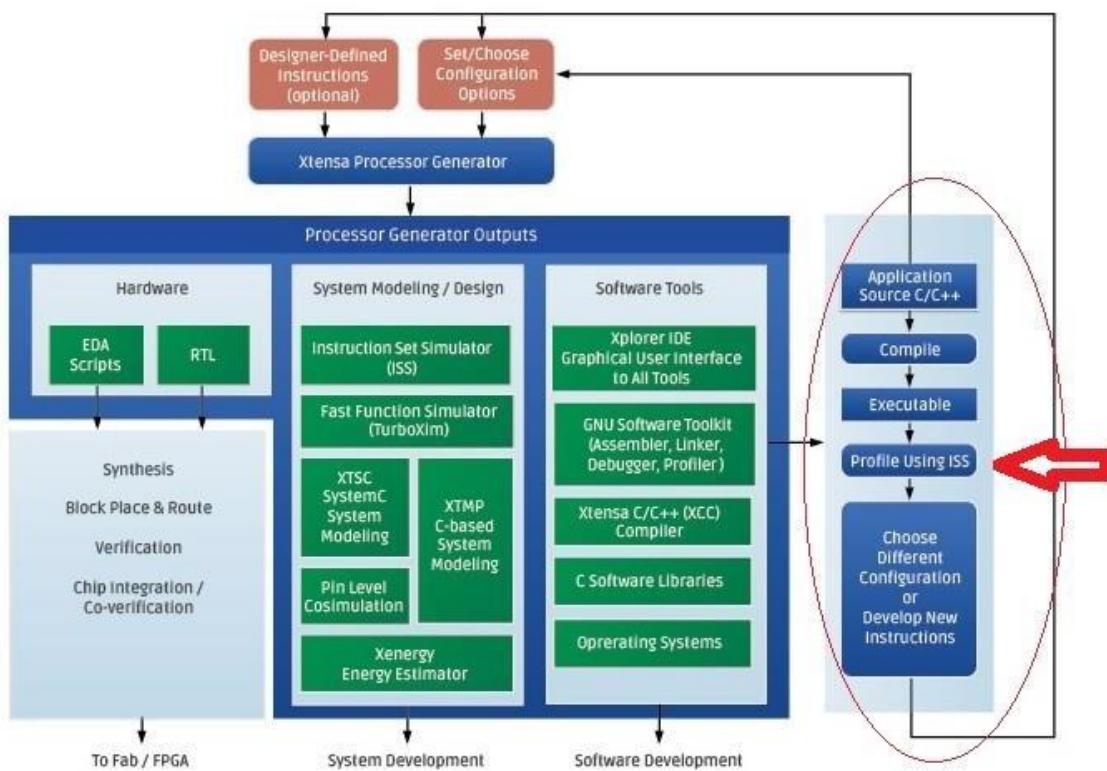
Remettre un rapport de TP par **quadrinôme** en version électronique **au format PDF (TP4-nom1-nom2-nom3-nom4.pdf)** incluant l'ensemble des réponses aux questions précédentes pour le **17/03/2025** aux adresses emails hammami@ensta.fr et sasa.radosavljevic@ens-paris-saclay.fr avec en sujet de message **ECE_4ES01_TA/TP4**.

La note du rapport comptera pour 15% de la note globale.

N.B. : La lisibilité et le format font partie de la note de votre rapport.



Automated Customization Processor Overview



TD/TP5 : Analyse de performances de configurations de microprocesseurs multicoeurs pour des applications parallèles.

Le parallélisme au niveau instructions (*ILP : Instruction Level Parallelism*) est un niveau de parallélisme qui a ses limites.

Une autre approche consiste à utiliser des architectures capables d'exécuter plusieurs flots d'instructions indépendants simultanément sur plusieurs flots de données, en fonction de la disponibilité des ressources internes. Citons par exemple les architectures superscalaires de type SMT (Simultaneous Multithreading). Ces architectures exploitent le parallélisme de l'application au niveau des tâches (*TLP : Thread Level Parallelism*). Le Pentium4 HyperThreading est un exemple commercial de ce type de processeur [1].

Pourtant, la recherche de performances supplémentaires sur la base d'un processeur unique ne peut plus être poursuivie pour des raisons thermiques et de consommation d'énergie. Cela signifie la fin de l'augmentation des fréquences d'horloge.

L'alternative consiste à multiplier le nombre de processeurs sur une même puce en utilisant une fréquence d'horloge plus basse. La Figure 16 montre les architectures de processeurs (a) monoprocesseur scalaire in-order (b) monoprocesseur superscalaire out-of-order (c) monoprocesseur SMT (Simultaneous Multithreading) (d) CMP (Chip MultiProcessor/multicore).

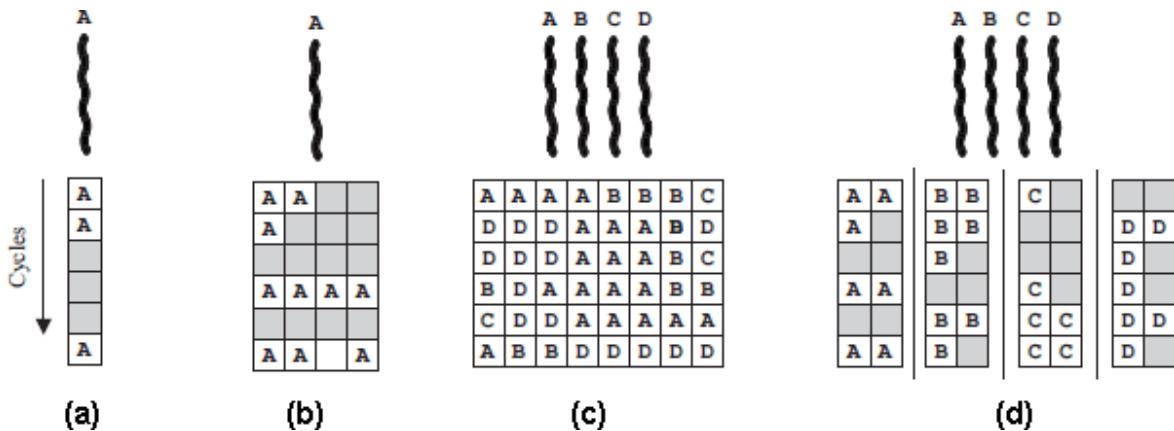


Figure 16 a) scalaire b) superscalaire c) SMT Simultaneous Multithreading d) CMP Chip MultiProcessor

IBM POWER6 [2], SUN UltraSPARC T2 [3], et Intel Ivy Bridge [4] sont des exemples commerciaux parmi plusieurs qui existent sur le marché.

Par contre, en multipliant le nombre de processeurs, des nouvelles questions et de nouveaux problèmes se posent :

- Type des cœurs de processeur (scalaire, superscalaire)
- Hiérarchie mémoire
- Synchronisation et communication entre les cœurs de processeur
- Cohérence de cache

Le but de ce TD/TP est d'explorer les architectures multiprocesseurs CMP en exécutant une application parallèle. En particulier, les performances par rapport aux nombre de cœurs et le type de chaque cœur seront étudiées. Pour ce TD/TP, on va utiliser le simulateur gem5 (Annexes 2 et 3) pour générer un simulateur de type SMP (Symmetrical MultiProcessing) afin de simuler des architectures multiprocesseurs de type CMP.

Description de l'application multiplication de matrice parallèle

Pour ce TD/TP, on va utiliser l'application de multiplication de 2 matrices A et B, qui est parallélisée pour être exécutée par m threads. A et B sont 2 matrices de taille $n * n$, et le résultat est stocké dans une matrice C.

La Figure 18 montre une description de cet algorithme pour 2 threads et une matrice de taille $4 * 4$

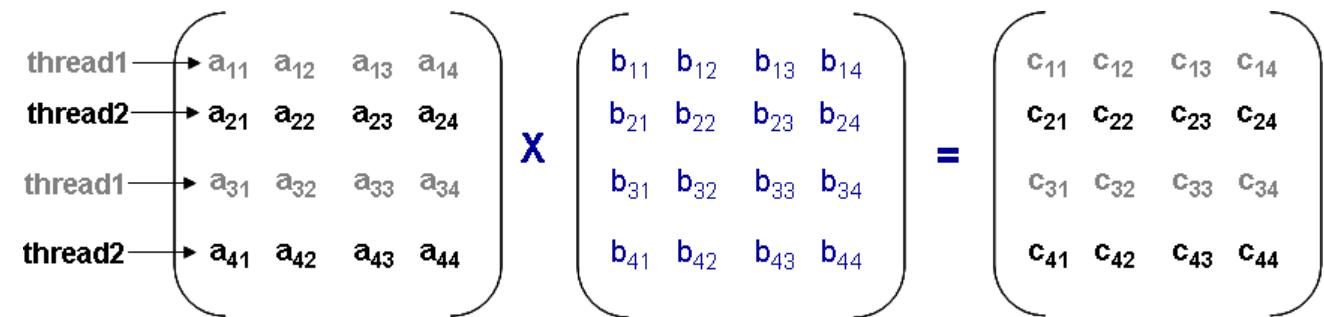


Figure 17 Multiplication de matrice 4x4 avec 2 threads

Le thread principal créé ('fork') $m-1$ threads secondaires indépendants. Ce pool de m threads exécute alors le calcul matriciel comme visible sur la Figure 19.

Puis, le thread principal attend la fin de l'exécution de tous les threads secondaires et considère que la multiplication des matrices a réussi.

Cette génération de threads secondaires est gérée dans la boucle **for** principale du programme **test_omp.cpp** grâce à une librairie de programmation parallèle très utilisée dans la communauté scientifique, OpenMP [6].

Dans le programme **test_omp.cpp** (compilé vers l'exécutable **test_omp**), le nombre de threads **m** ainsi que la taille des matrices **n** sont paramétrables.

Les paramètres d'entrée de l'application sont donc :

./test_omp <nthreads> <size>

<nthreads> : nombre de threads en parallèles (de 1 à m<n)

<size> : nombre de lignes et colonnes de la matrice carrée (**Note : pour conserver des temps de simulations raisonnables, garder n<256**)

Pour récupérer le binaire **test_omp** :

```
$cp -v /home/c/nom-mdc/ES201/tools/TP5/test_omp /your/target/directory/
```

Attention : La librairie de programmation pthreads fournie pour votre TD/TP pour le mode « SE » de gem5 (**voir Annexes 2 et 3**) est toujours en cours de développement et impose pour le moment de conserver l'équivalence suivante : **n threads = n cœurs**.

Attention 2 : Se référer au fichier : /home/c/nom-mdc/ES201/tools/TP5/README expliquant la procédure (ainsi qu'aux annexes).

```
export GEM5=/home/c/nom-mdc/ES201/tools/TP5/gem5-stable
```

L'exécution du programme **test_omp** se fera donc de la manière suivante (avec ncores = nthreads) :

```
$GEM5/build/ARM/gem5.fast $GEM5/configs/example/se.py -n <ncores> -c test_omp -o "<nthreads> <size>"
```

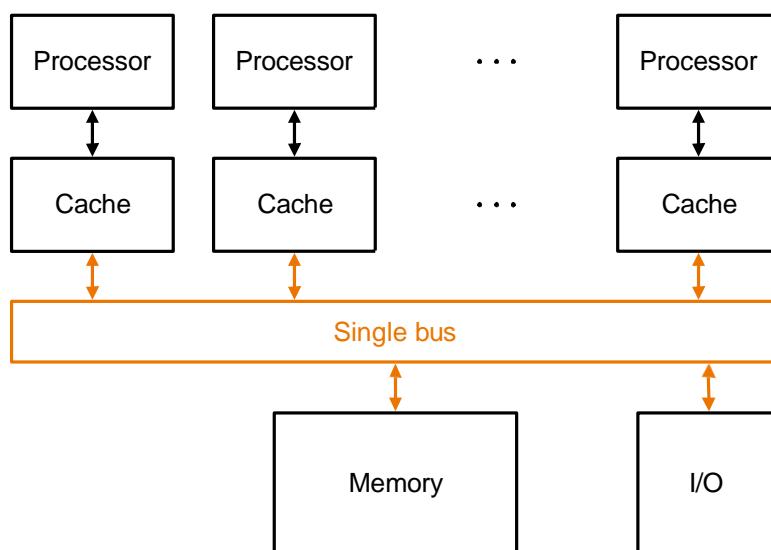


Figure 18 Architecture multicœurs à base de bus

Note : Pensez à vous référer aux Annexes 2 et 3 ainsi qu'à l'aide de l'exécutable pour accéder à toutes les options d'exécution possibles (type de cpu, configuration des caches, etc.) :

```
$GEM5/build/ARM/gem5.opt $GEM5/configs/example/se.py --help
```

Questions

1. Analyse théorique de cohérence de cache

Q1 : En considérant que chaque thread s'exécute sur un processeur dans une architecture de type multicoeurs à base de bus et 1 niveau de cache (comme décrit Figure 21), décrivez le comportement de la hiérarchie mémoire et de la cohérence des caches pour l'algorithme de multiplication de matrices. On supposera que le thread principal se trouve sur le processeur d'indice 1.

2. Paramètres de l'architecture multicoeurs

Le simulateur gem5 permet de faire varier de très nombreux paramètres des éléments architecturaux (types de processeur et paramètres associés à un processeur donné, mémoires caches L1, L2, cohérence de cache, etc.). Tous ces paramètres ne sont pas « accessibles » depuis les options de configuration système **se.py**, mais il est pourtant possible de les faire varier.

Q2 : Examinez le fichier de déclaration d'un élément de type « processeur superscalaire out-of-order », et présentez sous forme de tableau cinq paramètres configurables de ce type de processeur avec leur valeur par défaut. Choisissez de préférence des paramètres étudiés lors des séances TD/TP précédentes. Le fichier à consulter est le suivant :

```
$GEM5/src/cpu/o3/O3CPU.py
```

Q3 : Examinez le fichier d'options de la plateforme **se.py**, puis déterminez et présentez sous forme de tableau les valeurs par défaut des paramètres suivants :

- Cache de données de niveau 1 : associativité, taille du cache, taille de la ligne
- Cache d'instructions de niveau 1 : associativité, taille du cache, taille de la ligne
- Cache unifié de niveau 2 : associativité, taille du cache, taille de la ligne

Le fichier d'options à consulter est le suivant :

```
$GEM5/configs/common/Options.py
```

3. Architecture multicoeurs avec des processeurs superscalaires in-order (Cortex A7)

On se propose dans cette partie d'étudier une architecture multiprocesseur de type CMP à base de cœurs équivalents au Cortex A7 étudié dans le TD/TP5. Dans notre simulateur gem5, le modèle de CPU associé à ce type de processeur est le modèle **arm_detailed** (`--cpu-type=arm_detailed`).

En fixant la taille de la matrice à **m**, et en faisant varier le nombre de threads parallèles de l'application (nombre de threads = 1, 2, 4, 8, 16, ..., **m**), répondre aux questions suivantes :

Q4 : Déterminez quel est le processeur exécutant toujours le plus grand nombre de cycles. Expliquez pourquoi. Expliquez également pourquoi l'analyse du nombre de cycles sur ce processeur revient à analyser le nombre total de cycles d'exécution de l'application.

Q5 : Pour chaque configuration, quel est le nombre de cycles d'exécution de l'application ? Vous pourrez présenter vos résultats sous forme de graphe 2 axes

Q6 : Déduire le speedup par rapport à la configuration à 1 thread.

Q7 : En utilisant le nombre total d'instructions simulées, déterminez quelle est la valeur maximale de l'IPC pour chaque configuration ?

Q8 : Discussion et interprétation (*max. 10 lignes*).

4. Architecture multicoeurs avec des processeurs superscalaires out-of-order (Cortex A15)

On se propose dans cette partie d'étudier une architecture multiprocesseur de type CMP à base de cœurs équivalents au Cortex A15 étudié dans le TD/TP5. Dans notre simulateur gem5, on dispose d'un modèle de processeur superscalaire out-of-order : le modèle **o3** (`--cpu-type=detailed`)

En fixant la taille de la matrice à **m**, et en faisant varier le nombre de threads parallèles de l'application (nombre de threads = 1, 2, 4, 8, 16, ..., **m**), et la largeur du processeur superscalaire (nombre de voies = 2, 4, 8), répondre aux questions suivantes :

Q9 : Pour chaque configuration, quel est le nombre de cycles d'exécution de l'application ? Vous pourrez présenter vos résultats sous forme de graphe 3 axes.

Q10 : Déduire le speedup par rapport à la configuration à 1 thread.

Q11 : En utilisant le nombre total d'instructions simulées, déterminez quelle est la valeur maximale de l'IPC pour chaque configuration ?

Q12 : Discussion et interprétation (*max. 10 lignes*).

5. Configuration CMP la plus efficace

Q13 : Proposez une configuration ou une gamme de configuration de l'architecture CMP (nombre de threads de l'application **test_omp**, nombre et type de coeurs) qui vous semble la plus appropriée si la contrainte recherchée par le concepteur du système est l'efficacité surfacique ? Discussion et interprétation (*max. 10 lignes*).

N.B. : Vous vous appuierez sur les résultats des deux TD/TP (4 et 5).

6. Facultatif :

En utilisant des tailles de matrices relativement grandes (taille des lignes et des colonnes en octets supérieure à la taille du cache de données de niveau 1) ou des tailles de caches de données relativement petites, un grand nombre de threads peut parfois faire apparaître un comportement « supra-linéaire » (comportement pour lequel le speedup est supérieur à n, où n est le nombre de threads).

Q14 : Au regard de l'évolution théorique du speedup et son évolution constatée lors des questions précédentes, proposez une tentative d'explication (*max. 10 lignes*).

Remettre un rapport de TP par **quadrinôme** en version électronique au format PDF (**TP5-nom1-nom2-nom3-nom4.pdf**) incluant l'ensemble des réponses aux questions précédentes pour le **24/03/2025** aux adresses emails : omar.hammami@ensta.fr et sasa.radosavljevic@ens-paris-saclay.fr avec en sujet de message **ECE_4ES01_TA /TP5**.

La note du rapport comptera pour 15% de la note globale.

N.B. : La lisibilité et le format font partie de la note de votre rapport.

```

// test_omp.cpp
// Good old matrix multiply using openmp

#include <assert.h>
#include <pthread.h>
#include <stdio.h>
#include <stdlib.h>
#include <omp.h>

int64_t* A;
int64_t* B;
int64_t* C;

int main(int argc, const char** argv) {

    if (argc != 3) {
        printf("Usage: ./test_omp <nthreads> <size>\n");
        exit(1);
    }

    int nthreads = atoi(argv[1]);

    if (nthreads < 1) {
        printf("nthreads must be 1 or more\n");
        exit(1);
    }

    int size = atoi(argv[2]);

    if (size < 1) {
        printf("size must be 1 or more\n");
        exit(1);
    }

    printf("Setting OMP threads to %d\n", nthreads);
    omp_set_num_threads(nthreads);

    A = (int64_t*) calloc(size*size, sizeof(int64_t));
    B = (int64_t*) calloc(size*size, sizeof(int64_t));
    C = (int64_t*) calloc(size*size, sizeof(int64_t));

    printf("Starting with row/col size=%d\n", size);

    for (int x = 0; x < size; x++) {
        for (int y = 0; y < size; y++) {
            A[x*size + y] = x*y;
        }
    }
    printf("A initialized\n");

    for (int x = 0; x < size; x++) {
        for (int y = 0; y < size; y++) {
            B[x*size + y] = x*y - y;
        }
    }
    printf("B initialized\n");
    printf("Computing A*B with %d threads\n", nthreads);

    #pragma omp parallel for
    for (int x = 0; x < size; x++) {
        for (int y = 0; y < size; y++) {
            int64_t tot;
            for (int m = 0; m < size; m++) {
                tot += A[x*size + m]*B[m*size + y];
            }
            C[x*size + y] = tot;
        }
    }

    printf("Done\n");
    return 0;
}

```


TD/TP6 : Micropcesseurs et Energie**Exercice 1 : Lois Physiques Energie – Puissance**

Q1 : 2 milliards de téléphones portables dans le monde avec des utilisations en mode idle ?

Q2 : 2 milliards de téléphones portables dans le monde avec des utilisations en mode actif ?

Q3 : Consommation équivalente en éoliennes ?



Q4 : consommation équivalente en champ solaires ?



Exercice 2 : Mode de gestion de l'énergie des microprocesseurs (ARM) et FSM

Q1. Citer 3 méthodes matérielles pour réduire la consommation énergétique dans les multi-cœurs

Q2. Pour chaque méthode, quelles sont les implications énergétiques ? (Statique, Dynamique, ..., Timing, Area.) Faire un tableau de comparaison

Q3. Dans la documentation cortex A9, quelles sont les techniques mises en œuvre et comment le sont-elles ?

Exercice 3 : Microélectronique

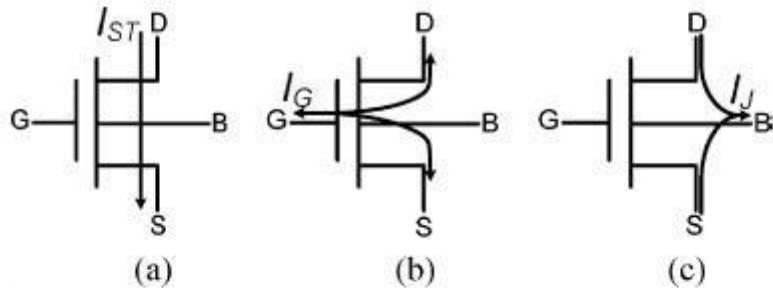


Fig. 2. NMOS transistor current contributions in subthreshold. (a) Sub-threshold current. (b) Gate current. (c) Junction current.

TABLE I
NMOS/PMOS TRANSISTOR PARAMETERS (65-NM, STD- V_{TH}) [17]

	n	I_0 [A]	V_{TH0} [V]	λ_{DS}	λ_{RS}
NMOS	1.39	6.65E-5	0.598	9.0E-2	9.9E-2
PMOS	1.27	5.95E-6	0.532	8.0E-2	1.1E-1

Q1 : Technologie actuelle / ordre de grandeur du nombre de transistors dans un processeur récent

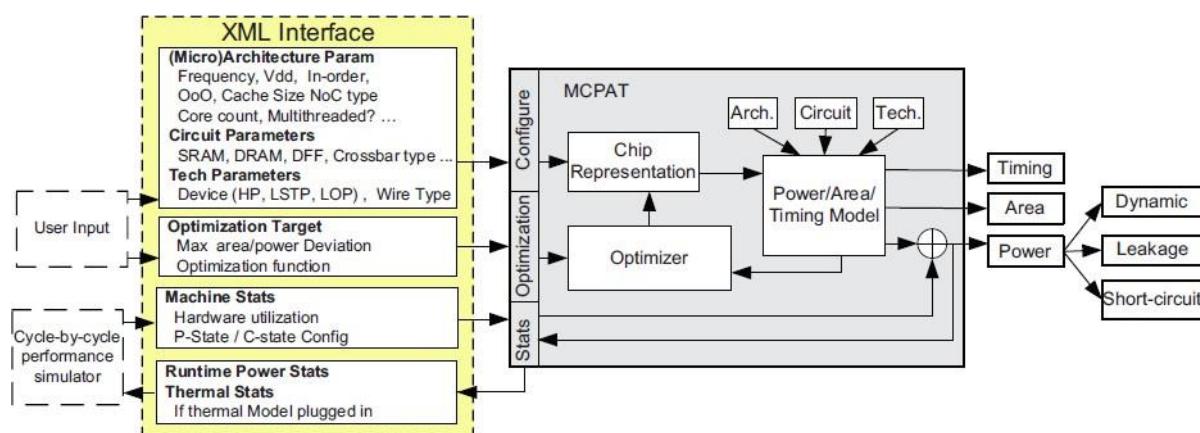
Q2 : Qu'est-ce que la conduction en régime de faible inversion et pourquoi est-ce utilisé ? Principaux "tuning knobs" accessibles ?

Q3 (opt.) : Quels sont les effets les plus pénalisants pour le transistor MOS ?

Sources et références :

Exercice 4 : Evaluation de performances – McPAT

On recherche à optimiser le processeur choisi, afin de réduire la consommation énergétique globale du système. Dans ce cas d'étude, nous nous intéressons à l'intérêt d'avoir une unité flottante dans le processeur. Le cas d'étude s'appuie sur les applications SSCA2 et PageRank (du benchmark miBench) sur un processeur de type ARM cortex A9. Pour avoir les informations de performance, le simulateur Gem5 est utilisé. Celui-ci est « connecté » à l'outil McPat permettant d'avoir les informations de surface et consommation énergétique du processeur.



Block diagram of the McPAT framework.

Commandes utiles :

```
export HOME_TOOLS=/home/c/nom-mdc/ES201/tools/TP6/tools
cp -r /home/c/nom-mdc/ES201/tools/TP6/bin/ /your/path/
cd /your/path/bin/<app>
$HOME_TOOLS/run_all.sh -b <app> (-f pour floating point)
<app> : [SSCA2|pagerank]
```

Q1 Simuler PageRank et SSCA2 avec et sans l'extension Floating point. Lancer le simulateur et l'émulateur énergétique. Quel est l'accélération à utiliser l'unité flottante ? Y a-t-il un gain énergétique ? Regarder dans m5out/.xml et m5out/*.xml_simple*

SSCA2	PageRank
Basic core_area core_leakage core_runtime_dynamic core_energy	Basic core_area core_leakage core_runtime_dynamic core_energy

fpu core_area core_leakage core_runtime_dynamic core_energy	J in	sec	fpu core_area core_leakage core_runtime_dynamic core_energy	J	sec
---	------	-----	---	---	-----

(Résultat d'énergie et de surface comprenant le cœur et le cache L1)

	SSCA2	PageRank
Speedup		
Energy gain		

Q2 Quelle est votre analyse pour chaque application ?

Q3 Si les 2 applications doivent tourner sur la même plateforme quelles méthodes peut-on employer pour réduire l'énergie ? Proposer des idées dans le cadre d'un mono-cœur et d'un multi-cœur. Les solutions de l'exercice 1 sont-elles utilisables ?

Solution TD/TP1 : Evaluation de performances - programmation assembleur MIPS/DLX

Exercice 1 : Evaluation de performances analytique - Loi d'Amdahl

Nous souhaitons améliorer les performances d'un microprocesseur en réduisant d'un facteur 5 le temps d'exécution des instructions flottantes. Nous souhaiterions évaluer l'impact d'une telle transformation sachant que le temps d'exécution d'un benchmark avant l'amélioration prend 10 secondes et que 50% du temps est dépensé dans l'exécution de calcul flottant.

Q1 : Quel serait le speed up ?

$$S_T = \frac{1}{(1-P) + (P/S_p)}$$

A1 : Suivant l'équation d'Amdahl, le speedup total est égal à :

On obtient pour $P = 0.5$ et $S_p = 5$

=> $S_T = [(1-0.5) + 0.5/5]^{-1}$

=> $S_T = 1.66$

Exercice 2 : Evaluation de performances analytique - Loi d'Amdahl

Nous souhaiterions améliorer les performances d'un microprocesseur et il existe 2 moyens :

3. Réduire le temps d'exécution des instructions de multiplication d'un facteur 4.
4. Réduire le temps d'exécution des instructions d'accès mémoire d'un facteur 2.

L'exécution du programme benchmark prend 100 secondes et utilise :

- 20 % des instructions pour la multiplication,
- 50% des instructions pour les accès mémoire,
- 30% des instructions pour les autres types d'opérations.

Q1 : Quel est le speedup si l'on améliore uniquement la multiplication ?

A1 : Le speedup si l'on améliore uniquement la multiplication pour $P = 0.2$ et $S_p = 4$ est égal à :

=> $S_T = [(1-0.2) + 0.2/4]^{-1}$

=> $S_T = 1.17$

Q2 : Quel est le speedup si l'on améliore uniquement les accès mémoires ?

A2 : Le speedup si l'on améliore uniquement les accès mémoire pour $P = 0.5$ et $S_P = 2$ est égal à :

$$\Rightarrow S_T = [(1-0.5) + 0.5/2]^{-1}$$

$$\Rightarrow S_T = 1.33$$

Q3 : Quel est le speedup si l'on améliore les deux ?

A3 : La généralisation de la loi d'Amdahl pour prendre en compte plusieurs améliorations est

$$S_T = \frac{1}{(1 - \sum_{i=0}^n P_i) + (\sum_{i=0}^n P_i / S_{P_i})}$$

donnée par :

Le speedup si l'on améliore la multiplication et les accès mémoire pour $P = 0.5$ et $S_P = 2$ est égal à :

$$\Rightarrow S_T = [(1-0.2-0.5) + (0.2/4 + 0.5/2)]^{-1}$$

$$\Rightarrow S_T = 1.66$$

Exercice 3 : Evaluation de performances – simulation

Nous souhaitons mesurer certains paramètres de performance d'un programme en utilisant un simulateur de processeur (Instruction Set Simulator – ISS). Pour cela, nous allons écrire un programme en C qui sera compilé dans un jeu d'instructions interprétable par le simulateur. L'exécutable généré sera alors simulé.

Ecrire un programme en C effectuant la somme de deux vecteurs de taille $N = 50$ que vous initialiserez de manière aléatoire. Compilez ce programme avec `sslittle-na-sstrix-gcc` :

```
sslittle-na-sstrix-gcc votreprog.c -o votreprog.ss
```

Cette commande générera un exécutable pour le processeur SimpleScalar avec un format .ss.

Simulez ce programme en utilisant le simulateur SimpleScalar (in-order).

```
sim-outorder -issue:inorder true votreprog.ss
```

Complétez Tableau 1 avec les valeurs suivantes :

Q1 : Quel est le nombre total d'instructions exécutées par votre programme sur ce processeur ? **sim_total_insn**

A1 : **sim_total_insn = 9644**

Q2 : Quel est le nombre total de cycles processeur nécessaires pour l'exécution du programme ? **sim_cycles**

A2 : **sim_cycles = 11259**

Q3 : Quel est le CPI de votre programme sur ce processeur ? **sim_CPI**

A3 : **CPI = Clock Per Instruction = # clock cycles / # of instructions**

=> **sim_CPI = sim_cycles / sim_total_insn = 11259 / 9644 = 1.167**

Q4 : Quel est l'IPC de votre programme sur ce processeur ? **sim_IPC**

A4 : **IPC = Instruction Per Cycle = 1 / CPI**

=> **sim_IPC = 1 / sim_CPI = 0.856**

Tableau 1 Evaluation de performance

Paramètres	Valeur
nombre total d'instructions exécutées	9644
nombre total de cycles processeur	11259
CPI	1.167
IPC	0.856

N.B : Les résultats dépendent de la manière avec laquelle les vecteurs ont été programmés et initialisés.

Q5 : Pour un processeur ayant une fréquence d'horloge de 3 GHz, quelle est la durée d'exécution de votre programme ?

A5 : Une fréquence f de 3 GHz correspond à une période $T = 1/f = 1/3\text{GHz} = 0.333\text{ ns}$

=> La durée d'exécution du programme est égale à : # clock cycles * T = 11259 * 0.333 ns = **3839.157 ns**

Exercice 4 : Commentaire d'un programme en assembleur MIPS

A l'aide du Tableau 2 du jeu d'instructions assembleur MIPS, commentez le programme suivant et indiquez ce que fait la fonction $F(X, Y, Z)$.

On suppose que la variable X se trouve dans le registre \$s1, la variable Y dans \$s2 et la variable Z dans \$s3. Le résultat de la fonction $F(X, Y, Z)$ se trouve dans le registre \$s7.

add \$s7,\$s1,\$s1	=>	$s7 = s1 + s1$	=>	$s7 = 2X$
add \$s7,\$s7,\$s7	=>	$s7 = s7 + s7$	=>	$s7 = 4X$
add \$s7,\$s7,\$s3	=>	$s7 = s7 + s3$	=>	$s7 = 4X + Z$
add \$s7,\$s7,\$s3	=>	$s7 = s7 + s3$	=>	$s7 = 4X + 2Z$
add \$s7,\$s7,\$s2	=>	$s7 = s7 + s2$	=>	$s7 = 4X + Y + 2Z$

$$F(X, Y, Z) = \mathbf{4X + Y + 2Z}$$

Exercice 5 : Programmation en assembleur MIPS

A l'aide du Tableau 2 du jeu d'instructions MIPS, programmez en assembleur MIPS la fonction $F(X, Y, Z) = X + 2Y - 3Z$

On suppose que la variable X se trouve dans le registre \$s1, la variable Y dans \$s2, la variable Z dans \$s3 et que le résultat de la fonction $F(X, Y, Z)$ se trouve dans le registre \$s7.

add \$s7, \$s3, \$s3	=>	$s7 = s3 + s3$	=>	$s7 = 2Z$
add \$s7, \$s7, \$s3	=>	$s7 = s7 + s3$	=>	$s7 = 3Z$
sub \$s7, \$s2, \$s7	=>	$s7 = s2 - s7$	=>	$s7 = Y - 3Z$
add \$s7, \$s2, \$s7	=>	$s7 = s2 + s7$	=>	$s7 = 2Y - 3Z$
add \$s7, \$s1, \$s7	=>	$s7 = s1 + s7$	=>	$s7 = X + 2Y - 3Z$

$$\Rightarrow F(X, Y, Z) = X + 2Y - 3Z$$

Note pour exercice 4 et 5 :

L'utilisation des instructions de multiplication est bien sûr aussi possible, mais ces instructions ont en général un temps d'exécution plus long (entre 2 et 20 cycles). En effet, le temps de propagation à travers un multiplieur 32 bits (généralement multi-cycles) est supérieur au temps de propagation d'un additionneur 32 bits (1 cycle).

L'instruction 'sll' (shift left logical) peut aussi être utilisée au lieu de l'instruction 'add'.

Exercice 6 : Encodage en assembleur MIPS

A l'aide du Tableau 3 et du Tableau 4 des codages des instructions MIPS, codez les instructions suivantes :

add \$s5,\$s6,\$s7

add => R format (voir Tableau 4)

(Note : R format = opération 2 registres sources vers 1 registre destination)

Field size	6 bits	5 bits	5 bits	5 bits	5 bits	6 bits
R-format	op	rs	rt	rd	shamt	funct

op: indique que l'instruction est R format

rs: première opérande source de l'instruction

rt: seconde opérande source de l'instruction

rd: registre destination

shamt: "shift amount" pour R format = 0

funct: code de la fonction arithmétique pour le R format

Le champ shamt sera ignoré car il ne concerne que les instructions de décalage. La valeur 0 lui sera affectée par défaut.

op = (0) _{dec} = (00 0000) _{bin}

rs = s6 = (6) _{dec} = (0 0110) _{bin}

rt = s7 = (7) _{dec} = (0 0111) _{bin}

rd = s5 = (5) _{dec} = (0 0101) _{bin}

shamt = (0) _{dec} = (0 0000) _{bin}

funct = add = (32) _{dec} = (10 0000) _{bin}

codage instruction :

0	6	7	5	0	32
000000	00110	00111	00101	00000	100000

and \$s6,\$s2,\$s5

and => R format (voir Tableau 4)

op = (0) _{dec} = (00 0000) _{bin}

rs = s2 = (2) _{dec} = (0 0010) _{bin}

rt = s5 = (5) _{dec} = (0 0101) _{bin}

rd = s6 = (6) _{dec} = (0 0110) _{bin}

shamt = (0) _{dec} = (0 0000) _{bin}

funct = and = (36) _{dec} = (10 0100) _{bin}

codage instruction :

0	2	5	6	0	36
000000	00010	00101	00110	00000	100100

lw \$s2,50(\$s4)

lw => I format (voir Tableau 4)

(Note : I format = opération 1 registre source et 1 immédiat vers 1 registre destination)

Field size	6 bits	5 bits	5 bits	5 bits	5 bits	6 bits
I-format	op	rs	rt	Address/immediate		

op = lw = (35) _{dec} = (10 0011) _{bin}

rs = s4 = (4) _{dec} = (0 0100) _{bin}

$rt = s2 = (2)_{dec} = (0\ 0010)_{bin}$
 $immediate = (50)_{dec} = (0000\ 0000\ 0011\ 0010)_{bin}$

codage instruction :

35	4	2	50
100011	00100	00010	0000000000110010

Exercice 7 : Commentaire du programme en assembleur MIPS

Commentez le programme suivant et indiquez ce qu'il fait.

Soit A un vecteur de dimension N = 10. L'adresse se trouve dans le registre \$s5.

A l'initialisation : \$s5 => adresse de base du vecteur A

$(\$s5+0) \Rightarrow$ contenu de la case mémoire pointée par \$s5
 $\Rightarrow A[0] = (\$s5+0)$
 $A[1] = (\$s5+4) \Rightarrow$ 4 cases mémoire pour pointer sur le mot suivant du vecteur
 $A[2] = (\$s5+8) \Rightarrow$ 8 cases mémoire pour pointer sur le mot suivant du vecteur
 ...

(Note : le pointeur vers A étant incrémenté de 4 en 4, on peut en déduire que A contient des éléments de taille 32 bits...)

andi \$s3,\$s3,0 \Rightarrow $s3 = s3 \& 0 \Rightarrow s3 = 0$
 andi \$s1,\$s1,0 \Rightarrow $s1 = s1 \& 0 \Rightarrow s1 = 0$
 addi \$s1,\$s1,1 \Rightarrow $s1 = s1 + 1 \Rightarrow s1 = 0 + 1 \Rightarrow s1 = 1$
 andi \$s11,\$s11,0 \Rightarrow $s11 = s11 \& 0 \Rightarrow s11 = 0$
 andi \$s2,\$s2,0 \Rightarrow $s2 = s2 \& 0 \Rightarrow s2 = 0$
 addi \$s2,\$s2,10 \Rightarrow $s2 = s2 + 10 \Rightarrow s2 = 0 + 10 \Rightarrow s2 = 10$
Loop : lw \$s8,0(\$s5) \Rightarrow **Loop:** label/étiquette permettant de réaliser un branchement.
 A l'initialisation, $0(\$s5) = A[0]$

\Rightarrow Chargement du premier élément du tableau dans le registre s8

s8 est registre de destination de l'opération de chargement mémoire au niveau du processeur.

Première boucle, $s8 = A[0]$

Deuxième boucle, $s8 = A[1]$

Dernière boucle, $s8 = A[9]$

add \$s11,\$s11,\$s8 \Rightarrow $s11 = s11 + s8$

Le registre s11 contient le résultat intermédiaire permettant de calculer la somme de tous les éléments du tableau.

A l'initialisation, $s11 = 0$

Première boucle, $s11 = 0 + A[0]$

Deuxième boucle, $s11 = A[0] + A[1]$

Dernière boucle, $s11 = A[0] + A[1] + \dots + A[9]$

addi \$s5,\$s5,4 => **s5 = s5 + 4**

Le registre s5 est incrémenté de la taille d'un mot et contient l'adresse de l'élément suivant

sub \$s2,\$s2,\$s1 => **s2 = s2 - 1**

Le registre s2 est l'index de la boucle permettant de balayer les divers éléments du tableau A.

A l'initialisation, s2 = 10

Première boucle, s2 = 9

Deuxième boucle, s2 = 8

Dernière boucle, s2 = 0

Le registre s1 contient la constante 1 qui permet de décrémenter l'index de boucle

bne \$s2,\$s3, **Loop** => **branch on not equal : instruction de branchement**

Tant que s2 ≠ s3, aller à l'étiquette « Loop » et exécuter les instructions entre « Loop » et bne.

Dès que s2 = s3, exécuter l'instruction suivante du programme (et donc la fin du programme, puisque la condition d'arrêt de la boucle est s2 = s3 = 0)

D'où s11 = somme (de i=0 à 9) de A[i]

Code équivalent en C:

```
i=10;                //équivalent à $s2
sum=0;               //équivalent à $s11
for (i; i > 0; i--)
    sum += A[i]
```

Exercice 8 : Programmation en assembleur MIPS (somme d'un tableau)

Ecrivez un programme en assembleur qui calcule la somme des éléments pairs dans un tableau A de dimension N = 10. L'adresse de A se trouve dans le registre \$s5

Similaire au programme précédent

s11 = A[0] + A[2] + A[4] + A[6] + A[8]

Il suffit de remplacer l'instruction **addi \$s1, \$s1, 1** par **addi \$s1, \$s1, 2 => s1 = s1 + 2**

L'indice de boucle est alors décrémenté de 2 à chaque itération.

Il faut de plus remplacer l'instruction **addi \$s5, \$s5, 4** par **addi \$s5, \$s5, 8** afin de pointer 2 éléments/mots plus loin dans le vecteur A.

Solution TD/TP2 : Programmation assembleur MIPS/DLX (sous programmes-équivalent langage C) - profiling d'applications et ISS (instruction set simulator)

Rappel sur les conventions de l'assembleur MIPS pour les registres :

Tableau 13 File de registres MIPS

Name	Register number	Usage	Preserved on call
\$zero	0	Valeur constante 0	n.a.
\$v0-\$v1	2-3	Valeurs pour résultats et évaluation d'expression	no
\$a0-\$a3	4-7	Arguments	yes
\$t0-\$t7	8-15	Variables temporaires	no
\$s0-\$s7	16-23	Sauvegarde	yes
\$t8-\$t9	24-25	Variables temporaires	no
\$gp	28	Pointeur global (global pointer)	yes
\$sp	29	Pointeur de pile (stack pointer)	Yes
\$fp	30	Pointeur de frame (frame pointer)	Yes
\$ra	31	Adresse de retour (return address)	Yes

N.B#1: Dans MIPS, la valeur du registre PC (Program Counter) n'est pas accessible par le programmeur. Elle est indirectement affectée par des instructions de branchements.

N.B#2: Dans MIPS, les registres numéros 1, 26, 27 sont réservés et ne peuvent pas être utilisés par le programmeur.

Exercice 1 : Switch statement

Veuillez écrire en assembleur l'équivalent du code C suivant :

```
switch(k) {
    case 0 : f = i + j ;break ; /* k = 0 */
    case 1 : f = g + h ;break ; /* k = 1 */
    case 2 : f = g - h ;break ; /* k = 2 */
    case 3 : f = i - j ;break ; /* k = 3 */
}
```

On supposera que les variables f, g, h, i, j et k se trouvent dans les registres \$s0-\$s5 respectivement.

Q1 : Proposez 2 solutions dont une version où le temps d'exécution est indépendant du nombre de cas.

A1 :

Solution 1 : temps d'exécution dépendant du nombre de cas : if-then-else imbriqués

```
beq    $s5, $zero, CASE0      # if (k==0), goto CASE0
addiu   $t2, $zero, 1        # t2 = 1
beq    $s5, $t2, CASE1      # if (k==1), goto CASE1
addiu   $t2, $zero, 2        # t2 = 2
beq    $s5, $t2, CASE2      # if (k==2), goto CASE2
addiu   $t2, $zero, 3        # t2 = 3
beq    $s5, $t2, CASE3      # if (k==3), goto CASE3
j      EXIT                  # if (k<0 || k > 3), goto EXIT => wrong case condition
```

CASE0:

```
add    $s0, $s3, $s4          # k=0 so f = i + j
j      EXIT                  #end of this case so go to EXIT
```

CASE1:

```
add    $s0, $s1, $s2          # k=1 so f = g + h
j      EXIT                  #end of this case so go to EXIT
```

CASE2:

```
sub    $s0, $s1, $s2          # k=2 so f = g - j
j      EXIT                  #end of this case so go to EXIT
```

CASE3:

```
sub    $s0, $s3, $s4          # k=3 so f = i - j
```

EXIT: #end of switch statement

Solution 2 : temps d'exécution indépendant du nombre de cas : approche par indexation de table

```

slt    $t3,$s5,$zero      // test if k < 0
bne    $t3,$zero,EXIT     // if k < 0 go to Exit
slti   $t3, $s5,3         // test if k > 3
beq    $t3,$zero, EXIT    // if k > 3 go to Exit
add    $t1, $s5, $s5      // temp reg $t1 = 2 * k
add    $t1, $t1, $t1      // temp reg $t1 = 4 * k
add    $t1, $t1, $t4      // $t1 = address of JumpTable[k]
lw     $t0, 0($t1)        // temp reg $t0 = JumpTable[k]
jr    $t0

```

CASE0:

```

add    $s0, $s3, $s4      // k = 0 so f gets i + j
j     EXIT                // end of this case so go to Exit

```

CASE1:

```

add    $s0, $s1, $s2      // k = 1 so f gets g + h
j     EXIT                // end of this case so go to Exit

```

CASE2:

```

sub    $s0, $s1, $s2      // k = 2 so f gets g – h
j     EXIT                // end of this case so go to Exit

```

CASE3:

```

sub    $s0, $s3, $s4      // k = 3 so f gets i – j

```

EXIT:

Discussion :

La solution à cet exercice est basée sur l'hypothèse qu'une table JumpTableau de 4 éléments contient de manière consécutive les adresses des étiquettes de branchements (label) CASE0, CASE1, CASE2 et CASE3 associées aux 4 possibilités du **switch**. Le premier intérêt de cette approche utilisée par les compilateurs comparés à l'approche simple de tests successifs (transformation d'une structure switch en constructions if-then-else imbriquées) est le déterminisme du temps d'exécution. En effet, l'approche if-then-else imbriqués fait que le temps d'exécution de cette structure dépend de la valeur **k**, avec le temps le plus court pour **k = 0** et le temps le plus long pour **k = 3**. Par contre, l'approche par indexation de table n'est pas possible lorsque les valeurs pour **k** ne sont pas contigües et il faut alors recourir aux if-then-else imbriqués.

Une dernière optimisation possible lorsque le **switch** est implémenté sous la forme de if-then-else imbriqués est de les imbriquer par probabilité d'occurrence. Cela suppose que le programmeur a une connaissance suffisamment forte à priori de son application pour estimer ces probabilités. Ces trois manières d'implémenter le **switch** suivant la situation sont celles habituellement recommandées pour l'optimisation logicielle (cf. [1] pour exemple).

[1] *Software optimization guide for AMD Athlon 64 and AMD Opteron Processors*, Publication

25112 Rev. 3.05 November 2004. www.amd.com

Exercice 2 : Boucles

Veuillez écrire en assembleur l'équivalent du code C suivant :

```
sum = 0 ;
for(i= 0 ; i < 1000 ; i++) {
    for(j= 500 ; j > 0 ;j--) {
        for(k = 0 ; k < 300; k = k + 10) {
            sum = sum + (i + j + k);
        }
    }
}
```

On supposera que les variables sum, i, j et k se trouvent dans les registres \$s1-\$s4 respectivement.

```
andi    $s1, $s1,0          // sum = 0
andi    $s2, $s2,0          // i = 0
addi   $s3, $zero, 500      // j = 500
andi    $s4, $s4,0          // k = 0
addi   $s5,$zero, 1000      // 1st loop upper bound = 1000
andi    $s6,$s6,0           // 2nd loop lower bound = 0
addi   $s7,$zero, 300       // 3rd loop upper bound = 300
```

Loop1:

Loop2:

Loop3:

```
add    $s1, $s1,$s2         // sum = sum + (i );
add    $s1, $s1,$s3         // sum = sum + (i + j );
add    $s1, $s1,$s4         // sum = sum + (i + j + k);
addi   $s4, $s4,10          // k = k + 10
bne   $s4, $s7, Loop3      // if (k < 300) goto Loop3, else execute 2nd loop
andi   $s4, $s4,0           // reinitialize k = 0
subi  $s3, $s3, 1           // j-
bne   $s3, $s6, Loop2      // if (j > 0) goto Loop2, else execute 1st loop
addi   $s3, $zero, 500       // reinitialize j = 500
addi   $s2, $s2, 1           // i++
bne   $s2, $s5, Loop1      // if (i < 1000) goto Loop1, else end program
```

Exit:

Une optimisation possible est de remarquer qu'au sein de la boucle d'indice **k** la partie **i+j** de l'expression **sum + (i + j + k)** reste inchangée et qu'il est donc possible d'économiser de nombreuses instructions d'additions inutiles en calculant une seule fois **i+j** en dehors de la boucle d'indice **k**.

Exercice 3 : Appels de fonctions

Veuillez écrire en assembleur l'équivalent du code C suivant :

```
int leaf(int g, int h, int i, int j)
{
    int f;
    f = (g + h) - (i + j);
    return f;
}
```

On supposera que les variables g, h, i et j sont transmises par les registres \$a0, \$a1, \$a2, \$a3 lors de l'appel de fonction, et que f correspond à \$s0. Lors de l'exécution d'un appel de fonction, il est nécessaire de sauvegarder dans une pile en mémoire le contenu des registres utilisés. Pour rappel, le registre \$sp donne l'adresse de la pile.

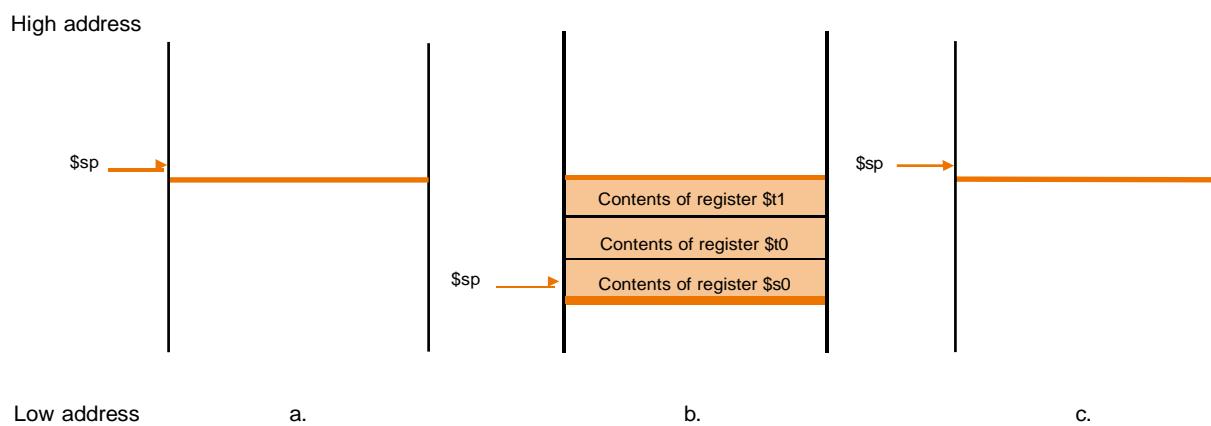


Figure 19 Evolution de la pile lors d'un appel de fonction

L'exécution d'un appel de fonction est constituée de 3 étapes :

1. Sauvegarder dans une pile en mémoire le contenu des registres utilisés par la fonction en cours d'exécution (fonction appelante, caller)
2. Exécuter la fonction appelée (callee)
3. Restaurer le contenu des registres depuis la pile

La pile est implémentée de sorte à : (1) progresser (empiler) dans le sens des adresses décroissantes dans l'espace d'adressage mémoire (2) le pointeur de pile pointe sur l'élément le plus bas dans la pile (en terme d'adresses).

La **Erreur ! Source du renvoi introuvable.** montre la situation de la pile avant empilement (a) après empilement (b) et enfin après dépilement (situation initiale) en (c).

On rappelle que le pointeur de pile **\$sp** est placé dans un registre du banc de registres mais que rien ne le différencie d'un point de vue physique des autres registres du banc de registres.

leaf_example:

```

subi    $sp,$sp,12           // adjust stack to make room for 3 items
sw      $s2, 8($sp)          // save register $s2 for further use
sw      $s1, 4($sp)          // save register $s1 for further use
sw      $s0, 0($sp)          // save register $s0 for further use

add    $s2, $a0, $a1          // register $s2 contains g + h
add    $s1, $a2, $a3          // register $s1 contains i + j
sub    $s0, $s2, $s1          // f = $s2 - $s1 which is (g+h) - (i+j)
add    $v0, $s0, $zero         // returns f ($v0 = $s0 + 0)

lw     $s0, 0($sp)           // restore register $s0 for caller
lw     $s1, 4($sp)           // restore register $s1 for caller
lw     $s2, 8($sp)           // restore register $s2 for caller
addi   $sp, $sp, 12           // readjust the stack pointer
jr     $ra                   // jump back to calling routine ($ra = return address)

```

Q1 : Pourquoi les appels de fonctions affectent les performances des programmes ?

A1 : Les appels de fonctions engendrent des pénalités de temps d'exécution pour sauvegarder et restaurer les registres. Les instructions **lw** et **sw** sont coûteuses en terme d'accès mémoire et prennent plusieurs cycles d'exécution. En conséquence, pour bien bénéficier d'une fonction, il faut que la durée d'exécution du cœur de la fonction soit nettement supérieure à la durée des traitements sur la pile.

Q2 : Pourquoi la récursivité en programmation affecte les performances ?

A2 : La récursivité fait des appels récursifs à la même fonction (même interprétation qu'A1), d'où le compromis facilité de programmation v/s performance. De plus, chaque récursion implique autant de sauvegardes sur la pile, ce qui peut être source d'une importante consommation mémoire.

Exercice 4 : Appels de fonctions

Veuillez écrire en assembleur l'équivalent du code C suivant :

```

void swap(int v[], int k)
{

```

```

int temp;
temp = v[k];
v[k] = v[k+1];
v[k+1] = temp;
}

swap :
subi    $sp,$sp,12           // adjust stack to make room for 3 items
sw      $s2, 8($sp)          // save register $s2 for use afterwards
sw      $s1, 4($sp)          // save register $s1 for use afterwards
sw      $s0, 0($sp)          // save register $s0 for use afterwards

add    $s1, $a1, $a1          // reg $s1 = k * 2
add    $s1, $s1, $s1          // reg $s1 = k * 4
add    $s1, $a0, $s1          // reg $s1 = v + (k * 4) => reg $s1 has the address of v[k]
lw     $s0, 0($s1)           // reg $s0 (temp) = v[k]
lw     $s2, 4($t1)           // reg $s2 = v[k +1]
sw     $s2, 0($s1)           // v[k] = reg $s2
sw     $s0, 4($s1)           // v[k +1] = reg $s0 (temp)

lw     $s0, 0($sp)           // restore register $s0 for caller
lw     $s1, 4($sp)           // restore register $s1 for caller
lw     $s2, 8($sp)           // restore register $s2 for caller
addi   $sp, $sp, 12           // readjust the stack pointer
jr     $ra                   // return to calling routine

```

Exercice 5 : Profiling d'applications (% d'instructions par catégorie) par simulation sur ISS (instruction set simulator)

Nous allons maintenant nous intéresser au profiling de deux applications. La première est tirée du domaine de la cryptographie sur les réseaux euclidiens [2], et la deuxième provient du domaine du traitement des graphes :

1. La multiplication de polynôme qui se retrouve au cœur de la performance de certains chiffrements homomorphes [3]. Vous écrirez un programme de multiplication de polynôme de degré 99 à coefficients flottant initialisés à votre convenance. Un rappel sur la multiplication de polynôme est donné en annexe 2.
2. L'algorithme de calcul de la centralité d'intermédiarité (Betweenness Centrality Score) [1] au travers de l'exécution d'un benchmark synthétique SSCA2 [1]. L'algorithme de BCS permet de calculer l'importance relative d'un nœud en calculant la fraction de plus court chemin entre chaque paire de nœuds, passant par lui.

Q1 : Générez le pourcentage de chaque classe d'instructions utilisées par ces programmes, puis remplissez le tableau suivant

Tableau 14 Pourcentage de chaque classe d'instructions

Classe d'instructions	P1 (%)	P2 (%)	P3 (%)
Instructions de lecture (Load)	12.30	13.11	27.34
Instructions d'écriture (Store)	0.40	0.42	0.88
Instructions de branchement inconditionnel (Uncond branch)	0	0	0
Instructions de branchement conditionnel (Cond branch)	8.08	8.61	2.57
Instructions de calcul entier (Int computation)	79.22	64.75	41.88
Instructions de calcul flottant (Fp computation)	0	13.11	27.33
Nombre total d'instructions exécutées	26 137 287	24 529 449	11 764 854

N.B : Pour la multiplication de polynômes les résultats dépendent de la manière dont ont été programmés et initialisés la multiplication.

Le produit de convolution est donné par le code C suivant :

Il a de plus été compilé avec l'option d'optimisation du compilateur -O (équivalent à O1).

Le compilateur produisant un binaire pour le simulateur SimpleScalar est dans notre cas utilisé de la manière suivante :

```
sslittle-na-sstrix-gcc <source> -o <exe>
```

Dans le cas de SSCA2, exéutez Make dans le répertoire afin de produire un exécutable compréhensible par SimpleScalar.

Vous obtiendrez les pourcentages par la commande suivante² :

```
sim-profile -iclass <exe>
```

Q2 : Quelle catégorie d'instructions nécessiterait une amélioration de performances ?

A2 :

Le profiling d'applications a pour objectif de détecter quelles sont les instructions (et par conséquent les ressources) les plus utilisées lors de l'exécution d'un programme donné sur un microprocesseur donné. Le logiciel **sim-profile** permet d'analyser l'exécution d'un programme et de générer les pourcentages d'utilisation de chaque classe d'instructions.

Pour P1, les instructions de calcul entier prennent près de 80 % des instructions exécutées, ainsi que 8% pour la gestion des branchements. Dans le cas de la convolution de matrices d'entiers, les opérations entre les entiers sont confondus avec les opérations de boucles. En fait, le processeur passe bien plus de temps à gérer les boucles que les accumulations de produits. Ceci est bien mis en évidence avec la version de flottants P2.

=> En l'état, un processeur superscalaire avec plusieurs ALUs pour paralléliser l'exécution des instructions de calcul entier et doté d'un bon prédicteur de branchements pourrait profiter à l'application. Cependant, une optimisation du code au niveau du compilateur et/ou une réécriture du code C afin de réduire cette proportion de calcul entier serait bienvenue dans un premier temps.

La réécriture des boucles pour simplifier le travail des branchements et des calculs des itérateurs a un impact très important sur le nombre total d'instructions exécutées. Cependant, on observe une augmentation des instruction de chargement des données. On compense ainsi une partie des calculs par un flux de mémoire. Le programme n'est plus cpu-bound mais trouve un équilibre qui réduit le temps de traitement du programme (temps d'exécution arrondis sur la sortie de simple-sim).

Solution TD/TP3 : Processeur pipeline – compilateur

Exercice 1 : Pipeline

Identifier toutes les dépendances de données dans le code suivant. Quelles dépendances sont des aléas de données qui seront résolus par *forwarding* ?

add \$2,\$5,\$4

add \$4,\$2,\$5

sw \$5, 100(\$2)

add \$3,\$2,\$4

Vous devez vous appuyer dans votre analyse sur la Figure 20 décrivant le pipeline du processeur.

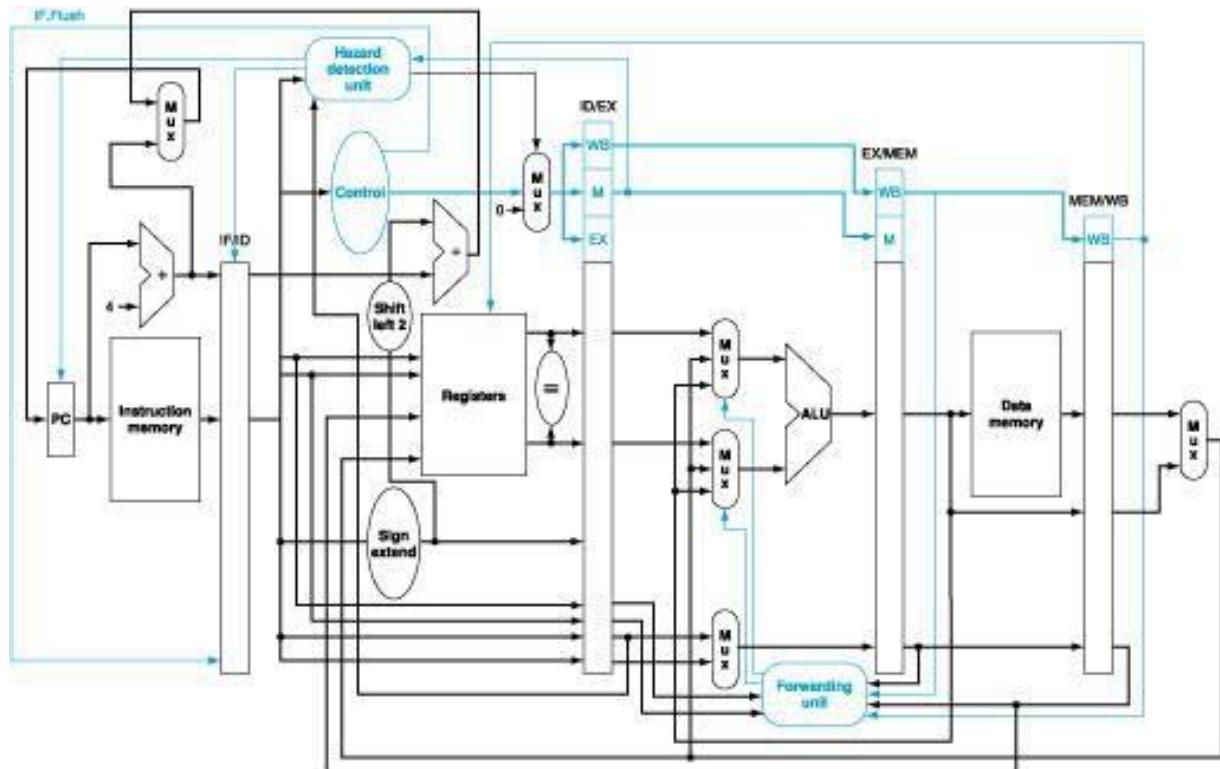


Figure 20 Processeur RISC pipeline 5 étage

Les dépendances de données existent dans les cas suivants :

RAW (Read After Write) : lecture après écriture, c'est-à-dire une instruction lit/utilise une donnée écrite/produite par l'instruction précédente. La manière de détecter cette situation est de rechercher si pour une instruction donnée le registre destination est utilisé en tant que source (opérande) lors des instructions suivantes.

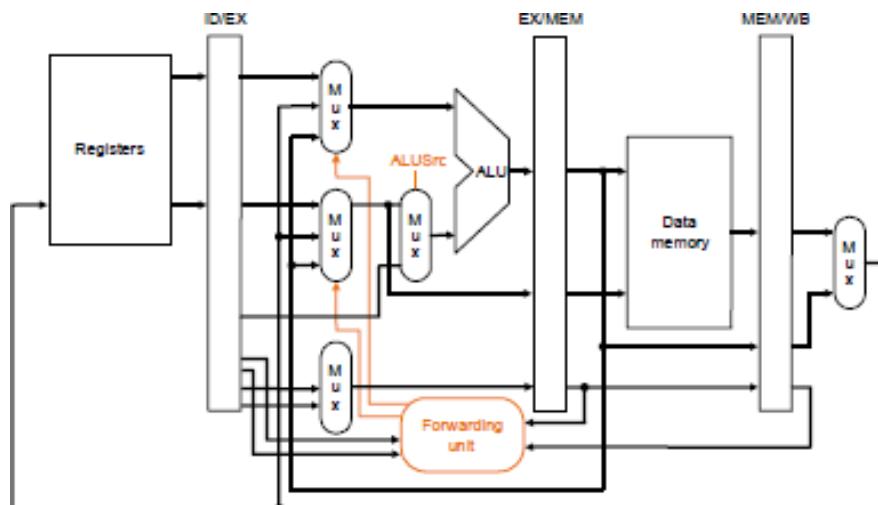
inst1 -> inst2 est une dépendance sur le registre \$2

inst1 -> inst3 est une dépendance sur le registre \$2

inst1 -> inst4 est une dépendance sur le registre \$2

inst2 -> inst4 est une dépendance sur le registre \$4

Le **forwarding** s'applique de la manière suivante :



et donc :

inst1 -> inst2 sera résolue par l'unité de forward lorsque S1 sera dans l'étage MEM et S2 sera dans EX

inst1 -> inst3 sera résolue par l'unité de forward lorsque S1 sera dans l'étage WB et S3 sera dans EX

inst1 -> inst4 sera résolue normalement les données étant présentes dans le banc de registres

inst2 -> inst4 sera résolue par l'unité de forward lorsque S2 sera dans l'étage WB et S4 sera dans l'étage EX

Exercice 2 : Pipeline - Data Forwarding

Nous souhaitons modifier le pipeline du processeur pour lui ajouter 2 nouvelles unités fonctionnelles :

1. Une unité de multiplication
2. Une unité racine carrée

Modifiez le chemin de données du processeur et l'unité de data forwarding pour prendre en compte ces deux nouvelles unités fonctionnelles.

Vous pouvez vous appuyer dans votre analyse sur la Figure 3 décrivant le data forwarding au sein du pipeline du processeur.

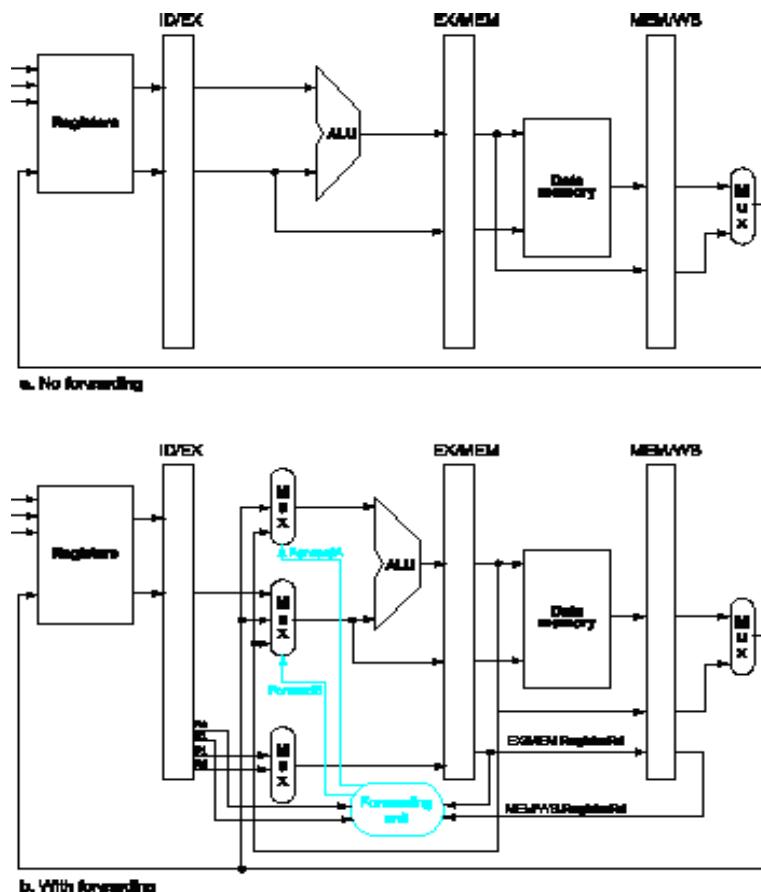
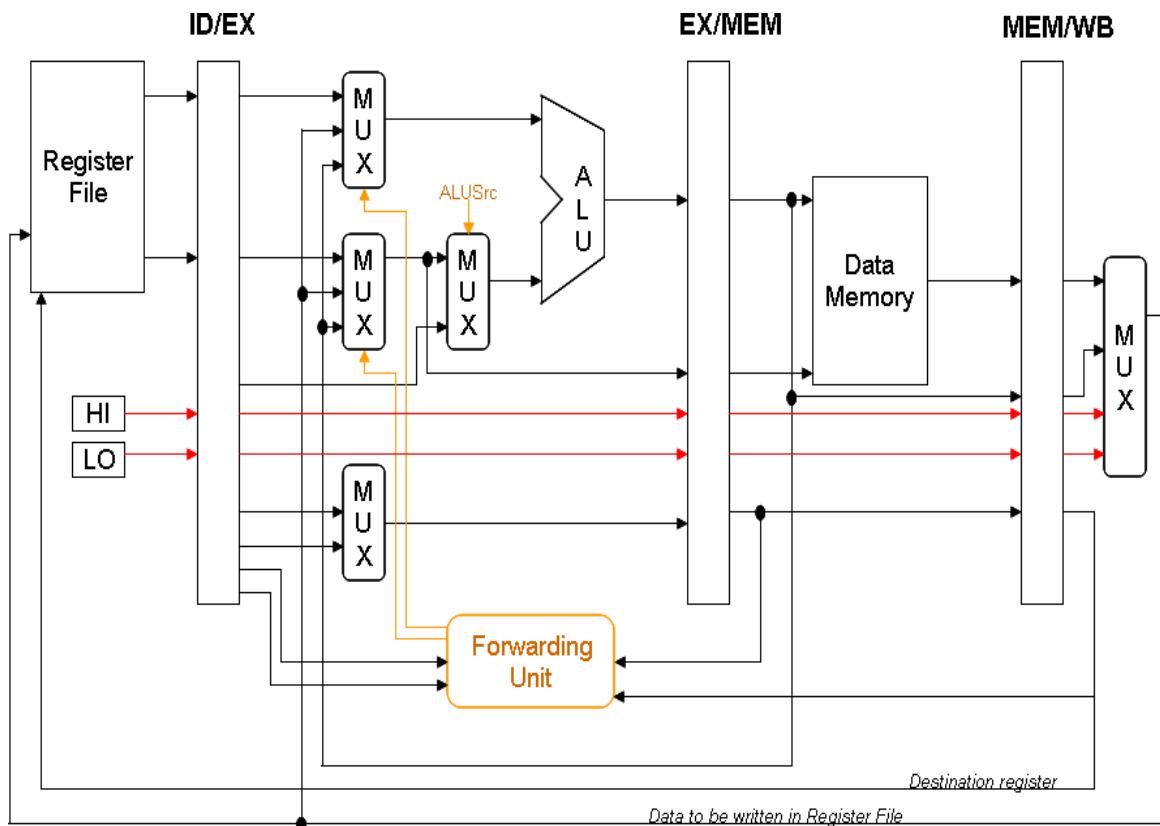


Figure 21 Data forwarding a) No forwarding b) With forwarding

Pour traiter l'unité racine carrée, on définit une nouvelle instruction : **sqrt \$s1, \$s2** dont la signification est : placer la racine carrée du nombre situé dans le registre **\$s2** dans le registre **\$s1**.

Pour la multiplication, les instructions de multiplication sont conservées. La dépendance des données étant détectée par l'égalité des identifiants de registres, l'instruction de multiplication pourra uniquement bénéficier du **forwarding** et n'y contribuera pas, puisque ses registres destination sont implicitement HI et LO, qui ne peuvent être référencés par les autres instructions. Le schéma avant modification est le suivant :



Les modifications principales à appliquer concernent :

- L'ajout des 2 unités racine carrée SQRT et multiplication MUL dont les entrées/sorties sont spécifiées par les instructions associées. Les instructions associées à la multiplication sont définies (Tableau 2 et 3 du polycopié). L'unité SQRT n'étant pas définie, au préalable, une nouvelle instruction est proposée : **sqrt \$s1, \$s2** qui réalise la racine carrée de la valeur existante dans le registre **\$s2** et place le résultat dans le registre **\$s1** (i.e. : $s1 = \text{sqrt}(s2)$). Le codage de cette instruction est du **format I**, avec la partie 16 bits de poids faible inutilisée.
- La connexion des entrées et sorties de ces unités dans l'étage EX et le suivi des sorties à travers les étages MEM et WB jusqu'à l'écriture des résultats dans les registres associés et l'ajout de la connexion à des multiplexeurs éventuels.

- L'ajout des chemins de données permettant le forwarding des données entre les différentes sorties d'unités sur les 2 étages MEM et WB vers les entrées de ces unités
- L'ajout des multiplexeurs permettant de contrôler pour l'unité de data forwarding les bonnes entrées
- L'unité de forwarding est augmentée pour accepter en entrée les numéros de registres destination de MULT (HI & LO)
- L'unité de forwarding est augmentée pour accepter en entrée les codes opérations des instructions relatives à la multiplication pour tenir compte du fait que les registres HI et LO n'apparaissent pas explicitement.

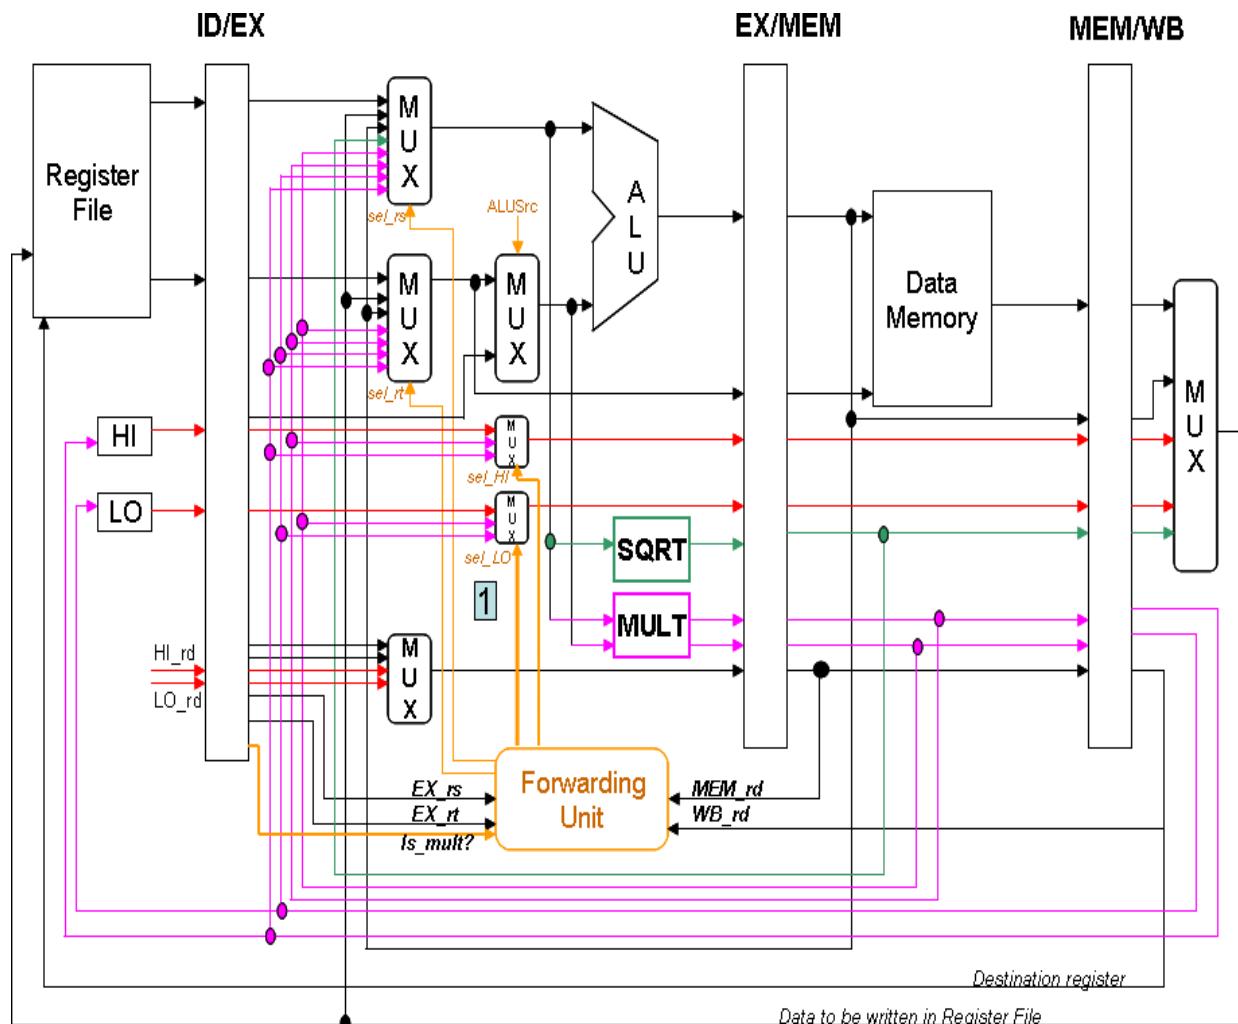


Figure 22 Architecture finale du pipeline

Les codes à vérifier sont les suivants :

Le premier code teste le forwarding entre les instructions de l'ALU et le multiplicateur.

```
add    $s1, $s3, $s8
add    $s2,$s7, $s9
```

```

mul    $s1, $s2
add    $s5, $s5, $s1
add    $s6, $s6, $s2

```

Le code suivant teste les dépendances cachées dues aux registres HI et LO qui n'apparaissent pas de manière explicite dans le codage des instructions :

```

mul    $s1, $s2
mfhi   $s4
mflo   $s5
add    $s3, $s4, $s3
add    $s6, $s6, $s5

```

Ce code fait clairement apparaître le besoin du forwarding des données entre HI et LO et des instructions suivantes et entre **mul** et **mfhi** et **mflo**. Le mécanisme du forwarding étant basé sur la comparaison d'identifiants de registres, le forwarding ne peut tester ce type de dépendances. La seule solution est pour l'unité de forwarding de tester les codes opérations et funct.

Enfin le code suivant :

```

sqrt   $s1, $s2
add    $s4, $s1, $s3
mul    $s1,$s2
mfhi   $s4
mflo   $s5
add    $s3, $s5, $s3

```

teste les trois unités. Le schéma donné ici donne un aperçu sur l'architecture générale. Les opérations **mfhi** et **mflo** transmettent le contenu des registres à travers le pipeline et passent par le **point 1** dans le schéma. Cette transmission à travers le pipeline permet la capture des données et permet du data forwarding.

Exercice 3 : Impact du nombre d'unités fonctionnelles

SimpleScalar s'exécute avec une configuration par défaut d'unités fonctionnelles. Il est possible de spécifier le nombre et le type d'unités fonctionnelles avec les options :

-res : ialu	M	nombre total d'ALUs (unité arithmétique et logique) entière
-res : imult	M	nombre total de multiplicateurs/diviseurs entiers

- res : fpalu** M nombre total d'ALUs flottantes (données de type float)
- res : fpmult** M nombre total de multiplicateurs/diviseurs flottants (données de type float)

Ce nombre total M peut varier de 0 à M où M dans les processeurs actuels ne dépasse pas 8, de manière générale.

Exemple de commande correspondant à une configuration avec 4 ALUs, 1 multiplicateur, 4 ALUs flottantes, 1 multiplicateur flottant :

```
sim-outorder -fetch:ifqsize 4 -decode:width 4 -issue:width 4 -issue:inorder false -commit:width 4 -ruu:size 16 -lsq:size 8 -res:ialu 4 -res:imult 1 -res:memport 2 -res:fpalu 4 -res:fpmult 1 program.ss
```

Du point de vue applicatif, l'étude sera menée sur l'algorithme PageRank, développé par Google comme métrique mesurant l'importance d'une page web [1]. Il s'avère que cette métrique peut également être utilisée dans d'autres types de réseaux (e.g. sociaux) afin de caractériser l'importance relative d'un sommet.

A l'étape initiale, chaque sommet se voit attribuer un rang égal. Chaque sommet recalcule son rang en fonction du rang de ses voisins et de ses degrés entrants/sortants. On considère que l'algorithme a convergé lorsque la variation de rang, d'une itération à l'autre, est inférieur à un seuil (voir [1] pour le détail).

***Q1 :** Analysez le code de l'algorithme PageRank en faisant varier la taille du graph d'entrée (min, med, max) et en faisant varier le nombre d'unités fonctionnelles M de 1 à 8 (1, 2, 4, 8). (Voir annexe « Applications »)*

***Q2 :** Tracez 2 figures indiquant le nombre de cycles et le CPI associés en fonction de la taille du problème traité ($N=\{min, med, max\}$) et des unités fonctionnelles. Quelle est votre analyse ?*

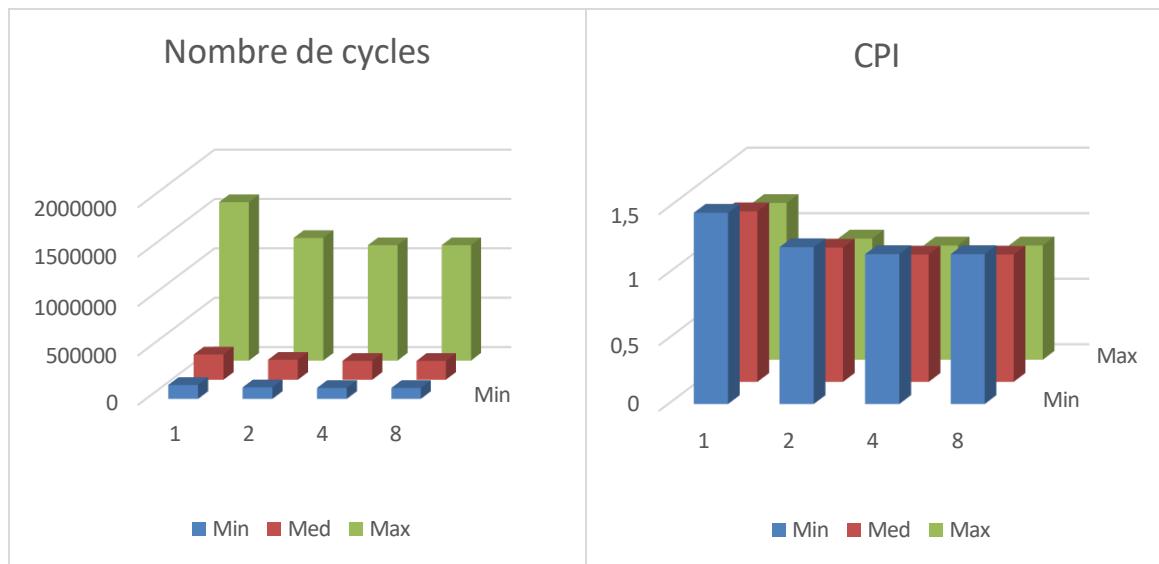


Figure 23 a) Nombre de cycles vs N vs Unités fonctionnelles

b) CPI vs N vs Unités fonctionnelles

A1 et A2 :

On fait varier la taille du graphe d'entrée du programme pagerank en utilisant les programmes suivants : pagerank_<version>.ss, où <version> prend les valeurs suivantes :

- min (plus petit)
- med
- max (plus grand)

Pour le nombre d'unités fonctionnelles, on fait varier le nombre d'ALUs et de multiplicateurs entiers et flottants en même temps.

```
sim-outorder -fetch:ifqsize 4 -decode:width 4 -issue:width 4 -issue:inorder false -commit:width 4
-ruu:size 16 -lsq:size 8 -res:ialu M -res:imult M -res:mimport 2 -res:fpalu M -res:fpmult M
pagerank_<version>.ss
```

où M est le nombre d'unités fonctionnelles.

PR/M	Nombre de cycles			
	1	2	4	8
Min	142k	116k	111k	111k
Med	256k	201k	192k	192k
Max	1603k	1234k	1172k	1172k

Interprétation : Quand on augmente le nombre d'UF, les performances augmentent jusqu'à atteindre un seuil maximal pour nombre d'UF = 4. Le processeur superscalaire n'arrive pas à exploiter efficacement plus de 4 UF parce qu'il manque de parallélisme d'instructions. Ceci est dû à un problème de dimensionnement de l'architecture, puisque la taille du 'fetch queue', 'decode', 'issue' et 'commit buffer' est limité à 4 dans nos paramètres de simulation. Même si l'on augmentait la taille de ces buffers, le gain en performances ne serait pas suffisant pour justifier l'augmentation de la surface du processeur.

Un concepteur d'architecture de processeur doit toujours trouver le seuil optimal qui peut donner la meilleure efficacité surfacique (performance en MOPS / surface en mm²).

N.B : les résultats peuvent varier par rapport au programme que vous exécutez.

Exercice 4 : Exécution dans l'ordre (in-order) VS exécution dans le désordre (out-of-order)

Dans un processeur superscalaire à ré-ordonnancement dynamique des instructions, l'exécution des instructions peut s'effectuer dans le désordre dans l'objectif d'éviter les contraintes artificielles de la séquentialité.

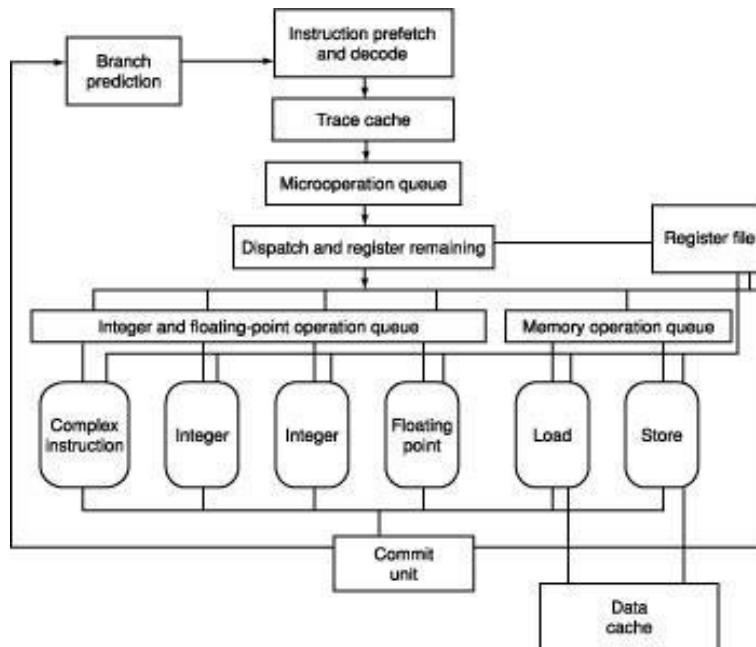


Figure 24 Pipeline d'exécution dans le désordre (out-of-order)

L'exécution d'un programme tel que généré sans optimisations par un compilateur représente l'ordre sémantique normal du programme. Pourtant l'ordre d'exécution des instructions peut être modifié tout en préservant la sémantique. Cette exécution est appelée ***out-of-order exécution***.

Le simulateur **sim-outorder** permet d'exécuter les instructions dans l'ordre ou le désordre (*out-of-order exécution*). Les deux commandes suivantes permettent les 2 possibilités :

- Exécution dans l'ordre : sim-outorder **-issue:inorder true program.ss**
- Exécution dans le désordre : sim-outorder **-issue:inorder false program.ss**

Par défaut le simulateur, ayant un modèle de processeur superscalaire avec ré-ordonnancement dynamique, exécute suivant un mode *out-of-order exécution*.

Q1 : Evaluez l'impact de l'exécution (CPI, nombre de cycles) dans l'ordre par rapport à l'exécution dans le désordre pour l'algorithme PageRank

A1 :

On utilise les paramètres par défaut du simulateur, en faisant varier paramètre **-issue:inorder** uniquement, sur l'application pagerank_med.

In-order VS out-of-order

	In-order	Out-of-order
CPI	1.5470	0.9753
Cycles	192243	304920

Le tableau montre bien une différence de performances de **importante** entre un processeur **superscalaire out-of-order** et un processeur **superscalaire in-order**.

Cela s'explique par le fait que le processeur **superscalaire in-order** n'exploite pas dynamiquement le parallélisme qui existe entre les instructions du code (ILP : Instruction Level Parallelism). Dans le cas d'un **superscalaire in-order**, ce parallélisme n'est analysé que lors de la compilation, contrairement au **superscalaire out-of-order**, qui ainsi exploite mieux les unités fonctionnelles de l'architecture.

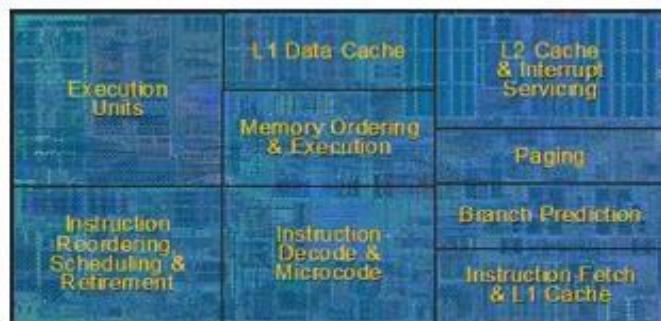
Plus précisément, lorsqu'un aléa a lieu dans le pipeline (aléa structurel, aléa de données), le processeur **superscalaire in-order** est bloqué ('stall' en anglais) jusqu'à ce que la cause de l'aléa ne soit résolue, tandis que le processeur **superscalaire out-of-order** peut exécuter d'autres instructions (indépendantes de celles qui causent l'aléa). Cela augmente la performance globale du processeur.

N.B : les résultats peuvent varier par rapport au programme que vous exécutez.

Solution TD/TP4 : Microprocesseur superscalaire / mémoires caches – Analyse de configurations d'architectures de microprocesseurs

Exercice 1 : Prédiction de branchement

La prédiction de branchement permet aux processeurs d'exécuter un flot d'instructions sans pénalité de blocage dû à l'attente de l'évaluation de la condition de branchement. Tous les microprocesseurs haute-performance incluent une unité de prédiction de branchement. La Figure 6 montre la surface prise par l'unité de prédiction de branchement dans un processeur multi cœur Intel.



Core floorplan with major units highlighted.

Figure 25 Floorplan d'un cœur de processeur Intel

Nous souhaitons dans cet exercice évaluer l'impact de différents mécanismes de prédiction de branchement sur le CPI et le nombre de cycles pour 2 applications :

1. La fonction de hachage SHA-1 ([7] [9]). Voir l'annexe « Applications ».
2. L'algorithme de calcul de la centralité d'intermédiaire (Betweenness Centrality Score / BCS) dans la suite SSCA2 [TP2.1], se référer à l'annexe « Applications ».

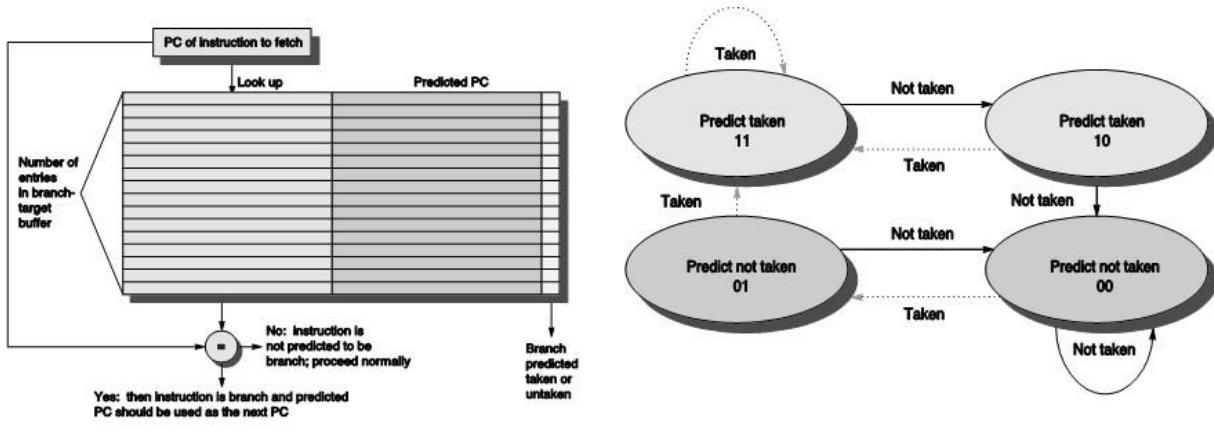
Les mécanismes de prédiction que nous souhaitons comparer sont les suivants :

- **nottaken** : ce mécanisme de prédiction de branchement statique considère toujours que le branchement n'est pas pris
- **taken** : ce mécanisme de prédiction de branchement statique considère toujours que le branchement est pris
- **perfect** : ce prédicteur « virtuel » représente la prédiction parfaite
- **bimod** : le prédicteur de branchement bimodal utilise un BTB (Branch Target Buffer) avec compteurs à 2 bits
- **2lev** : prédicteur de branchement adaptatif à 2-niveaux

Vous pouvez spécifier en utilisant le simulateur SimpleScalar le mécanisme de prédiction de branchement de votre choix en utilisant la commande suivante :

```
sim-outorder -bpred <type> <prog>.ss [options]
```

La documentation de SimpleScalar précise les détails pour les différents mécanismes de prédition de branchement. La Figure 7 et la Figure 8 décrivent 2 types de prédicteurs de branchement, et la Figure 9 décrit les différents paramètres en entrée pour le prédicteur de branchement de SimpleScalar.



© 2003 Elsevier Science (USA). All rights reserved.

© 2003 Elsevier Science (USA). All rights reserved.

Figure 27 Le prédicteur de branchement bimodal

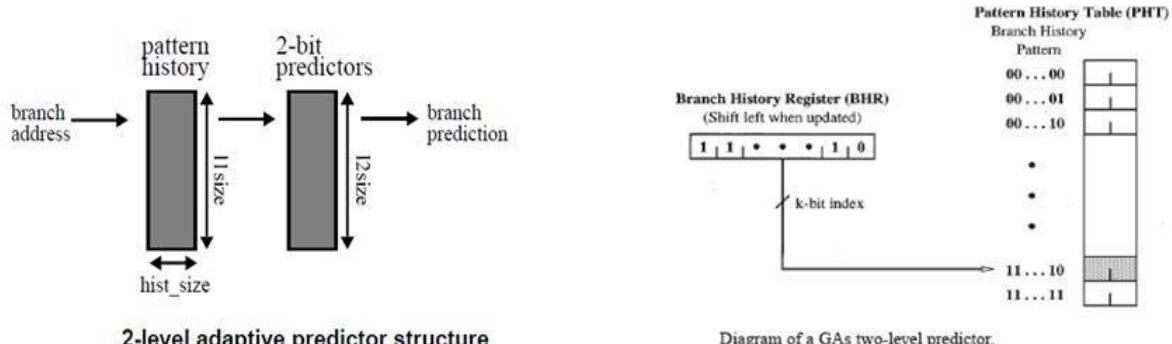


Figure 26 Le prédicteur de branchement adaptatif à 2-niveaux

Tableau 15 Paramètres du prédicteur de branchement

predictor	l1_size	hist_size	l2_size	xor
GAg	1	W	2^W	0
GAp	1	W	$>2^W$	0
PAg	N	W	2^W	0
PAp	N	W	2^{N+W}	0
gshare	1	W	2^W	1

Branch predictor parameters

On utilise les paramètres par défaut du simulateur, en faisant varier le paramètre `-bpred:<type>` uniquement.

Prédicteur de branchement pour SHA-1

	Not-taken	Taken	Perfect	Bimod	2lev
CPI	0.6815	0.6815	0.3521	0.3681	0.3683
Cycles	10068798	10068408	5202419	5438930	5441322

Le tableau montre que les prédicteurs de branchement **dynamiques (bimod et 2lev)** sont beaucoup plus performants que les prédicteurs de branchement **statiques (not-taken et taken)**, et sont très proches du seuil maximal d'un prédicteur de branchement **idéal** (perfect), qui bien évidemment n'existe pas en pratique.

On constate aussi que le prédicteur de branchement **bimod** est vraisemblablement plus efficace que **2lev**, puisque le surcout surfacique du prédicteur 2lev est plus important que celui du bimod (plus de mémoire pour stocker les tableaux), pour une augmentation de performances très relative.

N.B : les résultats peuvent varier par rapport au programme que vous exécutez.

Exercice 2 : Impact de la fenêtre d'instructions RUU

Le modèle d'exécution superscalaire de SimpleScalar utilise un mécanisme de ré-ordonnancement basé sur une partie centrale : la RUU (Register Update Unit).

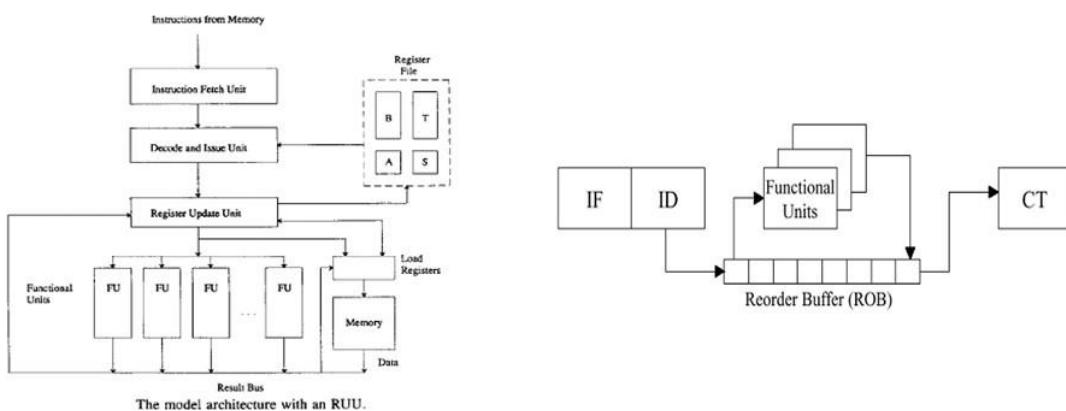


Figure 28 Register Update Unit (RUU)

L'augmentation de la taille de la RUU permet à priori de considérer davantage d'instructions potentielles pour l'exécution. Nous souhaitons analyser l'impact de cette taille sur le CPI.

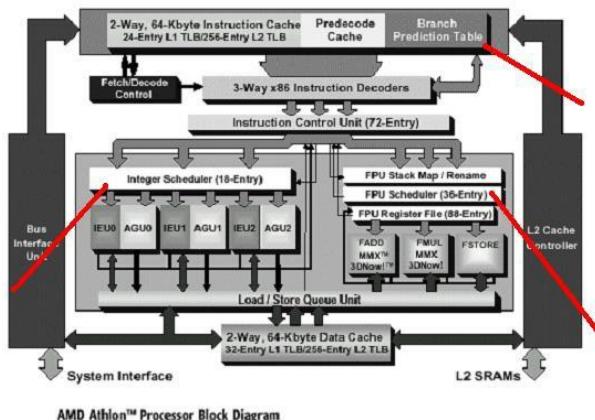


Figure 29 AMD Athlon Processor Block Diagram

Q1 : Faites varier la taille de la RUU de 16 à 128 et évaluez l'impact sur le CPI et le nombre de cycles sur une application de votre choix.

A1 :

On utilise les paramètres par défaut du simulateur, en faisant varier le paramètre `-ruu:size <int>` uniquement.

Register Update Unit (RUU) pour SHA-1

	RUU=16	RUU=32	RUU=64	RUU=128
CPI	0.3681	0.3470	0.3426	0.3423
Cycles	5438930	5126270	5061994	5057066

Le tableau montre que de meilleures performances en faisant augmenter la taille de la RUU, mais que le coût de cette amélioration ne justifie pas non plus le gain obtenu au-delà de RUU=32.

Pour cette application, il n'y a aucun intérêt à augmenter davantage la taille de la RUU (au-delà de 32), puisque le processeur superscalaire n'arrive pas à trouver un nombre suffisant d'instructions indépendantes à exécuter dans le désordre.

N.B : les résultats peuvent varier par rapport au programme que vous exécutez.

Exercice 3 : Mémoires caches - Evaluation des performances de différentes configurations de mémoires caches (instructions et données) pour 4 algorithmes de multiplication de matrices.

De nombreuses applications informatiques dans différents domaines font appel à des opérations sur des matrices, et en particulier la multiplication de matrices. Cette opération classique peut être répétée de nombreuses fois au cours de l'exécution de ces applications et il est donc primordial que ses performances soient optimisées. La multiplication de matrices sur des matrices de dimensions importantes est une opération dont la performance en temps d'exécution dépend beaucoup des performances de la hiérarchie mémoire, et notamment l'organisation des caches du microprocesseur sur lequel elle s'exécute. Le taux de défauts de caches (**miss rate**), qui est le rapport entre le nombre d'accès à un cache qui se traduisent par un défaut de cache (**cache miss**) sur le nombre total d'accès au cache, est le paramètre principal pour évaluer cette performance. Nous considérons ici des microprocesseurs ayant des caches d'instructions et de données séparés. De ce fait, le miss rate du cache d'instructions et du cache de données méritent une analyse.

Un simulateur de cache, comme **sim-cache (Annexe 1)**, permet d'effectuer une évaluation du miss rate pour une configuration de caches particulière et pour un programme en entrée. Lorsque l'on souhaite évaluer plusieurs configurations de caches il est alors nécessaire d'effectuer autant de simulations. Ce processus se répète pour le nombre de programmes que l'on considère en entrée.

Travail demandé

Nous considérons les 2 organisations de caches décrites dans le Tableau 7. On supposera que l'algorithme de remplacement est LRU pour toutes les configurations.

Tableau 16 Configurations de caches pour 2 processeurs

Configuration	Instruction cache	Data cache	L2 cache	Block size (bytes)
C1	4KB direct-mapped	4KB direct-mapped	32KB direct-mapped	32
C2	4KB direct-mapped	4KB 2-way set-asso	32KB 4-way set-asso	32

Q1 : Pour chacune des 2 configurations de mémoires cache, complétez le Tableau 8. Pour cela, vous devez déterminer les paramètres d'entrée du simulateur de cache « *sim_cache* » de SimpleScalar.

Tableau 17 Paramètres de sim-outorder pour chaque configuration

Configuration	IL1	DL1	UL2
C1	il1:128:32:1:l	dl1:128:32:1:l	ul2:1024:32:1:l
C2	il1:128:32:1:l	dl1:64:32:2:l	ul2:256:32:4:l

Q2 : Complétez les Tableau 9, Tableau 10 et Tableau 11. Pour cela vous devez simuler à l'aide de **sim-cache** les différentes configurations et collecter les informations suivantes :

- Le taux de défauts dans le cache d'instructions il1 : **il1.miss_rate**
- Le taux de défauts dans le cache de données dl1 : **dl1.miss_rate**
- Le taux de défauts dans le cache unifié (L2) ul2 : **ul2.miss_rate**

A2 :

Dans cet exercice, on modélise une hiérarchie mémoire de 2 niveaux, constituée d'un cache L1 d'instructions et de données séparés, et d'un cache L2 partagé par les 2 caches L1, et qui est relié à une mémoire externe de taille supposée infinie.

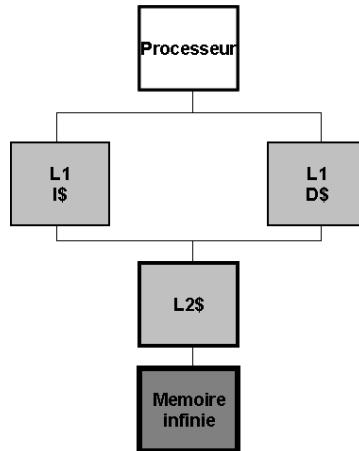


Figure 30 Hiérarchie mémoire vue du processeur

Le code pour les 4 algorithmes de matrices se trouve dans :

`/usr/ensta/pack/simplescalar-2.0/simplescalar-4.0/mase/matrix/<algo>.ss`

Où <algo> = **normale, pointeur, tempo, unr0l**

Vous pouvez consulter également le fichier source `<algo>.c` correspondant pour comparer les 4 algorithmes de multiplication de matrices.

La commande pour exécuter un programme avec la configuration de cache C1 est :

```
sim-cache -cache:il1 il1:128:32:1:l -cache:dl1 dl1:128:32:1:l -cache:il2 dl2 -cache:dl2 ul2:1024:32:1:l
/usr/ensta/pack/simplescalar-2.0/simplescalar-4.0/mase/matrix/<algo>.ss
```

La commande pour exécuter un programme avec la configuration de cache C2 est :

```
sim-cache -cache:il1 il1:128:32:1:l -cache:dl1 dl1:64:32:2:l -cache:il2 dl2 -cache:dl2 ul2:256:32:4:l
/usr/ensta/pack/simplescalar-2.0/simplescalar-4.0/mase/matrix/<algo>.ss
```

Les résultats de performances des caches pour les 4 algorithmes sont :

Tableau 18 Instruction Cache (il1) Miss Rate

Programmes	<i>Configurations de caches</i>	
	C1	C2
P1 (normale)	0.0%	0.0%
P2 (pointeur)	0.01%	0.01%
P3 (tempo)	0.0%	0.0%
P4 (unrol)	0.0%	0.0%

Tableau 19 Data Cache (dl1) Miss Rate

Programmes	<i>Configurations de caches</i>	
	C1	C2
P1 (normale)	3.67%	3.38%
P2 (pointeur)	4.13%	4.00%
P3 (tempo)	4.41%	4.27%
P4 (unrol)	5.12%	4.96%

Tableau 20 Unified Cache (ul2) Miss Rate

Programmes	<i>Configurations de caches</i>	
	C1	C2
P1 (normale)	41.88%	40.42%
P2 (pointeur)	44.14%	40.17%
P3 (tempo)	44.13%	40.17%
P4 (unrol)	44.18%	40.17%

Q3 : *Les 4 algorithmes de multiplication de matrices présentent-ils une bonne localité de références pour le code ? Pourquoi ?*

A3 :

Interprétation :

Au début de la simulation, le code et les données des programmes sont dans la mémoire externe. Les premiers accès à la mémoire (cold miss) engendrent des caches miss au niveau L2 et L1.

L1 I\$: le miss rate du cache d'instructions L1 est négligeable, ce qui signifie que la taille du code pour les 4 algorithmes peut tenir dans un cache de 4KB direct-mapped sans aucun impact sur les performances.

L1 D\$: le miss rate du cache de données L1 pour la configuration C1 (direct-mapped) est plus élevé que celui de C2 (2-way set associative). Ceci s'explique par le fait qu'en augmentant l'associativité du cache, le miss rate du cache de données diminue => moins d'accès au cache L2 => moins de blocages du processeur dus à la latence de la mémoire. L'algorithme de multiplication 'normale' présente la meilleure localité de référence, puisqu'il a le moins de miss rate.

L2\$: de la même manière, l'augmentation de l'associativité du cache en C2 diminue le miss rate => moins d'accès à la mémoire externe qui est pénalisante (de l'ordre de 100 cycles).

Le miss rate du cache L2 est élevé (> 40%). Cela montre que le cache L2 n'est pas bien dimensionné et qu'un cache de plus grande taille paraît judicieux pour ces 4 algorithmes de multiplication.

Solution TD/TP6 : Microprocesseurs et Energie



Exercice 1 : Lois Physiques Energie – Puissance

Q1 : 2 milliards de téléphones portables dans le monde avec des utilisations en mode idle

A1. Prenons pour l'exemple le smartphone cité en référence, dont la consommation « idle » est de l'ordre de 70mW

$$2.10^9 \times 70\text{mW} \approx 140\text{MW}$$

(17+ Cray Titan, 140+ Bugatti Veyron)

$$140\text{MW} \times 365 \times 24 = 1.2\text{TWh par an}$$

(Si tous les téléphones étaient en idle pendant l'année)

Q2 : 2 milliards de téléphones portables dans le monde avec des utilisations en mode actif

A2. Prenons le même exemple : la consommation « active » est en moyenne de l'ordre de 2W.

$$2.10^9 \times 2\text{W} = 4\text{GW}$$

(30+ Genève / 8000 Eoliennes / 2+ tranches de réacteur IV)

$$4\text{GW} \times 365 \times 24 = 35\text{TWh par an}$$

(Si tous les téléphones étaient actifs pendant l'année).

Q3 : consommation équivalente en éoliennes

A3. En se basant sur un modèle « gros grain » d'utilisation 50% idle / 50% actif, on obtiendrait en moyenne :

$$\frac{35}{2} + \frac{4}{2} = \frac{39}{2} = 19.5\text{GW}$$

88/132

2 2

$= 19.5TWh$



1 éolienne (40m / 43km/h) = 500kW Pnominal

En France : 15.9 TWh (2012), il faudrait environ 1.22 fois la production éolienne équivalente en France pour produire l'énergie nécessaire à l'ensemble des smartphones.

Notes : 15.9TWh, soit 1.81GW Pnominal (au lieu des 8 GW), rendement « faible »

Q4 : consommation équivalente en champ solaires



A4. En France : 4.9 TWh (2013) sont produit par champ solaire, il faudrait donc environ 4 fois la production solaire française pour produire l'énergie nécessaire à l'ensemble des smartphones.

Notes : 4.9TWh produit en 2013 équivaut à une installation « parfaite » de 560 MWc (au lieu des 4.7 GWc installés).

Notes : Le plus grand champ solaire du monde : 1 GWc théorique, en Chine pour 2020 (en 2014, 540MWc). Il est à noter que les champs solaires ne sont qu'une manière d'exploiter l'énergie solaire (solaire thermique/thermodynamique)

Remarques générales & ordres de grandeurs :

Puissance :

- Cortex A9 @1GHz = 1W
- Intel Core i5-6440HQ @ 2.60GHz = 45W
- Intel Xeon X7460 @ 2.66Ghz = 130W
- Radiateur sèche serviette = 500W-2kW
- Saab 9-3 Aero (MY06) = 191 kW (260cv)
- Koenigsegg One :1 = 1MW (1360cv)
- Cray Titan = 8.2 MW
- Ville de Genève = 150 MW
- LHC (CERN) = 220-300 MW
- Tranche EPR Gen. IV = 1-1.5 GW
- Data centers = 30 GW
- Puissance peak EDF = 136 GW

$$\text{-} \quad \text{Laser BELLA (Thales)} \quad = \quad 1 \text{ PW}$$

On se méfiera tout de même, et d'une manière générale, des seuls chiffres de puissance (notamment pour l'éolien/le solaire). On mettra plutôt en perspective ces valeurs en termes de Wattheures produit par an ou bien de W/m² pour le solaire qui sont des métriques intéressantes car elles permettent d'apprécier le rendement de production (ou surfacique). Par exemple pour l'éolien français, la puissance nominale des installations comparée à la puissance effectivement délivrée nous donne un rendement de l'ordre de 20%, relativement faible ($\mu = P_{\text{prod}}/P_{\text{nom}}$).

De même, le modèle « gros grain » 50/50 utilisée pour le calcul de l'énergie utilisée par les smartphones sur un an part du principe que le téléphone n'est actif que 50% du temps... or ce modèle n'est pas réaliste. La complexité logicielle de ces systèmes ne facilite pas l'identification d'un modèle de consommation précis (recherche d'un réseau Wi-Fi /GSM en permanence, Mise à jour de l'OS/des applications en tâche de fond, etc...). De plus, la variabilité des usages d'un smartphone rendrait un tel modèle non-nécessairement applicable à tous les utilisateurs finaux. Il faudrait donc arriver à composer un modèle tenant compte des différences architecturales, logicielles et d'utilisation des smartphones.

Tous ces calculs nous amènent à la conclusion que le moindre pourcent d'économie d'énergie qu'il est possible de gagner sur des systèmes tels que les smartphones (qui embarquent de plus en plus les mêmes processeurs/capteurs) sont bons à prendre à l'échelle du milliard de « devices » → 1% * 19.5 TWh = 195 GWh (22MW), soit l'équivalent de la consommation électrique sur un an d'une petite ville de 30 000 habitants...

Consommation moyenne / habitants : (FR-2011) : 7MWh (800W) / (INT-2012) : 3MWh (350W)

Consommation mondiale d'électricité en 2012 : environ 20 PWh

Production mondiale annuelle d'électricité : quelques dizaines de PWh... (Production totale d'énergie : 184000 PWh)

Data centers : 30 GW / 263 TWh ...

Exercice 2 : Mode de gestion de l'énergie des microprocesseurs (ARM) et FSM

Q1. Citer 3 méthodes matérielles pour réduire la consommation énergétique dans les multi-cœurs

1/Clock gating: Couper l'horloge dans certaines parties des cœurs.

2/Power gating: Extinction de certaines parties des cœurs.

3/Dynamic Voltage Frequency Scaling (DVFS): Ajustement de la fréquence/tension dynamiquement.

Q2. Pour chaque méthode, quelles sont les implications énergétiques ? (Statique, dynamique, surface, timing) Faire un tableau de comparaison

	Energie Statique	Energie Dynamique	Surface	Timing
Clock Gating	Pas de changements	Pas d'énergie dynamique consommée	Augmentation légère de la surface	Overhead : temps d'établissement de la clock
Power Gating	Pas d'énergie statique consommée	Pas d'énergie dynamique consommée	20 % à 30 % de plus en cas de registres + surface des interconnexions	Temps de sauvegarde avant extinction et temps de backup au réveil sur les données volatiles
DVFS	Réduction adaptable	Réduction adaptable	Module de gestion voltage/fréquence à ajouter (faible surface)	Temps d'établissement de la clock en cas de changement.

Q3. Dans la documentation cortex A9, quelles sont les techniques mises en œuvre et comment le sont-elles ?

Voir (2.4) dans la Technical Reference Manual du Cortex A9 :

<http://infocenter.arm.com/help/index.jsp?topic=/com.arm.doc.ddi0388i/index.html>

Par exemple 2.4.3: Power Gating « The Cortex-A9 uniprocessor contains optional placeholders between the Cortex-A9 logic and RAM arrays, or between the Cortex-A9 logic and the NEON SIMD logic, when NEON is present, so that these parts can be implemented in different voltage domains. »

Exercice 3 : Microélectronique

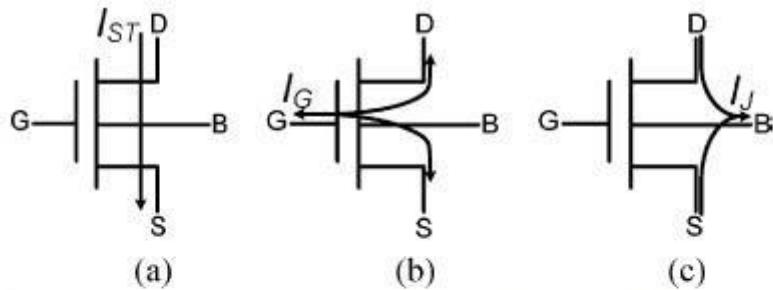


Fig. 2. NMOS transistor current contributions in subthreshold. (a) Subthreshold current. (b) Gate current. (c) Junction current.

TABLE I
NMOS/PMOS TRANSISTOR PARAMETERS (65-NM, STD- V_{TH}) [17]

	n	I_0 [A]	V_{TH0} [V]	λ_{DS}	λ_{BS}
NMOS	1.39	6.65E-5	0.598	9.0E-2	9.9E-2
PMOS	1.27	5.95E-6	0.532	8.0E-2	1.1E-1

Q1 : Technologie actuelle / combien de transistors / consommation / surface dans un processeur récent ?

A1. Quelques milliards de transistors (2014):

Intel Core-M family : 14nm (1,300,000,000 t) / 30x16.5 mm² / 4.5 Watts (TDP) / 1.2-2.9 GHz.

Intel i7 family : 22nm (1,400,000,000 t) / 52.5x45 mm² / 130 Watts (TDP) / 3.6-4.0 GHz.

Q2 : Qu'est-ce que la conduction en régime de faible inversion et pourquoi est-ce utilisé ? Principaux "tuning knobs" accessibles ?

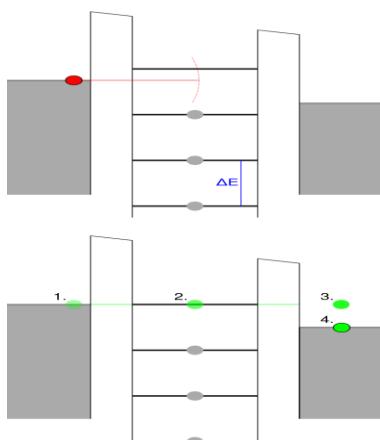
« Subthreshold conduction » ou « fait conduire » un transistor sous V_{th} . Le canal n'est pas formé au sens strict du terme comme en forte inversion, mais un courant de diffusion, fonction de V_{ds} traverse le transistor. Ce régime de faible inversion est intéressant car il expose une transconductance très élevée (mais importante influence du process de fabrication et des défauts).

Tuning Knobs :

Le facteur de forme du transistor : W/L . Si l'on augmente W , V_{th} peut augmenter (RNCE) ce qui rend le courant plus sensible aux variations de W pour les transistors « fins » (on augmentera plutôt L : RSCE, détérioration de V_{th}).

De fait, V_{th} est aussi un paramètre important. Mais toutes ces caractéristiques sont déterminées par le designer du circuit... (Autres facteurs : polarisation du substrat (V_{bb}),

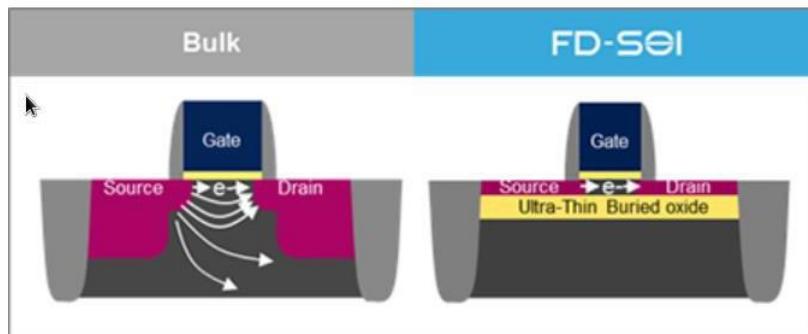
Q3 (opt.) : Quels sont les effets les plus pénalisants pour le transistor MOS ?



- μ (pondération par champ vertical/horizontal de la mobilité des porteurs)
- d (pondération du courant par non-uniformité du substrat)
- dC/C Augmentation de Cox par déplétion de la grille
- vL saturation en vitesse des porteurs
- DIBL diminution de v_{th} par effet de drain
- Perçage passage de courant dans le substrat hors contrôle de la grille
- R résistance série du transistor
- I_{sub} courant de substrat
- NPN Effet du transistor NPN parasite

Remarques

Lien Design/Puissance : $P = \frac{1}{2}V^2Cf$ / Static : $I_{leak} \propto \frac{W}{L}$



FDSOI (rajout d'un film pour isoler le canal du bulk: DIBL réduit, effet parasite du substrat réduit + meilleur contrôle du transistor) vs. ThinFET (faire ressortir la grille en surface pour une meilleure isolation des parasites du substrat/drain)

SET – Single Electron Transistors

Transistor ambipolaire, contrôle du courant à l'électron près : électronique TRES low-power. Dimensions nanométriques (« Coulomb Island » de quelques nm), donc très fort potentiel d'intégration. Courant de commande très faible, sensible aux perturbations électromagnétiques. Température de fonctionnement très basse...

Exercice 4 : Evaluation de performances – MPACT

On recherche à optimiser le processeur choisi, afin de réduire la consommation énergétique globale du système. Dans ce cas d'étude, nous nous intéressons à l'intérêt d'avoir une unité flottante dans le processeur. Le cas d'étude s'appuie sur les applications ftt et susan (du benchmark miBench) sur un processeur de type ARM cortex A9. Pour avoir les informations de performance, le simulateur Gem5 est utilisé. Celui-ci est « connecté » à l'outil McPat permettant d'avoir les informations de surface et consommation énergétique du processeur.

Commandes utiles :

```
export HOME_TOOLS=/home/c/nom-mdc/ES201/tools/TP6/tools/
cp -r=/home/c/nom-mdc/ES201/tools/TP6/bin/ /your/path/ cd /your/path/bin/<app>
$HOME_TOOLS/run_all.sh -b <app> (-f pour floating point)
```

Q1 Simuler PageRank et SSCA2 avec et sans l'extension Floating point. Lancer le simulateur et l'émulateur énergétique. Quel est l'accélération à utiliser l'unité flottante ? Y a-t-il un gain énergétique ? Regarder dans m5out/.xml et m5out/*.xml_simple*

SSCA2	PageRank
Basic 0.000267324201618375 J in 0.00209697125 sec core_area 0.759698 mm^2 core_leakage 0.012725105 W core_runtime_dynamic 0.039784 W core_energy 0.000110110083548231 J	Basic 0.000199285153215875 J in 0.00157287875 sec core_area 0.759698 mm^2 core_leakage 0.012725105 W core_runtime_dynamic 0.0395964 W core_energy 8.22953833825187e-05 J
fpu 0.00024410315597925 J in 0.0018347675 sec core_area 1.43199 mm^2 core_leakage 0.01859642 W core_runtime_dynamic 0.0393282 W core_energy 0.00010627821022585 J	fpu 0.000140310721439 J in 0.00107046625 sec core_area 1.43199 mm^2 core_leakage 0.01859642 W core_runtime_dynamic 0.0378871 W core_energy 6.04637018412e-05 J

(résultat d'énergie et de surface comprenant le cœur et le cache L1)

	SSCA2	Pagerank
Speedup	1.1430	1.4693
Energy gain	1.0951	1.4250

Q2 Quelle est votre analyse pour chaque application ?

Dans le cas de PageRank, l'ajout d'une FPU fait sens dans la mesure où les performances en termes d'exécutions sont largement améliorées (47% en temps d'exécution et 43% en efficacité énergétique). Dans le cas de Susan, les performances sont améliorées bien plus légèrement.

Etant donné l'important gain en termes de surface utilisé lors de l'ajout d'une FPU, ainsi que le leakage occasionné par l'ajout d'une FPU, la décision de l'ajout ou non d'une FPU au système doit se faire en tenant compte d'autres critères : variétés d'applications utilisées, caractérisation du profil d'utilisation (si le système reste très souvent au repos, le leakage important avec une FPU risque de se révéler pénalisant par exemple) contraintes temporelles et/ou spatiales.

Q3 Si les 2 applications doivent tourner sur la même plateforme quelles méthodes peut-on employer pour réduire l'énergie ? Proposer des idées dans le cadre d'un mono-cœur et d'un multi-cœur. Les solutions de l'exercice 1 sont-elles utilisables ?

On peut utiliser le power gating autour de la FPU dans un mono cœur afin de couper l'extension quand on ne s'en sert pas (le clock gating ne sert pas, car les registres flottant continuent à dissiper de l'énergie statique, l'impact sera moindre). Le DVFS ne résout pas la question de l'utilisation ou non des extensions.

Dans un multi-cœur, il existe un type de plateforme dite « asymétrique » où les extensions ne sont mises que sur certains cores. (cf. Article d'intel: <http://www.neotextus.net/wp-content/uploads/2013/03/hpca10.pdf>, thèse d'Alexandre AMINOT).

Hors-Programme - Pour aller plus loin...

Compilateur - analyse de dépendances

Déterminer les dépendances dans les boucles de code en se basant sur l'hypothèse que les indices de tableaux ont des formes affines ($a * i + b$) où a et b sont des constantes et i est l'index de boucle. Déterminer s'il existe une dépendance entre 2 références au même tableau dans une boucle est équivalent à déterminer si 2 fonctions affines peuvent avoir la même valeur pour des indices différents dans l'intervalle de valeur de l'indice de boucle.

Un test simple et suffisant pour détecter l'absence de dépendances est le PGCD. Le test est basé sur l'observation que si une dépendance à travers une boucle (loop-carried dependence) existe alors le $\text{PGCD}(c,a)$ doit diviser $(d - b)$. Le test du PGCD est suffisant pour garantir qu'aucune dépendance n'existe.

Déterminer pour la boucle suivante s'il existe une dépendance entre les variables du tableau.

```
for(i = 1 ; i <= 1000 ; i = i +1) {
    x[2*i + 3] = x[2* i] + 5.0;
}
a*i + b = 2*i + 3 => a = 2, b = 3
c*i + d = 2*i => c = 2 , d = 0
pgcd(c,a) = pgcd (2,2) = 2 ne divise pas (d- b) = -3. Donc il n'existe pas de dépendance entre 2*i + 3 et 2*i.
```

Impact du ré-ordonnancement de code - Loop unrolling

Une technique utilisée par les compilateurs pour améliorer les performances de programmes s'exécutant sur des processeurs avec une structure pipeline consiste à déplier (**unroll**) des boucles de code (**loop unrolling**). Le principe général est simple et consiste donc à dupliquer le corps de la boucle.

Considérons l'exemple suivant :

```
for(i = 1000 ; i > 0 ; i = i -1)
    x[i] = x[i] + s;
```

Dans cet exemple, un dépliage de niveau 5 donnerait :

```
for(i = 1000 ; i > 0 ; i = i - 5)
{
    x[i] = x[i] + s;
    x[i-1] = x[i-1] + s;
    x[i-2] = x[i-2] + s;
    x[i-3] = x[i-3] + s;
    x[i-4] = x[i-4] + s;
}
```

Q1 : Codez en assembleur la boucle initiale et estimez le nombre de cycles nécessaires à son exécution pour le pipeline du processeur.

A1 :

Supposons que \$s3 contienne l'adresse de x[1000]

```

addi    $s2, $zero, 1000      // initialisation de l'indice de boucle
start :
lw      $s1,0($s3)          // lecture donnée en mémoire
addi    $s1,$s1,s            // ajout de la constante s
sw      $s1,0($s3)          // écriture et mise à jour en mémoire
subi    $s3,$s3,4            // passage à l'élément suivant dans le tableau
subi    $s2,$s2,1            // mise à jour de l'indice de boucle
bne    $s2,$zero, start     // passage à l'itération suivante

```

Estimation du nombre de cycles :

Soit N le nombre d'instructions à exécuter dans un pipeline de processeur à M étages.

=> le nombre de cycles nécessaires à l'exécution sans aléas est : **M + N - 1**

Le nombre d'instructions de ce programme est :

N = 1 + [nombre d'itérations] * [nombre d'instructions dans la boucle]

=> **N = 1 + [1000] * [6] = 6001 instructions**

Le nombre de cycles nécessaires à l'exécution est :

[Nombre de cycles sans aléas] + [nombre de cycles dus aux aléas]

=> **[M + N - 1] + [nombre de cycles dus aux instructions de branchements + nombre de cycles dus aux aléas de dépendances]**

=> **[5 + 6001 - 1] + [999 * 2] + [1000 * 1]**

En effet, chaque branchement sauf le dernier générera une pénalité de 2 cycles (bne \$s2, \$zero, start), puisque le branchement est exécuté dans l'étage EX et donc les 2 instructions qui le suivent sont fetchées (i.e. ces instructions avancent au début du pipeline, dans IF puis ID). Ces 2 instructions seront donc annulées à cause du branchement.

Enfin, il existe une dépendance entre lw \$s1,0(\$s3) et addi \$s1,\$s1,s qui est non résolue par **forwarding**, obligeant le pipeline à une pénalité de 1 cycle.

Le nombre total de cycles est donc :

[5 + 6001 - 1] + [999 * 2] + [1000 * 1] = 9003 cycles.

Q2 : Codez en assembleur la boucle dépliée et estimez le nombre de cycles nécessaires à son exécution pour le pipeline du processeur.

A2 :

Supposons que \$s3 contienne l'adresse de x[1000]

addi \$s2,\$zero, 1000 // initialisation de l'indice de boucle.

start :

//----- // iteration i

lw \$s1,0(\$s3)

addi \$s1,\$s1,s

sw \$s1,0(\$s3)

subi \$s3,\$s3,4

//-----// iteration i+1

lw \$s1,0(\$s3)

addi \$s1,\$s1,s

sw \$s1,0(\$s3)

subi \$s3,\$s3,4

//-----// iteration i+2

lw \$s1,0(\$s3)

addi \$s1,\$s1,s

sw \$s1,0(\$s3)

subi \$s3,\$s3,4

//-----// iteration i+3

lw \$s1,0(\$s3)

addi \$s1,\$s1,s

sw \$s1,0(\$s3)

subi \$s3,\$s3,4

//-----// iteration i+4

lw \$s1,0(\$s3)

addi \$s1,\$s1,s

sw \$s1,0(\$s3)

subi \$s3,\$s3,4

//-----

subi \$s2,\$s2,5 // mise à jour de l'indice de boucle

bne \$s2,\$zero, start

Le nombre total d'instructions du corps de la boucle est 22.

Le nombre total d'instructions exécutées est donc : $N = 1 + [22 * 200] = 4401$

Le nombre d'instructions de branchement exécutées est de 200 dont 199 générant une pénalité de branchement de 2 cycles => $[199 * 2]$

Enfin il existe 5 aléas de dépendance par itération de boucle dus à la dépendance entre lw \$s1,0(\$s3) et addi \$s1,\$s1,s => le nombre de pénalités est alors :

nombre d'itérations * nombre d'aléas de dépendance par itération = $[200 * 5]$

Le nombre de cycles total nécessaires à l'exécution est donc:

$$[5 + 4401 - 1] + [199 * 2] + [200 * 5] = 4405 + 398 + 1000 = 5803 \text{ cycles}$$

=> Le speedup est de $9003/5803 = 1.55$, soit 1.55 plus rapide avec le loop unrolling

Q3 : Reprenez les 2 estimations précédentes en considérant que le processeur est muni d'un prédicteur de branchement statique

A3 :

Le prédicteur de branchement statique va considérer que les branchements backwards sont pris et donc recherchera les bonnes instructions pour le fetch. Cela élimine les pénalités dues aux branchements dans les 2 équations précédentes :

$$[5 + 6001 - 1] + [999 * 2] + [1000 * 1] \text{ devient } [5 + 6001 - 1] + [1000 * 1] \Rightarrow 7005 \text{ cycles.}$$

$$[5 + 4401 - 1] + [199 * 2] + [200 * 5] \text{ devient } [5 + 4401 - 1] + [200 * 5] \Rightarrow 5405 \text{ cycles.}$$

Compilation – Optimisation automatique

Les compilateurs offrent des options de compilation permettant d'optimiser l'exécution des programmes. Le compilateur C/C++ d'Intel (*icc*: compilateur C - *icpc*: compilateur C++) offre certains niveaux d'optimisation dont les plus habituels sont **-O*i*** (avec *i*=0,1,2,3 - 3 maximum d'optimisation). L'ensemble des options peut être consulté avec *man icc*, ou bien en lisant le manuel */opt/intel_cc/doc/c_ug_lnx.pdf*

Pour ce TP, nous allons utiliser la version 8.0 du compilateur *icc* (la version la plus récente est la version 13.0). Pour initialiser l'environnement, tapez la commande : *Use_intel_cc*

Options de compilation

Dans la première partie, nous souhaitons évaluer l'impact des différents niveaux d'optimisations sur le processeur de votre PC: **-O0, -O1, -O2, -O3**.

Linux* and Mac OS* X	Windows*	Description
-O3	/O3	Enables aggressive optimization for code speed. Recommended for code with loops that perform substantial calculations or process large data sets.
-O2 (or -O)	/O2	Affects code speed. This is the default option; the compiler uses this optimization level if you do not specify anything.
-O1	/O1	Affects code size and locality. Disables specific optimizations.
-fast	/fast	Enables a collection of common, recommended optimizations for run-time performance. Can introduce architecture dependency.
-O0	/Od	Disables optimization. Use this for rapid compilation while debugging an application.

Figure 31 Options de compilation pour icc

Ecrivez un programme qui fait la **multiplication de 2 matrices d'entiers, et de taille 1000** (array_mult.c), que vous initialiserez de manière aléatoire. Le résultat est sauvegardé dans une autre matrice de la même taille. Cette opération sera répétée **10** fois afin de calculer une moyenne plus ou moins précise du temps d'exécution d'une itération.

Pour mesurer précisément le temps pris pour faire ces multiplications, on utilise la fonction **clock()** (dans la librairie <time.h>) avant et après l'exécution du cœur de boucle. La différence entre ces 2 valeurs nous donnera le temps total en microsecondes.

Q1 : Compilez le programme avec chacune des options d'optimisations et complétez le tableau suivant :

A1 :

Tableau 7 Résultats pour les différentes options d'optimisations

Option	Taille du programme (Byte)	Temps (secondes)
-O0	34980	24.78
-O1	35870	18.92
-O2	35870	18.92
-O3	35870	18.91

Observation 1: Taille du programme

Pour une compilation sans optimisation -O0, le compilateur a généré un programme qui est plus petit qu'avec les optimisations -O1, -O2, -O3. Ces derniers sont de taille identique. Cependant, le compilateur utilise des techniques d'optimisation qui, bien que pénalisantes en terme de nombre d'instructions (taille du programme), permettent en général d'augmenter les performances.

Observation 2 : Performances

Pour ce programme, le compilateur a fait les mêmes optimisations pour les options -O1, -O2, -O3. Ceci se remarque en analysant les temps d'exécution ainsi que la taille du programme (invariants). Le temps d'exécution pour les options -O1, -O2, -O3 est 18.92 secondes, soit 5.86 secondes d'amélioration par rapport à la version sans optimisation -O0. Notons que ces informations sont dépendantes du programme et ne peuvent pas être généralisées, puisque dans d'autres programmes, l'option -O3 peut donner des performances bien meilleures que les autres.

Loop unrolling

Dans la seconde partie, nous souhaitons évaluer l'impact de l'option « loop unrolling ».

Dans la version 8.0 du compilateur Intel, le « loop unrolling » est fait automatiquement par le compilateur avec les optimisations **O1**, **O2**, **O3**.

Le programmeur peut contrôler l'activation de cette optimisation en utilisant des « pragma » sur les boucles à partir de son code C.

La syntaxe de la directive 'unroll' est :

#pragma unroll <--- optimisateur décide le nombre d'unrolling

#pragma unroll(n) <--- unroll n times, 0 < n < 255

Cette directive doit être insérée avant la boucle la plus interne.

Q2 : Insérez la directive `#pragma nounroll` avant la boucle la plus interne de votre programme, et recompilez avec l'option `-O3`. Que constatez-vous ?

A2 :

Le temps d'exécution avec #pragma nounroll et compilation -O3 est : **18.104 secondes < 18.92**

secondes

Quand on force le compilateur à ne pas faire de « loop unrolling » pour la boucle interne, le temps d'exécution diminue et devient donc meilleur qu'avec l'option `-O3`, qui par défaut utilise cette optimisation. Ce résultat, qui peut paraître surprenant, sera expliqué dans Q3.

Q3 : Insérez la directive `#pragma unroll(n)` avant la boucle la plus interne de votre programme en faisant varier le nombre **n**, et recompiler avec l'option « `-O3` ». Complétez le tableau suivant. Que constatez-vous ?

A3 :

Tableau 21 Résultats du `#pragma unroll(n)`

n	Taille du programme (Byte)	Temps (secondes)
2	35870	19.02
4	35870	18.35
8	35870	18.08
100	39966	17.838
255	53310	17.846

On constate que le compilateur n'a pas choisi automatiquement le nombre **n** optimal.

En fait, la décision du compilateur est basée sur des heuristiques qui ne peuvent pas être optimales, et qui nécessitent donc l'intervention du programmeur pour ajuster sa décision.

Pour faire un choix optimal, le programmeur doit comprendre la limite des optimisations du compilateur, l'architecture du processeur, ainsi que l'algorithme du programme.

Q4 : Facultatif : En gardant la directive `#pragma nounroll`, effectuez un « loop unrolling » **n** fois de votre boucle manuellement afin de regagner le temps perdu. Vous utiliserez la valeur optimale de **n** obtenue en Q3.

N.B : Tous ces résultats et ces analyses dépendent forcément de la machine utilisée, de la version du compilateur, et du programme que vous avez codé.

Machine utilisée :

AMD Athlon 64-bit Dual core, fréquence = 1 GHz, L1 cache = 128 KB, L2 cache = 512 KB

Compilateur :

Intel C compiler (icc) version 8.0

Code array_mult.c :

```
#include <stdio.h>
#include <stdlib.h>
#include <time.h>

#define N 1000
int main ()
{
    double start, end;

    int loop;
    int i,j,k, count;
    int **a, **b, **c;

    a = (int **) malloc(N*sizeof(int *));
    b = malloc(N*sizeof(int *));
    c = malloc(N*sizeof(int *));

    for (i=0; i < N; i++)
    {
        a[i] = (int *) malloc(N*sizeof(int));
        b[i] = (int *) malloc(N*sizeof(int));
        c[i] = (int *) malloc(N*sizeof(int));
    }

    loop = 10 ;

    for (i=0; i < N; i++)
    {
        for (j=0; j < N; j++)
        {
            a[i][j] = i % 10;
            b[i][j] = i % 20;
            c[i][j] = 0;
        }
    }

    start = clock();

    count = 0;
```

```
while (count < loop)
{
    for (i=0; i < N; i+=1)
    {
        //#pragma nounroll
        //#pragma unroll
        //#pragma unroll(2)
        //#pragma unroll(4)
        //#pragma unroll(8)
        //#pragma unroll(100)
        //#pragma unroll(255)
        for (j=0; j < N; j++)
        {
            c[i][j] = 0;

            for (k=0; k < N; k++)
                c[i][j] += a[i][k] * b[k][j];
        }
        count++;
    }
    end = clock() - start;
    printf("End of program unroll at elapsed time = %10E ...average=%f\n", end, end/loop);
    return 0;
}
```

ENST2



**INSTITUT
POLYTECHNIQUE
DE PARIS**

Annexe 1 : SimpleScalar

Le simulateur SimpleScalar est un simulateur de microprocesseur superscalaire qui permet l'évaluation de performances de différentes architectures. Le simulateur est dans le domaine public sous licence, et est téléchargeable à l'adresse <http://www.simplescalar.com>

L'outil est installé à l'ENSTA dans le répertoire suivant :

- `/usr/ensta/pack/simplescalar-3v0d/bin/ (cross-compilateurs)`
- `/usr/ensta/pack/simplescalar-3v0d/simplesim-3.0/ (interpreteurs)`

Vous pouvez donc choisir d'ajouter ces deux répertoires à votre PATH pour pouvoir appeler directement les outils sans le chemin d'exécution

```
export PATH=$PATH:/usr/ensta/pack/simplescalar-3v0d/bin/:/usr/ensta/pack/simplescalar-3v0d/simplesim-3.0/
```

sim-outorder utilisé sans argument permet d'afficher l'aide et la liste des options.

sim-profile est un outil permettant de faire de l'étude d'applications en phase préliminaire à une exploration architecturale.

sim-cache est un des outils fournis dans la distribution du simulateur SimpleScalar et permet de faire des évaluations de performances pour différentes configurations de cache.

L'utilisation de **sim-cache** se fait de manière générale comme suit :

sim-cache <paramètres de configuration> <toto.ss>

où :

<paramètres de configuration> représentent les paramètres de configuration des caches

<toto.ss> représente un exécutable SimpleScalar résultant de la compilation du programme C toto.c par le compilateur associé à SimpleScalar

sslittle-na-sstrix-gcc toto.c -o toto.ss

Exemple :

sim-cache -cache:il1 il1:256:32:1:l -cache:dl1 dl1:256:32:1:l -cache:dl2 ul2:1024:64:4:l toto.ss

Le simulateur génère en sortie les résultats de la simulation sous forme textuelle dans le terminal. La sortie de **sim-cache** peut être redirigée vers un fichier en utilisant l'option : **-redir:sim fichier.txt**

Les configurations de cache sont spécifiées de la manière suivante :

- cache:dl1 <config>** configure un cache de données de niveau 1
- cache:il1 <config>** configure un cache d'instructions de niveau 1

Pour spécifier un cache unifié de niveau 2 il suffit de d'associer le cache d'instructions sur le cache de données associé, de la manière suivante :

-cache:il2 dl2
-cache :dl2 <config>

Le paramètre **<config>** a le format suivant :

<name> :<nsets> :<bsize> :<assoc> :<repl>

où :

<name> est le nom du cache (unique)
<nsets> est le nombre d'ensembles du cache
<bsize> est la taille du bloc
<assoc> est l'associativité du cache
<repl> est la stratégie de remplacement (l|f|r) avec l = LRU, f = FIFO et r = random replacement

La taille totale du cache spécifié de cette manière est donc calculée par :

Taille du cache = <nsets> * <bsize> * <assoc>

Les valeurs par défaut dans **sim-cache** sont les suivantes :

il1 :256 :32 :1 :l (8 KB)
 dl1 :256 :32 :1 :l (8 KB)
 ul2 :1024 :64 :4 :l (256 KB)

Les paramètres que nous souhaitons analyser sont donnés en sortie du simulateur, comme le montre le tableau suivant.

Tableau 22 Statistiques sur les caches en sortie du simulateur SimpleScalar

sim_num_insn	Nbr total d'instructions exécutées
sim_num.refs	Nbr total de loads et stores exécutés
il1.miss_rate	Miss rate cache instruction L1
dl1.miss_rate	Miss rate cache donnée L1
ul2.miss_rate	Miss rate cache unifié L2

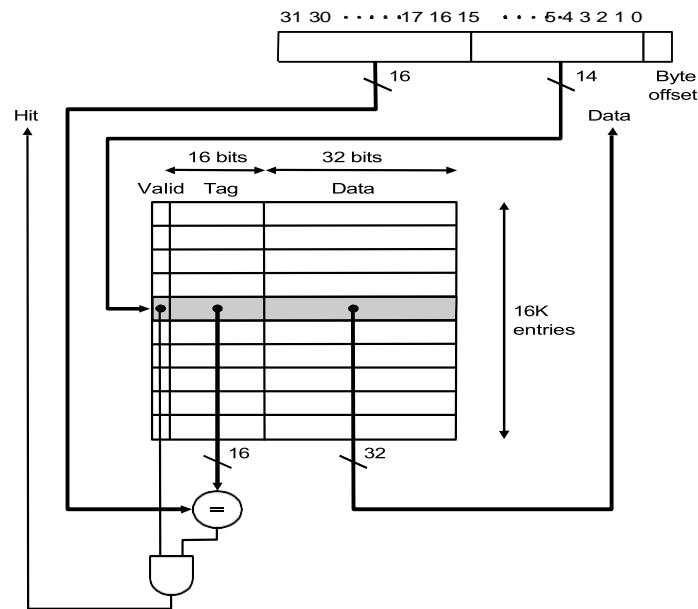


Figure 32 Organisation de cache : exemple DECstation 3100 direct-mapped cache (64 KB, 16 Kwords, 1 word/block)

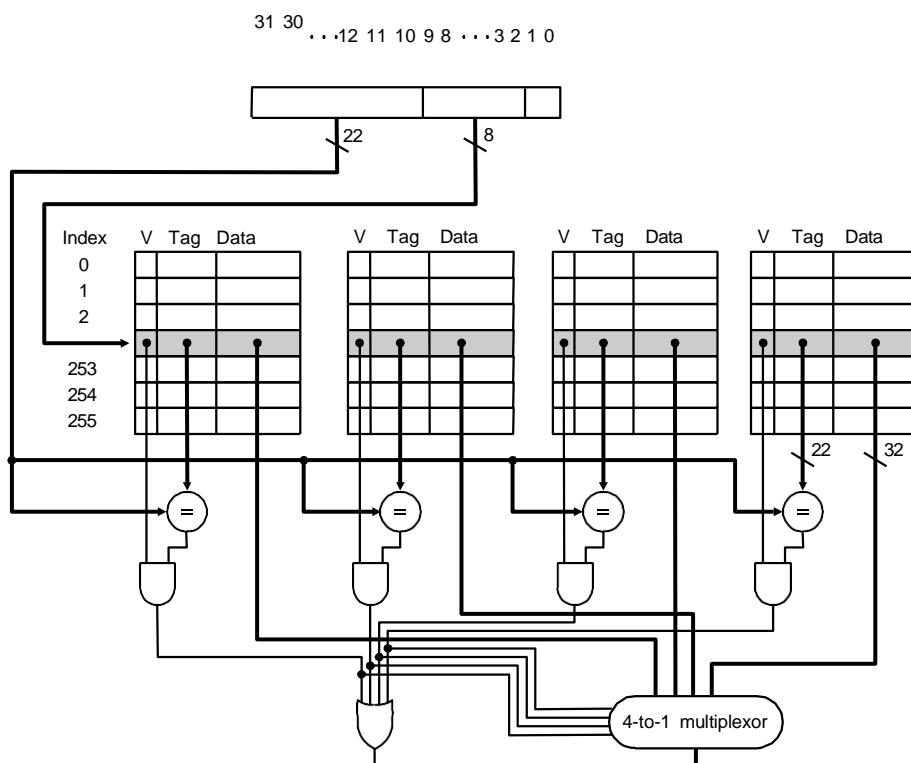


Figure 33 Organisation de cache : 4-way set-associative

Hit Data

Annexe 2 : Applications

Les codes sources de PageRank et de BCS peuvent être récupérés en utilisant la commande suivante, ou `<target directory>` doit être remplacé par le répertoire local que vous ciblez :

```
cp -rfv /home/c/nom-mdc/ES201/tools/graph/* <target directory>
```

avec **nom-mdc** le nom de votre maître de conférences

PageRank

Une implémentation C de l'algorithme de PageRank est proposée. Le source tree est le suivant :

`/home/c/nom-mdc/ES201/tools/graph/PageRank/`:

- main.c examples.h (source code)
- Makefile
- pagerank (binary file, compiled with gcc)
- pagerank_* (binary file for SimpleScalar:
 - o pagerank_min (smallest graph example)
 - o pagerank_med (medium graph example)
 - o pagerank_max (biggest graph example)

Nettoyage du répertoire : **make clean**

Compilation de tous les binaires : **make all**

Betweenness Centrality Score – SSCA #2

Le benchmark *Synthetic Scalable Compact Applications #2* contient des applications de type traitement de graphes. En l'occurrence le benchmark est composé de plusieurs étapes (*kernels*) dont notamment :

- Génération du graphe (2^{SCALE} sommets / $8 \times 2^{\text{SCALE}}$ arcs)
- Prétraitements (sélection de sous-ensembles et extraction)
- Analyse du graphe (Calcul du score de centralité d'intermédiairité pour un sous set de sommet).

La génération du binaire se fait via “make”. **USAGE** : sim-* SSCA2.ss <SCALE> (valeurs recommandées : entre 4 et 8).

Source tree:

`/home/c/nom-mdc/ES201/tools/graph/SSCA2v2-C/`

- *.ch (source code)
- *.doc README (article/document détaillant la suite SSCA #2)
- Makefile
- SSCA2.ss (binary file for SimpleScalar)

La multiplication de polynômes

Voici un petit rappel sur la multiplication de polynôme. Multiplier deux polynômes de degré N (N+1 coefficients) revient à faire le calcul de la convolution linéaire de leur séquence de coefficient. Soit $A = \sum_{i=0}^N a_i \cdot X^i$ et $B = \sum_{i=0}^N b_i \cdot X^i$ deux polynômes.

Le polynôme produit de A par B :

$$C = A * B = \sum_{i=0}^{2N} c_i \cdot X^i$$

Les coefficients de C vérifient pour tout $i \in \llbracket 0; 2N \rrbracket$:

$$c_i = \sum_{k=0} a_k \cdot b_{i-k}$$

Secure Hash Algorithm (SHA-1)

Les fonctions de hachage (hash functions) calculent une empreinte servant à identifier rapidement, bien qu'incomplètement, une donnée initiale. En cryptographie ces fonctions sont employé entre autres pour la signature électronique, et rend également possibles des mécanismes d'authentification par mot de passe sans stockage de ce dernier.

Le code C utilisé dans ce TP provient de l'ensemble de benchmarks MiBench. Le Makefile original a été modifié pour compiler l'application avec le compilateur de SimpleScalar.

Récupérez le code source avec les commandes suivantes :

```
cp /home/c/nom-mdc/ES201/tools/sha_modified.tar.gz <your_directory>
```

```
tar xzf <your_directory>/sha_modified.tar.gz
```

Compiler le binaire pour SimpleScalar:

```
cd <your_directory>/sha
```

```
make
```

Le binaire pour SimpleScalar est désormais à votre disposition: <your_directory>/sha/sha.ss Le fichier d'entrée qui nous intéresse est: <your_directory>/sha/input_small.asc

Voici un exemple de lancement d'une simulation SimpleScalar :

```
sim-outorder <options> sha.ss input_small.asc
```

Bloc cipher BlowFish

Les chiffrements par bloc (block cipher) sont les éléments centraux des protocoles de chiffrement symétrique [TP4/11]. BlowFish est l'un des premiers chiffrements par bloc à être entré dans le domaine public (non breveté).

Le code C utilisé dans ce TP provient de l'ensemble de benchmarks MiBench. Le Makefile original ainsi que les fichiers d'inputs ont été modifié pour s'adapter à notre TP.

Récupérez le code source avec les commandes suivantes :

```
cp /home/c/nom-mdc/ES201/tools/blowfish_modified.tar.gz <your_directory>
tar xzf <your_directory>/blowfish_modified.tar.gz
```

Compiler le binaire pour SimpleScalar:

```
cd <your_directory>/blowfish
```

```
make
```

Le binaire pour SimpleScalar est désormais à votre disposition: <your_directory>/blowfish/bf.ss

Les fichiers d'entrée qui nous intéressent sont:

<your_directory>/blowfish/input_[small/medium/large].asc

Voici un exemple de lancement d'une simulation SimpleScalar :

```
sim-outorder <options> bf.ss e input_small.asc output_small.enc 1234567890abcdeffedcba0987654321
```

Avec:

- e** : option indiquant à bf.ss qu'on est en mode chiffrement (encrypt)
- input_small.asc** : le fichier d'entrée (les données à chiffrer)
- output_small.dec** : le fichier de sortie (les données chiffrées)
- 123456789abcdefedcba0987654321** : la clé de chiffrement

Autres applications 2020 :

- **MLPerf** : Fair and useful benchmarks for measuring training and inference performance of ML hardware, software, and services. <https://mlperf.org/>
- **EEMBC** : <https://www.eembc.org/>

Annexe 3 : gem5 – généralités

Le simulateur gem5 est une plateforme d'exploration architecturale issue de la fusion de deux projets de recherche (GEMs et M5). Cette plateforme est de plus en plus utilisée, aussi bien dans le milieu industriel que dans le domaine de la recherche. Citons à titre d'exemple les contributions actives sur le projet de AMD, ARM, HP, MIPS, Princeton, MIT, et les universités du Michigan, du Texas et du Wisconsin.

Cet outil étant de plus en plus admis par la communauté, nous nous proposons de l'utiliser pour explorer quelques paramètres d'une architecture multiprocesseur. L'utilisateur de la plateforme gem5 a la possibilité de construire et de simuler des systèmes complets, en connectant de nombreux éléments paramétrables : modèles de processeurs (scalaires, superscalaires in-order, superscalaires out-of-order), jeux d'instructions (ARM, Alpha, MIPS, PowerPC, SPARC, x86), systèmes mémoire, protocoles de cohérence de cache, bus système, gestionnaire d'appels systèmes, etc.

Pour mieux comprendre l'infrastructure de ce simulateur, veuillez consulter la documentation depuis :
<http://www.m5sim.org/Documentation>

Toutes les étapes pour construire et utiliser un environnement de simulation complet sont détaillées ci-dessous. Cependant, les étapes 1 à 3 figurent ici à titre purement informatif, puisque pour les besoins du TD/TP6, ces étapes ont déjà été effectuées sur les stations de travail.

1. Résolution des dépendances, récupération des sources et compilation de gem5 :

La liste des dépendances nécessaires pour l'obtention et la compilation des fichiers sources de gem5 peut être trouvée à l'adresse suivante : <http://www.m5sim.org/Dependencies>

A titre d'exemple, la commande suivante convient sur une distribution Ubuntu récente :

```
> sudo apt-get install mercurial scons swig gcc m4 python python-dev libgoogle-perf-tools-dev g++
```

Sous réserve de pouvoir résoudre les dépendances ci-dessus, il est bien évidemment possible d'utiliser gem5 dans votre distribution préférée ou dans un environnement différent.

Ensuite, les commandes suivantes permettent de se déplacer dans le répertoire d'installation locale de gem5 et d'extraire le dépôt stable le plus récent de la plateforme :

```
> cd /path/to/local-installation  
> hg clone http://repo.gem5.org/gem5  
> cd gem5  
> scons build/ARM/gem5.opt
```

Notons qu'il est possible de compiler différents types de simulateurs (*gem5.debug*, *gem5.opt*, *gem5.fast*, *gem5.prof*, *gem5.perf*) suivant les besoins de l'utilisateur. Pour plus d'informations, se référer à la documentation.

Notons également que dans le cas présent, la plateforme compilée est un simulateur dont les processeurs utilisent le jeu d'instruction ARM. Il est bien sûr possible de construire une plateforme équivalente pour un autre type de jeu d'instructions, pour peu qu'il soit supporté (voir ci-dessus).

2. Installation du cross-compilateur :

Contrairement à SimpleScalar (Annexe 1) qui embarque son propre jeu d'instructions et le compilateur C associé, le simulateur gem5 est multi jeux d'instructions. C'est pourquoi l'utilisateur doit pouvoir compiler ses programmes avec la chaîne d'outils associée à la plateforme qu'il a préalablement construite (étape 1).

Dans le cas du système généré dans l'étape 1 ci-dessus, il faut donc disposer d'une chaîne d'outils ARM afin de compiler les programmes à simuler (ou bien disposer des binaires de l'application préalablement compilés).

La première solution consiste à installer les chaînes d'outils fournies avec votre distribution, si elle les propose (exemple pour Ubuntu : installer **g++-arm-linux-gnueabi** et **g++-arm-linux-gnueabihf**). La société Mentor propose aussi, sous réserve de création d'un compte, d'obtenir des chaînes d'outils pour de nombreux jeux d'instructions cibles à l'adresse suivante : <https://sourcery.mentor.com/>

3. Installation de la librairie m5threads :

La librairie *m5threads*, développée par des contributeurs de gem5, est nécessaire pour implémenter des applications multithreads (création, destruction, gestion de threads). Il faut donc d'abord récupérer les sources de la librairie sur le dépôt suivant :

```
> cd /path/to/local-installation  
> hg clone http://repo.gem5.org/m5threads  
> cd m5threads/tests
```

Ensuite, on modifie (si nécessaire) le ***Makefile*** situé à la racine du dépôt afin de compiler la librairie avec la chaîne d'outils installée dans l'étape 2, puis :

```
> make
```

4. Compilation et exécution d'un programme sur le simulateur gem5 :

Il existe principalement deux manières d'utiliser le simulateur gem5, dont les différentes spécificités et les différents cas d'utilisations sont trouvables sur la documentation en ligne :

- FS mode (Full System mode)
- SE mode (Syscall Emulation mode)

Dans le cadre du TD/TP6, nous utiliserons le mode SE. Par défaut, le répertoire gem5 contient déjà des exécutables d'exemple afin de lancer une première simulation, comme ceci :

```
> build/ARM/gem5.opt config/examples/se.py -c tests/test-progs/hello/bin/arm/linux/hello
```

gem5.opt : exécutable du simulateur
se.py : fichier de configuration de la plateforme
hello : binaire à simuler

Pour compiler notre propre programme à exécuter dans gem5, on utilise la chaîne d'outils installée dans l'étape 2. Notons qu'il est nécessaire d'embarquer, dans l'exécutable qui sera généré, tous les symboles (fonctions, données) contenues habituellement dans des librairies dynamiques. Pour ce faire, on compilera le programme en statique (ci-dessous et pour exemple *toto.c*) :

```
> /path/to/toolchain/bin/arm UNKNOWN-elf-gcc toto.c -static
```

Cas particulier : Si votre programme est multithreads (c'est le cas de l'application de multiplications de matrices étudié dans le TD/TP6), il faut bien évidemment linker le fichier objet (*libpthreads.o*) de gestion de threads, créé dans l'étape 3. Lors de la compilation de l'application, la commande de création de liens devient donc :

```
> /path/to/toolchain/bin/arm UNKNOWN-elf-gcc -o matrix_mult.exe matrix_mult.o pthreads.o -static
```

Note : A tout moment, vous pouvez accéder à la documentation de l'exécutable du simulateur et à la documentation de la configuration utilisée :

```
> build/ARM/gem5.opt --help  
> build/ARM/gem5.opt config/examples/se.py --help
```

5. Statistiques d'exécution de gem5 :

Pour visualiser les statistiques d'exécution d'un programme, ouvrir avec votre éditeur de texte favori le fichier généré suivant :

```
> $WORK/m5out/stats.txt
```

Note annexe : Vous pouvez exécuter le simulateur *gem5.opt* en faisant varier une très importante quantité de paramètres système. Pour cela, il convient de bien se familiariser avec la structure et la syntaxe du simulateur, afin de pouvoir modifier correctement la structure du système, qui pour rappel est décrite dans le fichier :

> **\$WORK/config/examples/se.py**

Annexe 4 : gem5 – mémo TP5-6

Log in sur machine salle 2013 :

```
> ssh <votre_login>@salle2013.ensta.fr
```

Compilation de l'application de multiplication de matrice :

Récupérer et compiler les sources de m5threads :

```
> hg clone http://repo.gem5.org/m5threads
> cd m5threads/tests
> make
```

Commande pour lancer une simulation :

<GEM5 exécutable> <architecture système> <options architecture> <exécutable appli>

où :

<GEM5 executable> :	/opt/gem5/build/ARM/gem5.[opt fast]
<architecture système> :	/opt/gem5/configs/example/se.py
<options architecture> :	--cpu-type = atomic arm-detailed detailed
<i>Atomic => Processeur scalaire</i>	
<i>arm-detailed => Cortex A7</i>	
<i>detailed => Cortex A15</i>	
--caches	//à utiliser avec 'arm-detailed' et 'detailed'
-n NCPU	//NCPU = nombre de CPUs
-w WIDTH	//WIDTH = issue width pour 'detailed' model
< exécutable appli> :	-c <nom de l'exécutable>
	-o "<args>"

<nom de l'exécutable> = \$HOME/m5threads/tests/test_omp

<args> = "N M"

N: nombre de threads

M: taille de la matrice carrée

N.B#1 : le nombre de CPU **NCPU** doit être plus grand ou égal au nombre de thread logiciel **N**

N.B#2 : pour savoir les paramètres de l'architecture modélisée, il suffit de consulter l'aide

```
/opt/gem5/build/ARM/gem5.fast /opt/gem5/configs/example/se.py --help
```

Statistiques :

Les statistiques de la simulation se trouvent dans **m5out/stats.txt**

Exemples de statistiques intéressantes pour le TD/TP6 :

- > **sim-insts** : total executed instructions (on all cores)
- > **system.cpu<i>.committedInstns** : executed instructions on core <i>
- > **system.cpu<i>.numCycles** : cycles on core <i>
- > **system.cpu<i>.cpi**
- > **system.cpu<i>.ipc**
- > **Les statistiques de caches**

Commandes utiles :

TP5 (fichier /home/c/nom-mdc/ES201/tools/TP5/README):

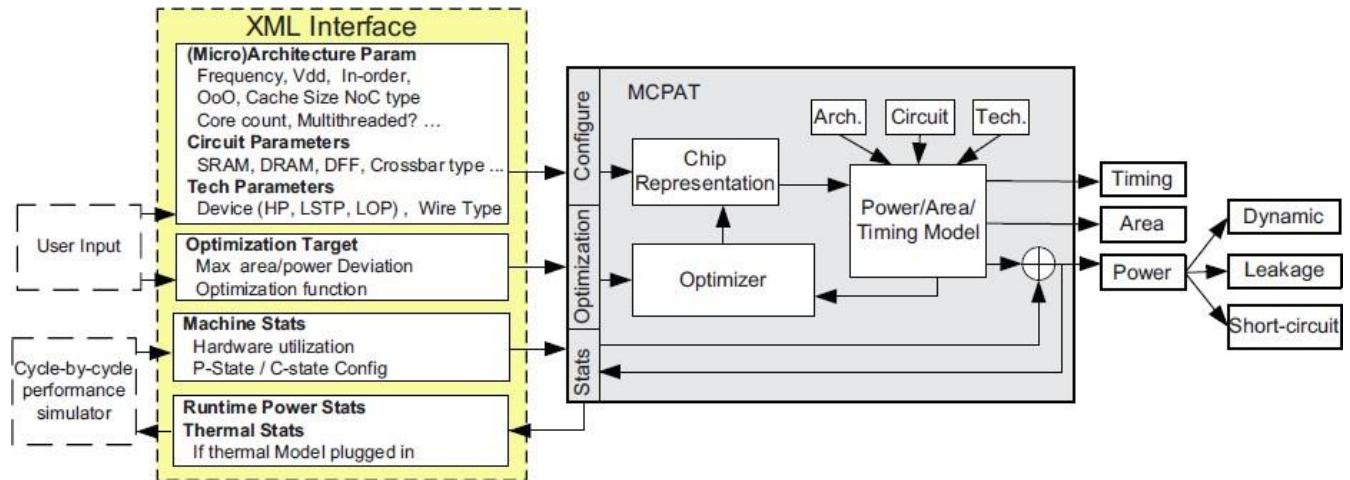
```
$cp -v /home/c/nom-mdc/ES201/tools/TP5/test_omp <target directory>
```

```
export GEM5=/home/c/nom-mdc/ES201/tools/TP5/gem5-stable
```

```
$GEM5/build/ARM/gem5.fast $GEM5/configs/example/se.py -c <bin> -o "<options>"
```

Annexe 5 : McPAT: An Integrated Power, Area, and Timing Modeling Framework for Multicore and Manycore Architectures

<https://www.hpl.hp.com/research/mcpat/>



Block diagram of the McPAT framework.

Références

www.intel.com, www.arm.com, www.amd.com, www.ieee.org, www.acm.org, www.cadence.com,
www.synopsys.com, www.qualcomm.com, www.mentor.com

Energy Efficient Microprocessor Design Burd, T. D., Brodersen, R. W. (2002)

Computer Organization and Design RISC-V Edition: The Hardware Software Interface (ISSN) (English Edition) 1 de D.A. Patterson , J. L. Hennessy

Parallel Computer Organization and Design by Michel Dubois, Murali Annavaram, et al.

Computer Architecture: A Quantitative Approach (The Morgan Kaufmann Series in Computer Architecture and Design) J.L. Hennessy and D.A. Patterson

Computer Organization and Architecture (10th Edition) 10th Edition by William Stallings

TP2

Online pipeline simulator: <http://www.ecs.umass.edu/ece/koren/architecture/windlx/main.html>

[1] **D. A. Bader, J. Feo, J. Gilbert, J. Kepner, D. Koester, E. Loh, K. Madduri, B. Mann, T. Meuse**, HPCS Scalable Synthetic Compact Applications #2 Graph Analysis
http://www.graphanalysis.org/benchmark/HPCS-SSCA2_Graph-Theory_v2.1.pdf

[2] **Léo Ducas**, Une cryptographie nouvelle: le réseau euclidien, GLMF-178, GNU/Linux Magazine, <http://connect.ed-diamond.com/GNU-Linux-Magazine/GLMF-178/Une-cryptographie-nouvelle-le-reseau-euclidien>

[3] **J. Fan and F. Vercauteren**, Somewhat practical fully homomorphic encryption. *IACR Cryptology ePrint Archive*, 2012:144, 2012.

TP3

[1] **L. Page, S. Brin, R. Motwani, and T. Winograd**, The PageRank Citation Ranking: Bringing Order to the Web. Technical Report. Stanford InfoLab <http://ilpubs.stanford.edu:8090/422/>

TP4

[1] EDN 2010 Microprocessor Directory

[2] Intel : www.intel.com

[3] AMD : www.amd.com

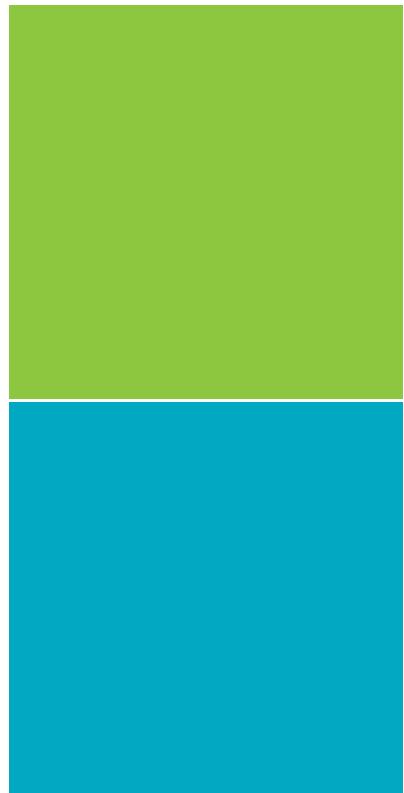
- [4] Arm : www.arm.com
- [5] MIPS : www.mips.com
- [6] ARM big.LITTLE : www.arm.com/files/downloads/big.LITTLE_Final.pdf
- [7] MiBench : www.eecs.umich.edu/mibench
- [8] CACTI : <http://www.hpl.hp.com/research/cacti/>
- [9] B. Schneier, Applied Cryptography, *Protocols Algorithms and Source Code in C*, 1996, John Wiley & Sons
- [10] B. Schneier,
https://www.schneier.com/academic/archives/1994/09/description_of_a_new.html
- [11] M. Bellare and P. Rogaway, Introduction to modern cryptography, *Lectures Notes*,
<https://cseweb.ucsd.edu/~mihir/cse207/classnotes.html>

TP5

- [1] Intel Pentium 4 HT : <http://www.intel.com/technology/platform-technology/hyper-threading/index.htm>
- [2] IBM POWER5 : <http://www-03.ibm.com/systems/power/>
- [3] Sun UltraSPARC T2 : www.sun.com/processors/UltraSPARC-T2/
- [4] Intel Ivy Bridge : <http://www.intel.com/technology/architecture-silicon/next-gen/>
- [5] gem5 : <http://www.m5sim.org/>
- [6] OpenMP : <http://www.openmp.org/>

TP6

- [1] <http://www.connaissance-des-energies.org/fiche-pedagogique/chiffres-cles-production-d-energie>
- [2] http://www.nytimes.com/2012/09/23/technology/data-centers-waste-vast-amounts-of-energy-belying-industry-image.html?_r=0
- [3] **Carroll, Aaron and Heiser, Gernot**, “The Systems Hacker’s Guide to the Galaxy, Energy Usage in a Modern Smartphone”, available online (<http://www.nicta.com.au/pub?doc=7044>)
- [4] **Shye, Alex et al.**, “Into the Wild: Studying Real User Activity Patterns to Guide Power Optimizations for Mobile Architectures” available online (<http://dl.acm.org/citation.cfm?doid=1669112.1669135>)



**École Nationale Supérieure
de Techniques Avancées**

828, boulevard des Maréchaux - 91762 Palaiseau Cedex - France
www.ensta-paris.fr

ENSTA



**INSTITUT
POLYTECHNIQUE
DE PARIS**